

STATISTIK – ÜBUNGEN TEIL I – DESKRIPTIVE STATISTIK - Ausarbeitung

Michael Geuze

March 05, 2024

Technische Fertigkeiten

A-1)

- a. Bestandsgröße
- b. Bewegungsgröße
- c. Bestandsgröße
- d. Bewegungsgröße
- e. Bewegungsgröße

A-2)

- a. Grundgesamtheit sind die Anrufe je 10 Minuten entsprechend der Liste. Die beobachteten Merkmale ist die Häufigkeit je 10 Minuten. Sie sind metrisch und proportional skaliert.
- b. Zur Aufgabe b)

```
# Raw input data
cpi.raw <- c(0, 0, 1, 3, 4, 1, 2, 2, 1, 1, 1, 2, 3, 0, 2, 0, 1, 3, 1, 2, 2, 0, 1, 1, 6, 1, 0,
2, 3, 1, 1, 4, 2, 3, 2, 0, 3, 0, 1, 2) # Calls per interval

# Scale factor for y axis of barplot. Controls how much the scale goes beyond the last value
scale_factor <- 1.1

# Settings for boxplot
# IQR * whiskers_factor
whiskers_factor <- 1.5
# Use ceil, resp, floor function on IQR * whiskers_factor
quantize_outliers <- TRUE
# Maximum outlier value. Deviation of q50 must be in range of IQR * max_outlier
max_outlier_factor <- 6

data <- cpi.raw # Write to data, rest of script can be reused

data.table <- table(factor(data, 0:6))
print("Absolute Häufigkeitstabelle")
```

```
## [1] "Absolute Häufigkeitstabelle"
```

```
data.table
```

```
##
##  0  1  2  3  4  5  6
##  8 13 10  6  2  0  1
```


```
data.len <- length(data)
```

```
# Absolute occurrences
```

```
data.element_counts <- data.table
```

```
barplot(data.element_counts, ylim = c(0,max(data.element_counts) * scale_factor), ylab = "Anzahl", xlab = "Telefonate im Intervall von 10 min", main = "Absolute Häufigkeit", col = "green")
```

Absolute Häufigkeit



```
# Relative occurrences
```

```
data.element_frq <- data.table/data.len
```


```
print("Relative Häufigkeitstabelle")
```

```
## [1] "Relative Häufigkeitstabelle"
```

```
data.element_frq
```

```
##  
##      0      1      2      3      4      5      6  
## 0.200 0.325 0.250 0.150 0.050 0.000 0.025
```

```
barplot(data.element_frq, ylim = c(0,max(data.element_frq) * scale_factor), ylab = "Anzahl",  
xlab = "Telefonate im Intervall von 10 min", main = "Relative Häufigkeit", col = "blue")
```




```

# Set variables for plot
data.table.len <- length(data.table)
colors <- rainbow(data.table.len)
space_initial <- 1.4
space_between <- 1.2
spacing <- seq(space_initial, length.out = data.table.len, by = space_between)

# Create initial barplot
barplot(rep(data.table[1], length(data.table)), ylim = c(0,(sum(data.table) * scale_factor)),
ylab = "Kumulierte Anzahl", xlab = "Telefonate im Intervall von 10 min", main = "Summenhäufigkeit", col = colors[1], names.arg = names(data.table))

# Add all data on top of other, change color while doing so
offset_var <- cumsum(data.table)
for(loop_outer in (data.table.len - 1) : 1){
  idx <- data.table.len - loop_outer
  for(loop_inner in 1:loop_outer){
    barplot(data.table[idx + 1], add = TRUE, col = colors[idx+1],
      offset = offset_var[idx], names.arg = NA,
      space = spacing[idx + loop_inner - 1])
  }
}

```



- c. Schätzung: es kommen etwa 1,5 Gespräche alle 10 Minuten. Median ist ziemlich genau bei 1. Wenn bei der Achse "Kumulierte Anzahl" bei 20 eine Linie eingezeichnet werden würde, so wäre diese recht genau beim Balken "1".
- d. Nachfolgen werden alle geforderten Werte berechnet und mit cat gedruckt.

```
data.sorted <- sort(data)

# Positional parameters
data.mode <- names(data.table)[which(data.table == max(data.table))]
if (length(data.mode) != 1){
  data.mode <- NA
}

if (data.len %% 2) {
  upper <- data.sorted[ceiling(data.len/2)]
  lower <- data.sorted[floor(data.len/2)]
  data.q50 <- (upper + lower) / 2
}else{
  data.q50 <- data.sorted[data.len/2]
}

data.mean <- sum(data)/data.len
cat("Zentralmaße", "\nModus:", data.mode, "\nMedian:", data.q50, "\nMittelwert:", data.mean)
```

```
## Zentralmaße
## Modus: 1
## Median: 1
## Mittelwert: 1.625
```

```
# Scattering parameters
data.min <- min(data)
data.max <- max(data)
data.range <- data.max - data.min
cat("Streumaße", "\nMinimalwert:", data.min, "\nMaximalwert:", data.max, "\nSpannweite:", data.range)
```

```
## Streumaße
## Minimalwert: 0
## Maximalwert: 6
## Spannweite: 6
```

```
# Quantiles
data.q25.pos <- ceiling(data.len/4)
data.q25 <- data.sorted[data.q25.pos]
data.q75.pos <- floor(3*data.len/4)
data.q75 <- data.sorted[data.q75.pos]
cat("Quantile", "\nOberes Quantil:", data.q75, "\nUnteres Quantil:", data.q25)
```

```
## Quantile
## Oberes Quantil: 2
## Unteres Quantil: 1
```

```
data.mean_abs_dev <- sum(abs(data))/data.len
data.std_dev <- sqrt(sum((data.mean - data)^2) / data.len)
data.std_dev_emp <- sqrt(sum((data.mean - data)^2) / (data.len-1))
cat("Mittlere absolute Abweichung:", data.mean_abs_dev, "\nStandardabweichung:", data.std_dev,
    "\nEmpirische Standardabweichung:", data.std_dev_emp)
```

```
## Mittlere absolute Abweichung: 1.625
## Standardabweichung: 1.316957
## Empirische Standardabweichung: 1.333734
```

```
# Automated calculation for cross check
mean(data)
```

```
## [1] 1.625
```

```
sd(data)
```

```
## [1] 1.333734
```

```
summary(data)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      0.000   1.000   1.000   1.625   2.000   6.000
```


- e. Die gerade generierten Daten werden nun zu einem Boxplot zusammengefasst. Hierfür wird noch der Interquartilabstand berechnet. Davon ausgehend werden die Ausreißer berechnet und als solche dargestellt. Die Anzahl der Ausreißer die $IQR * \text{max_outlier_factor}$ überschreiten, sollte es welche geben, werden als Warnung ausgegeben und im Boxplot ignoriert.

```

data.iqr <- data.q75 - data.q25
if (quantize_outliers){
  data.outliers.max.val <- ceiling(data.q50 + data.iqr * whiskers_factor)
  data.outliers.min.val <- floor(data.q50 - data.iqr * whiskers_factor)
}else{
  data.outliers.max.val <- data.q50 + data.iqr * whiskers_factor
  data.outliers.min.val <- data.q50 - data.iqr * whiskers_factor
}
data.outliers.pos <- data.sorted < data.outliers.min.val | data.sorted > data.outliers.max.val
data.outliers <- data.sorted[data.outliers.pos]
# Get rid of outliers out of range. If there is one, print warning
data.outliers.bool <- data.outliers - data.q50 < data.iqr * max_outlier_factor
if (!all(data.outliers.bool)){
  cat("Warning:", length(data.outliers) - sum(data.outliers.bool), "outliers were ignored.")
}
data.outliers <- data.outliers[data.outliers.bool]
data.inliers <- data.sorted[!data.outliers.pos]

bxp_obj <- list(
  stats = matrix(
    c(min(data.inliers), data.q25, data.q50, data.q75, max(data.inliers),
      ncol = 1)),
  n = c(data.len),
  conf = matrix(c(1, 1), ncol = 1), # Conf is not drawn, so its not calculated either
  out = data.outliers,
  group = rep(1, times = length(data.outliers)), # Every outlier is in group 1
  names = "Telefonate"
)
bxp(bxp_obj, show.names = TRUE, pars = c(boxcol = "blue", boxfill = "lightblue",
  outcol = "red"))

```



In dieser Arbeit wurde für den Einstieg alles “händisch” durchgeführt. In den weiteren Aufgaben werden die systemeigenen Funktionen verwendet.