

Wahrscheinlichkeitsrechnung für Elektrotechnik

Hans-Georg Beyer

Hans-Georg.Beyer@fhv.at

Center for Process and Product Engineering
Vorarlberg University of Applied Sciences



Einführung in die Wahrscheinlichkeitsrechnung

Motivation und Anforderungen

Ziele der Wahrscheinlichkeitsrechnung:

- Beschreibung und Mathematisierung des Zufalls
- Vorhersagen des Ausgangs von “Experimenten”, Prozessen, etc.
- Nutzbarmachung des Zufalls in Technik, Wirtschaft und Wissenschaft
- Grundlagen für die mathematische Statistik mit den Teilbereichen
 - ① deskriptive Statistik (beschreibende Statistik)
 - ② induktive Statistik (mathematische Statistik)
 - ③ explorative Statistik (Modell- und Hypothesenbildung “*data mining*”)

Anwendungsfelder in der Elektrotechnik/Elektronik:

- stochastische physikalische Modelle von Bauelementen
- stochastische Signaltheorie und Rauschtheorie
- Zuverlässigkeitsanalysen und Qualitätsmanagement



Voraussetzungen für diese Lehrveranstaltung

- andere Denk- und Zugangsweise im Vergleich zur bisherigen Mathematikausbildung
- sicheres Beherrschen des bisherigen Mathematikstoffes ist die *conditio sine qua non* (Bedingung, ohne die nichts geht) für das Verstehen und den erfolgreichen Abschluß dieser Lehrveranstaltung

Insbesondere werden benötigt:

- ① sicheres Beherrschen der Logik und Mengenlehre
- ② Anfangsgründe der Kombinatorik
- ③ Differential- und Integralrechnung

Planen Sie *überproportional* viel Zeit für die Nacharbeit der Vorlesung und Vorbereitung der Übungen ein!

Bearbeiten Sie die Übungsaufgaben zeitnah!!!



Diese Vorlesung hat mit der Quantifizierung des Zufalls zu tun, um dessen Definition und dessen Ursachen kümmern wir uns *nur* auf dieser Seite:

Was ist Zufall? Definitionsversuche:

“Zufall ist ein Prozeß, der so oder auch anders ablaufen kann”

(PHILOSOPHISCHES WÖRTERBUCH)

“Zufall ist das Unvermögen einer 100%-igen Vorhersage”

(HGB)

Quellen des Zufalls

- 1 quantenmechanische Effekte:
HEISENBERG's Unschärferrelation (Impuls-Ort-, Energie-Zeit-Unschärfe)
- 2 prinzipielle Meßungenauigkeiten:
thermisches Rauschen, Systemoffenheit
- 3 schwache Stabilität nichtlinearer Systeme:
chaotisches Verhalten, empfindliche Abhängigkeit von Anfangs- oder Randbedingungen
- 4 Informationsmangel



Grundbegriffe

Die Begrifflichkeiten der Wahrscheinlichkeitsrechnung drehen sich um die mathematische Beschreibung

- zufälliger Versuche (auch Zufallsexperimente) und
- zufälliger Ereignisse.

Definition 1.1 (Zufälliger Versuch)

Ein Versuch (oder Experiment), der unter *definierten gleichen Bedingungen beliebig oft wiederholbar* ist und dessen *Ergebnis* (engl: outcomes) im Bereich gewisser Möglichkeiten *ungewiß (unvorhersagbar)* ist, wird als zufälliger Versuch (oder Zufallsexperiment, Zufallsversuch) bezeichnet.

Beispiele 1.2

<i>zufälliger Versuch</i>	<i>mögliche Ergebnisse</i>	
Werfen einer Münze	“Zahl” (Z), “Wappen” (W)	(a)
Werfen zweier Münzen	“WW”, “WZ”, “ZW”, “ZZ”	(b)
Werfen eines Würfels	Augenzahl $k = 1, \dots, 6$	(c)
Ausfall eines Power-MOSFETs	Lebensdauer $t \in [0, \infty)$	(d)

Beispiele 1.2 (Fortsetzung)

<i>zufälliger Versuch</i>	<i>mögliche Ergebnisse</i>	
<i>Anzahl defekter Chips auf einem Wafer</i>	<i>Anzahl z, $z = 0, 1, 2, \dots$</i>	(e)
<i>Anzahl der Ersatzteile, die innerhalb eines Zeitintervalls geordert werden</i>	<i>Anzahl b, $b = 0, 1, 2, \dots$</i>	(f)
<i>Häufigkeit von Blitzeinschlägen in eine Hochspannungsleitung pro Zeiteinheit</i>	<i>Anzahl h, $h = 0, 1, 2, \dots$</i>	(g)
<i>Momentanspannung über einen hochohmigen Widerstand</i>	<i>Spannung U, $U \in (-\infty, \infty)$</i>	(h)
<i>E-Energiebedarf einer Stadt in einem Zeitintervall</i>	<i>Arbeit W, $W \in (0, \infty)$</i>	(i)
<i>Momentanleistung einer Windenergieanlage</i>	<i>Leistung P, $P \in (0, \infty)$</i>	(j)
<i>Regenmenge pro Quadratmeter innerhalb eines Zeitintervalls</i>	<i>Volumen V, $v \in [0, \infty)$</i>	(k)

Definition 1.3 (Grundraum, Ergebnis)

Die Menge aller möglichen Ergebnisse eines Zufallsexperiments wird *Grundraum* (oder Ergebnismenge, Ergebnisraum, engl.: sample space) Ω genannt

$$\Omega = \{\omega \mid \omega \text{ ist mögliches Ergebnis eines Zufallsversuchs}\}. \quad (1.1)$$

Ein Element ω von Ω heißt *Ergebnis*.

Definition 1.4 (Ereignis, Elementarereignis)

Eine Menge von Ergebnissen heißt *Ereignis* (engl.: event), üblicherweise symbolisiert durch große lateinische Buchstaben. Ein Ereignis, das genau ein Element besitzt, heißt *Elementarereignis*.

Beispiel 1.5 (einfacher Münzwurf, vgl. Bsp. 1.2a)

Der Grundraum ist $\Omega = \{Z, W\}$,
Elementarereignisse sind $A = \{Z\}$ und $B = \{W\}$.

Beispiel 1.6 (zweifacher Münzwurf, vgl. Bsp. 1.2b)

Der Grundraum ist $\Omega = \{ZZ, ZW, WZ, WW\}$,

Elementarereignisse sind $A = \{ZZ\}$, $B = \{ZW\}$, $C = \{WZ\}$ und $D = \{WW\}$,

Ereignis “gleicher Ausgang” $G = \{ZZ, WW\}$,

Ereignis “ungleicher Ausgang” $G = \{ZW, WZ\}$.

Beispiel 1.7 (Lebensdauer eines Power-MOSFETs, vgl. Bsp. 1.2d)

Der Grundraum ist $\Omega = \{t | t \in \mathbb{R} \wedge t \geq 0\}$,

Elementarereignisse sind alle $T = t$ mit $t \geq 0$,

Ereignis “Ausfall bis zum Zeitpunkt $t = t_1$ ”: $T = \{t | t \leq t_1\} = [0, t_1]$,

Ereignis “kein Ausfall bis zum Zeitpunkt $t = t_2$ ”: $T = \{t | t > t_2\} = (t_2, \infty)$.

Beispiel 1.8 (Anzahl defekter Chips, vgl. Bsp. 1.2f)

Der Grundraum ist $\Omega = \mathbb{N}$,

Elementarereignisse sind alle $Z = \{z\}$ mit $z \in \mathbb{N}$,

Ereignis “Wafer ist ohne defekte Chips”: $Z = \{0\}$,

Ereignis “Es gibt weniger als z_1 defekte Chips”: $Z = \{0, \dots, z_1 - 1\}$.

Es gibt zwei “Grenzfälle” zufälliger Ereignisse:

Definition 1.9 (sicheres Ereignis, unmögliches Ereignis)

Ein Ereignis, das bei jeder Wiederholung des Zufallsexperiments eintritt, wird als *sicheres Ereignis* bezeichnet und mit Ω symbolisiert.

Ein Ereignis, das bei jeder Wiederholung des Zufallsexperiments *niemals* eintritt, wird als *unmögliches Ereignis* bezeichnet und mit “ $\emptyset$ ” symbolisiert.

Anmerkung 1.10

Da der Grundraum (vgl. Def. 1.3) alle möglichen Ergebnisse des Zufallsexperimentes beinhaltet, ist das Ereignis $A = \Omega$ offensichtlich ein sicheres Ereignis (d.h., andere Ergebnisse können nicht auftreten).

Beispiel 1.11 (Würfel, vgl. Bsp. 1.2c)

Das Werfen einer Augenzahl von 1 bis 6 ist offensichtlich ein sicheres Ereignis, also $\Omega = \{1, 2, 3, 4, 5, 6\}$.

Das Ereignis “Werfen der Augenzahl 7” ist hingegen ein unmögliches Ereignis.

- ➡ Ereignisse können offensichtlich als *Mengen* dargestellt werden
- ➡ Verknüpfung von Ereignissen erfolgt durch die Operationen der Mengenlehre:

Definition 1.12 (Summe von Ereignissen)

Tritt ein Ereignis C genau dann ein, wenn mindestens eines der Ereignisse A und B eintritt, dann wird C als *Summe der Ereignisse* (auch Vereinigungsergebnis) von A und B bezeichnet. C kann daher als die Mengen-Vereinigung von A und B interpretiert werden und wird durch $C = A \cup B$ symbolisiert:

$$A \cup B = \{\omega \in \Omega \mid \omega \in A \text{ oder } \omega \in B\} \quad (1.2)$$

Definition 1.13 (Produkt von Ereignissen)

Tritt ein Ereignis C genau dann ein, wenn sowohl Ereignisse A als auch B eintritt, dann wird C als *Produkt der Ereignisse* (auch Schnittergebnis) von A und B bezeichnet. C kann daher als der Mengen-Durchschnitt von A und B interpretiert werden und wird durch $C = A \cap B$ symbolisiert:

$$A \cap B = \{\omega \in \Omega \mid \omega \in A \text{ und } \omega \in B\} \quad (1.3)$$

Definition 1.14 (Differenz von Ereignissen)

Tritt ein Ereignis C genau dann ein, wenn ein Ereignisse A , jedoch *nicht* B eintritt, dann wird C als *Differenz der Ereignisse* von A und B bezeichnet. C kann daher als die Mengen-Differenz von A und B interpretiert werden und wird durch $C = A \setminus B$ symbolisiert:

$$A \setminus B = \{\omega \in \Omega \mid \omega \in A \text{ und } \omega \notin B\} \quad (1.4)$$

Definition 1.15 (Komplementäres Ereignis)

Wenn bei einem Zufallsversuch das Ereignis A *nicht* eintritt, tritt immer das *komplementäre Ereignis* $\bar{A}$ (auch als A^c symbolisiert) ein, also

$$\bar{A} = \{\omega \in \Omega \mid \omega \notin A\} = \Omega \setminus A \quad (1.5)$$

Definition 1.16 (disjunkte Ereignisse)

Ereignisse A und B sind *disjunkt*, also *sich gegenseitig ausschließend* (*unvereinbar*), wenn ihr gleichzeitiges Eintreten unmöglich ist, also

$$A \cap B = \emptyset \quad (1.6)$$

Definition 1.17 (Teilereignis)

Ereignisse A heißt *Teilereignis* von B wenn

$$A \subseteq B. \quad (1.7)$$

Das heißt, daß Ereignis A zieht das Ereignis B nach sich.

Anmerkung 1.18

Da Ereignisse durch Mengen dargestellt werden können, gelten die gleichen Verknüpfungsregeln wie bei den Mengenoperationen.

Theorem 1.19

Für Ereignisse $A, B, C \in \Omega$ gilt:

$$A \cap \emptyset = \emptyset \quad (1.8)$$

$$A \cap \Omega = A \quad (1.9)$$

$$A \cup \emptyset = A \quad (1.10)$$

$$A \cup \Omega = \Omega \quad (1.11)$$

$$A \cap A = A \quad (1.12)$$

$$A \cup A = A \quad (1.13)$$

Theorem 1.19 (Fortsetzung)*Kommutativität*

$$A \cap B = B \cap A \quad (1.14)$$

$$A \cup B = B \cup A \quad (1.15)$$

Assoziativität

$$A \cap (B \cap C) = (A \cap B) \cap C \quad (1.16)$$

$$A \cup (B \cup C) = (A \cup B) \cup C \quad (1.17)$$

Distributivität

$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C) \quad (1.18)$$

$$A \cup (B \cap C) = (A \cup B) \cap (A \cup C) \quad (1.19)$$

Absorption

$$A \cap (A \cup B) = A \quad (1.20)$$

$$A \cup (A \cap B) = A \quad (1.21)$$

De Morgansche Gesetze

$$\overline{A \cap B} = \bar{A} \cup \bar{B} \quad (1.22)$$

$$\overline{A \cup B} = \bar{A} \cap \bar{B} \quad (1.23)$$

unmögliches Ereignis

$$A \cap \bar{A} = \emptyset \quad (1.24)$$

sicheres Ereignis

$$A \cup \bar{A} = \Omega \quad (1.25)$$

Um Wahrscheinlichkeitsrechnung auf den Ereignissen betreiben zu können, sind gewisse Forderungen an das System der Ereignisse zu stellen. Das führt uns zu dem Begriff des Ereignisfeldes

Definition 1.20 (Ereignisfeld)

Enthält ein System von Ereignissen eines zufälligen Versuches alle relevanten Ereignisse und führt die Anwendung der Operationen, Gln. (1.2)–(1.5), *immer* zu einem Ereignis, das wieder zu dem System gehört, so ist das System ein *Ereignisfeld* (auch Ereignisraum) und wird mit $\mathfrak{E}$ bezeichnet.

Beispiel 1.21 (Würfel, vgl. Bsp. 1.2c)

*Ein mögliches Ereignisfeld ist $\mathfrak{E} = \{\emptyset, A, B, \Omega\}$
mit $A = \{1, 3, 5\}$, $B = \{2, 4, 6\}$ und $\Omega = \{1, 2, 3, 4, 5, 6\}$.*

Die Definition 1.20 definiert ein Mengensystem.
Läßt man bei den Mengenoperationen auch abzählbar (unendlich) viele Operationen zu, erhält man die Definition einer σ -Algebra:



Definition 1.22 (σ -Algebra)

Ein Mengensystem $\mathfrak{A}$ von Teilmengen $A_i \subseteq \Omega$ wird *σ -Algebra* genannt wenn

- ❶ $\Omega \in \mathfrak{A}$,
- ❷ wenn $A_i \in \mathfrak{A}$ dann ist $\overline{A_i} \in \mathfrak{A}$,
- ❸ wenn $A_i \in \mathfrak{A}$ dann ist $\bigcup_{i \in \mathbb{N}} A_i \in \mathfrak{A}$.

Die σ -Algebra ist also ein Mengensystem auf einer festen Grundmenge, das die Grundmenge enthält und bezüglich der Komplementbildung und abzählbarer Vereinigungen abgeschlossen ist.

Anmerkungen 1.23

- ❶ *kleinste σ -Algebra auf Grundmenge Ω ist: $\mathfrak{A} = \{\emptyset, \Omega\}$*
- ❷ *größte σ -Algebra auf Grundmenge Ω ist: $\mathfrak{P}(\Omega)$ (Potenzmenge von Ω)*
- ❸ *für jede Teilmenge $A \subseteq \Omega$ ist $\mathfrak{A} = \{\emptyset, A, \overline{A}, \Omega\}$ die kleinste σ -Algebra, die A enthält.*



Beispiel 1.24 (Borelsche σ -Algebra auf $\mathbb{R}$)

Nicht jedes Teilmengensystem aus der Potenzmenge $\mathfrak{P}(\mathbb{R})$ der reellen Zahlen ist als Mengensystem für die Wahrscheinlichkeitsrechnung geeignet (und auch nicht $\mathfrak{P}(\mathbb{R})$ selbst). Die Borelsche σ -Algebra erfüllt jedoch die Bedingungen.

Eine mögliche Definition lautet:

Sei $\Omega = \mathbb{R}$ und $\mathfrak{I} = \{(a, b] | a, b \in \mathbb{R}, a < b\}$, (das ist die Menge aller linksseitig halboffenen Intervalle aus $\mathbb{R}$), dann ist

$\mathfrak{B} = \{A | A \text{ ist Vereinigung von höchstens abzählbar vielen Mengen aus } \mathfrak{I}\}$ eine Borelsche σ -Algebra.

Beispiel 1.25 (σ -Algebra bei Münzwurf, vgl. Bsp. 1.2a)

Hier bietet sich die Potenzmenge an: $\Sigma = \{\emptyset, \{Z\}, \{W\}, \{Z, W\}\}$

Wir haben jetzt die Struktur entwickelt, die es uns erlaubt, axiomatisch Wahrscheinlichkeiten einzuführen: den **Meßraum** (Ω, Σ) , bestehend aus dem Grundraum Ω und dem Ereignisfeld (σ -Algebra) Σ .

Nun kann man den Ereignissen Wahrscheinlichkeiten zuordnen.



Definition 1.26 (Wahrscheinlichkeitsmaß-Axiome (A. N. KOLMOGOROV))

Gegeben sei die Grundmenge Ω und ein Ereignisfeld Σ (σ -Algebra), dann wird jedem Ereignis $A \in \Sigma$ eine reelle Zahl P zugeordnet, die **Wahrscheinlichkeit** des Ereignisses A . Das Wahrscheinlichkeitsmaß hat dabei den folgenden Axiomen zu genügen:

❶ für jedes Ereignis A gilt: $0 \leq P(A) \leq 1$, (1.26)

❷ es gilt: $P(\Omega) = 1$, (1.27)

❸ schließen sich Ereignisse $A_i, A_j \in \Sigma$ mit $i \neq j$ paarweise aus (disjunkte Ereignisse), also $A_i \cap A_j = \emptyset$, dann gilt:

$$P(A_i \cup A_j) = P(A_i) + P(A_j) \quad (1.28)$$

Das Tripel (Ω, Σ, P) heißt **Wahrscheinlichkeitsraum**.

Anmerkung 1.27

Definition 1.26 gibt keine Auskunft darüber, wie die Wahrscheinlichkeiten der Elementarereignisse von Ω bestimmt werden können.

Theorem 1.28 (Grundlegende Rechenregeln für Wahrscheinlichkeiten)

Gegeben sei der Wahrscheinlichkeitsraum (Ω, Σ, P) und zwei Ereignisse

$$A, B \in \Sigma, \text{ es gilt } P(\emptyset) = 0, \quad (1.29)$$

$$P(\bar{A}) = 1 - P(A), \quad (1.30)$$

$$A \subseteq B \Rightarrow P(A) \leq P(B), \quad (1.31)$$

$$P(A \cup B) = P(A) + P(B) - P(A \cap B). \quad (1.32)$$

Beweis für Gl. (1.32).

Aufgrund von (1.28) gelten wegen der Disjunktivität der gewählten

$$\text{Zerlegung: } P(A \cup B) = P(A \setminus B) + P(A \cap B) + P(B \setminus A)$$

$$P(A) = P(A \setminus B) + P(A \cap B)$$

$$P(B) = P(A \cap B) + P(B \setminus A)$$

Zieht man die beiden letzten Gleichungen von der ersten ab, erhält man

$$P(A \cup B) - P(A) - P(B) = -P(A \cap B)$$

und nach der Addition von $P(A)$ und $P(B)$ folgt (1.32). □

Definition 1.29 (Stochastische Unabhängigkeit von Ereignissen)

Gegeben sei der Wahrscheinlichkeitsraum (Ω, Σ, P) . Zwei Ereignisse $A, B \in \Sigma$ heißen *stochastisch unabhängig*, wenn

$$P(A \cap B) = P(A)P(B) \quad (1.33)$$

gilt.

Beispiel 1.30 (Zweifacher Münzwurf, vgl. Bsp. 1.2b)

Das Ereignis A_i stehe für “Auftreten der Zahl im i -ten Wurf ($i = 1, 2$), also $A_1 = \{ZW, ZZ\} \in \Sigma$ und $A_2 = \{ZZ, WZ\} \in \Sigma$.


Wie groß ist P für das Ereignis B = “Zahl in beiden Würfeln” also $B = \{ZZ\}$? Offensichtlich ist $B = A_1 \cap A_2 = \{ZZ\}$. Anschaulich ist klar, daß $P(A_i) = \frac{1}{2}$. Da anzunehmen ist, daß der Ausgang eines Münzwurfs den des anderen nicht beeinflusst, gilt (1.33), also

$$P(B) = P(A_1 \cap A_2) = P(A_1)P(A_2) = \frac{1}{2} \frac{1}{2} = \frac{1}{4}. \quad (1.34)$$

Anwendung in der Zuverlässigkeitstheorie

Eine wichtige Anwendung der Wahrscheinlichkeitsrechnung betrifft die Abschätzung der Zuverlässigkeit von Systemen, z.B. Computersteuerung eines automatisches Bahnsystems, RAID-Systeme¹, Internet-Verbindung.

- Systeme S sind aus Teilsystemen $S_1, \dots, S_n$ zusammengesetzt.
- Im einfachsten Fall ist für das Funktionieren des Gesamtsystems S die Funktion aller Teilsysteme erforderlich. Das entspricht einer **“Reihenschaltung” der Teilsysteme:**



und das Ereignis S = “das Gesamtsystem funktioniert” entspricht dem Schnitt der Teilsysteme S_i = “das Teilsystem i funktioniert”


$$S = \bigcap_{i=1}^n S_i \quad \Longrightarrow \quad P(S) = \prod_{i=1}^n P(S_i), \quad (1.35)$$

wobei die *stochastische Unabhängigkeit* aller S_i angenommen wurde.

¹RAID – redundant array of independent [ursprünglich: inexpensive] disks



- In sicherheitskritischen Anwendungen können Teilsysteme S_i auch *redundant* verschaltet werden, d.h., das System fällt nur aus, wenn *alle* Teilsysteme ausfallen. Das entspricht einer **“Parallelschaltung”** der Teilsysteme:



Das Ereignis S = “das Gesamtsystem funktioniert” entspricht der Vereinigung der Teilsysteme S_i = “das Teilsystem i funktioniert”

$$P(S) = P(S_1 \cup S_2 \cup \dots \cup S_n) \quad (1.36)$$


☞ Zur Auswertung von (1.36) kommt (1.32) (rekursiv) zur Anwendung.

- Kompliziertere Systeme lassen sich häufig schrittweise auf Reihen- und Parallelschaltungen reduzieren (siehe Beispiel 1.31, nächste Seite).
- Darüber hinaus gibt es weitere Methoden zur Erhöhung der Systemzuverlässigkeit, wie **Mehrheitsentscheidungen (majority voting)**, die eines u.U. anderen Analysezugangs bedürfen (siehe Beispiel 1.32).




Beispiel 1.31 (Schritt-für-Schritt-Lösung eines Zuverlässigkeitsproblems)

Gegeben sei das nebenstehende System S mit fünf stochastisch unabhängigen Komponenten und den Zuverlässigkeitswahrscheinlichkeiten $P(A) = p_a, \dots, P(E) = p_e$. Man berechne die Zuverlässigkeit des Gesamtsystems.



Lösung: Zunächst werden folgende Komponenten zusammengefaßt
 $A \cap B =: G$ und $D \cup E =: F$, dann $C \cap F =: H$, und schließlich $S = G \cup H$



$$P(G) = p_a p_b$$

$$P(F) = p_d + p_e - p_d p_e$$

$$P(H) = p_c P(F) = p_c (p_d + p_e - p_d p_e)$$

$$P(S) = P(G) + P(H) - P(G)P(H) = p_a p_b + p_c (1 - p_a p_b) (p_d + p_e - p_d p_e)$$

Beispiel 1.32 (Zuverlässigkeitsteigerung durch Mehrheitsentscheidung)

In “missionskritischen” Anwendungen oder bei Forderung nach sehr hoher Entscheidungssicherheit verwendet man mehrere unabhängige Informationsquellen, Algorithmen, etc., um eine Entscheidung zu treffen. So werden z.B. beim fly-by-wire 3 verschiedene Auswertungen der Sensoren an Stelle von einer verwendet, um die Motoren der Landeklappen zu steuern.

Geht es bspw. um eine JA/NEIN Entscheidung, können 3 unabhängige Sensoren verwendet werden und eine Mehrheitsentscheidung getroffen.

Wie zuverlässig ist die Mehrheitsentscheidung M , wenn die Wahrscheinlichkeiten der einzelnen Sensoren

$P(\text{“Sensor } S_i \text{ liefert die korrekte Information”}) = p_i$ ist?

$$\begin{aligned} M &= (S_1 \cap S_2 \cap \bar{S}_3) \cup (S_1 \cap S_3 \cap \bar{S}_2) \cup (S_3 \cap S_2 \cap \bar{S}_1) \cup (S_1 \cap S_2 \cap S_3) \\ P(M) &= p_1 p_2 (1 - p_3) + p_1 p_3 (1 - p_2) + p_3 p_2 (1 - p_1) + p_1 p_2 p_3 \\ &= p_1 p_2 + p_1 p_3 + p_2 p_3 - 2 p_1 p_2 p_3 \end{aligned} \quad (1.37)$$

Falls für alle $p_i = p$ gilt, folgt $P(M) = p^2(3 - 2p)$.

Wahrscheinlichkeit – LAPLACESche Wahrscheinlichkeiten

Gemäß Anmerkung 1.27 gibt uns die Struktur (Ω, Σ, P) des Wahrscheinlichkeitsraums *keine* Auskunft darüber, wie sich die Werte der Wahrscheinlichkeiten der Elementarereignisse ergeben. Diese müssen “irgendwie” beschafft werden. Hierzu gibt es prinzipiell die folgenden Zugänge:

❶ Symmetrieprinzipien:

z.B. physikalische Argumente für Gleichwahrscheinlichkeit von Elementarereignissen (physikalisch/geometrische Struktur des Würfels, der Münze, etc., Symmetrie des Phasen- oder Konfigurationsraums)

❷ Statistik (frequentistischer Wahrscheinlichkeitsbegriff):

das Zufallsexperiment wird sehr oft (unter gleichen Bedingungen) wiederholt und die *relative Häufigkeit* der Ereignisse wird gemessen als die Anzahl des gewünschten Ereignisses zur Gesamtanzahl der Experimente

❸ Subjektive Wahrscheinlichkeit:

Schätzung der Wahrscheinlichkeiten durch “Experten”



Definition 1.33 (LAPLACEScher Wahrscheinlichkeitsraum, LAPLACE-Experiment)

Es sei (Ω, Σ, P) ein endlicher Wahrscheinlichkeitsraum mit der nicht-leeren Ergebnismenge $\Omega = \{\omega_i \mid 1 \leq i \leq n > 0\}$. Gilt für alle i , $1 \leq i \leq n$

$$p_i = P(\{\omega_i\}) = \frac{1}{n}, \quad (1.38)$$

dann spricht man von einem **LAPLACESchen Wahrscheinlichkeitsraum** und das Experiment wird als **LAPLACE-Experiment** bezeichnet.

P wird als *diskrete Gleichverteilung* bezeichnet.

Beispiele 1.34

Anschaulich ist klar, daß:

- Münzwurf: $P(W) = P(Z) = \frac{1}{2}$
- zweifacher Münzwurf: $n = |\Omega| = 4 \Rightarrow p_i = \frac{1}{4}$
- Würfel: $P(k) = \frac{1}{6}$ ($k = 1, \dots, 6$ – Augenzahl)
- Zufallsp permutation π_k von n Elementen: $P(\pi_k) = \frac{1}{n!}$

Theorem 1.35

Gegeben sei der Laplacesche Wahrscheinlichkeitsraum (Ω, Σ, P) , dann gilt für beliebige Teilmengen $A \in \Sigma$

$$P(A) = \frac{|A|}{|\Omega|} \quad (1.39)$$

Anmerkung 1.36 (Klassische Definition der Wahrscheinlichkeit)

Die Aussage von Theorem 1.35 bedeutet anschaulich das Verhältnis der Anzahl k der für Ereignis A “günstigen Fälle” zur Gesamtanzahl n der überhaupt “möglichen Fälle”

$$P(A) = \frac{k}{n} = \frac{\text{Anzahl der für } A \text{ günstigen Fälle}}{\text{Anzahl der möglichen Fälle}}. \quad (1.40)$$

(1.40) wird als **klassische Definition der Wahrscheinlichkeit** bezeichnet.

Beispiele 1.37 (Würfelexperimente)

- $P(\text{“gerade Augenzahl”}) = P(\{2, 4, 6\}) = \frac{|\{2,4,6\}|}{|\{1,2,3,4,5,6\}|} = \frac{3}{6} = \frac{1}{2}$
- $P(\text{“Augenzahl kleiner als 5”}) = P(\{1, 2, 3, 4\}) = \frac{|\{1,2,3,4\}|}{|\{1,2,3,4,5,6\}|} = \frac{4}{6} = \frac{2}{3}$

Beispiel 1.38 (Welche Augensumme ist beim 3-maligen Würfeln wahrscheinlicher, 11 oder 12?)

❶ Grundraum $\Omega = \{\omega = (w_1, w_2, w_3) | w_i \in \{1, \dots, 6\}, i \in \{1, 2, 3\}\}$

❷ Damit folgt: $|\Omega| = 6 \times 6 \times 6 = 6^3 = 216$

❸ Bestimmung der günstigen Fälle für die Ereignisse

$A = \{\omega \in \Omega | w_1 + w_2 + w_3 = 11\}$ und $B = \{\omega \in \Omega | w_1 + w_2 + w_3 = 12\}$

$A : \sum w_i = 11$	# Fälle
6 4 1	3!
6 3 2	3!
5 5 1	3
5 4 2	3!
5 3 3	3
4 4 3	3
$ A =$	27

$B : \sum w_i = 12$	# Fälle
6 5 1	3!
6 4 2	3!
6 3 3	3
5 5 2	3
5 4 3	3!
4 4 4	1
$ B =$	25

❹ Damit folgt: $P(A) = \frac{|A|}{|\Omega|} = \frac{27}{216}$ und $P(B) = \frac{|B|}{|\Omega|} = \frac{25}{216}$ und $P(A) > P(B)$.

Urnen-Modelle und Kombinatorik

Die Auswahl von Objekten aus einer Urne bildet die Grundlage für viele Modelle. Mittels der Kombinatorik kann dann die Anzahl der günstigen Fälle berechnet werden. Die Formeln der Kombinatorik werden als bekannt vorausgesetzt und hier nur zusammengefaßt.

Es sei n Gesamtzahl der Objekte in der Urne, k die Anzahl der zu ziehenden Objekte und l_j die Anzahl der Objekte der Gruppe j , wobei $\sum_{j=1}^k l_j = n$.

	Permutation	Variation (Reihenfolge zählt: $\{a, b\} \neq \{b, a\}$)	Kombination (Reihenfolge zählt nicht $\{a, b\} = \{b, a\}$)
ohne Zurücklegen	$n! = \prod_{k=1}^n k$	$P(n, k) = \frac{n!}{(n-k)!} = n \cdot (n-1) \cdot \dots \cdot (n-k+1)$	$C(n, k) = \frac{n!}{k!(n-k)!} = \binom{n}{k} = \frac{n(n-1) \dots (n-k+1)}{1 \cdot 2 \cdot \dots \cdot k}$
mit Zurücklegen	$\frac{n!}{l_1! l_2! \dots l_k!}$	n^k	$C_r(n, k) = \frac{(n+k-1)!}{k!(n-1)!} = \binom{n+k-1}{k}$



Beispiel 1.39 (Wahrscheinlichkeit für einen Sechser bei 6 aus 45)

Es werden 6 Zahlen aus einer Menge von 45 gezogen. Es wird nicht zurückgelegt. Die Reihenfolge, wie die Zahlen gezogen werden, zählt nicht. Die Anzahl der möglichen Ausgänge der Lotterie ist daher
 $|\Omega| = C(n, k) = C(45, 6) = 8145060$. *Da jeder Ausgang als gleichwahrscheinlich angenommen werden kann, ergibt sich für einen konkreten Tip T damit die Wahrscheinlichkeit*

$$P(\text{"}T\text{ wird ausgelost"}) = \frac{|T|}{|\Omega|} = \frac{1}{C(n, k)} \approx 1.22774 \cdot 10^{-7}$$

Frage: Wie groß ist aber die Wahrscheinlichkeit, einen 3-er zu haben, oder allgemein einen " r -er"?

Antwort: Für gegebenes $r = 3$ setze $R = 6$, $G = 45 - 6$, $n = 6$ in (1.41),

$$\text{es folgt } P(\text{"3-er"}) = \frac{\binom{6}{3} \cdot \binom{39}{3}}{\binom{45}{6}} = \frac{20 \cdot 9139}{8145060} \approx 0.02244$$



Beispiel 1.40 (Urnenschema der Qualitätskontrolle)

In einer Urne befinden sich R rote und G grüne Kugeln. Es werden n Kugeln zufällig aus der Urne gezogen. Wie groß ist die Wahrscheinlichkeit für das Ereignis X , genau r rote Kugeln in der Probe zu finden, also

$P(X = r) = P(\text{“Es werden genau } r \text{ rote Kugeln gezogen”})?$

- ❶ Es kommt (1.40) zur Anwendung.
- ❷ Anzahl der möglichen Fälle ist gleich Auswahl von n Objekten aus $R + G$ Objekten (ohne Zurücklegen, Reihenfolge irrelevant) $|\Omega| = \binom{R+G}{n}$
- ❸ Anzahl der günstigen Fälle: r Kugeln werden aus R ausgewählt und $n - r$ Kugeln aus G . Da die r roten Kugeln mit den $n - r$ grünen Kugeln beliebig kombiniert werden können, gibt es $\binom{R}{r} \cdot \binom{G}{n-r}$ günstige Konstellationen.
- ❹ Gl. (1.40) liefert damit

$$P(X = r) = \frac{\binom{R}{r} \cdot \binom{G}{n-r}}{\binom{R+G}{n}}. \quad (1.41)$$

Bedingte Wahrscheinlichkeiten

Motivation

- ➊ Unter der Bedingung, daß man gute Schulleistungen in Mathematik hatte, wie groß ist die Wahrscheinlichkeit für ein erfolgreiches Elektrotechnikstudium?
- ➋ Sie erhalten die Information, daß beim Würfeln eine ungerade Zahl geworfen wurde.
 - ▶ Wie groß ist die Wahrscheinlichkeit für eine 3?
 - ▶ Wie groß ist die Wahrscheinlichkeit für eine 2?

Definition 1.41 (Bedingte (auch konditionale) Wahrscheinlichkeit)

Gegeben sei ein Wahrscheinlichkeitsraum (Ω, Σ, P) und die Ereignisse $A, B \in \Sigma$ mit $P(A) > 0$. Dann wird

$$P(B|A) = \frac{P(A \cap B)}{P(A)} \quad (1.42)$$

als *bedingte Wahrscheinlichkeit* des Ereignisses B unter der Bedingung des Ereignisses A bezeichnet.

Beispiel 1.42 (Problem 2 von Motivation (S. 31))

$$\textcircled{1} \quad P(\{3\}|\{1, 3, 5\}) = \frac{P(\{1,3,5\} \cap \{3\})}{P(\{1,3,5\})} = \frac{P(\{3\})}{P(\{1,3,5\})} = \frac{1/6}{1/2} = \frac{1}{3}$$

$$\textcircled{2} \quad P(\{2\}|\{1, 3, 5\}) = \frac{P(\{1,3,5\} \cap \{2\})}{P(\{1,3,5\})} = \frac{P(\emptyset)}{P(\{1,3,5\})} = \frac{0}{1/2} = 0$$

Beispiel 1.43

Wie groß ist die Wahrscheinlichkeit, daß bei zweimaligem Würfeln die Augensumme 6 auftritt, wenn wenigstens einmal eine 2 gewürfelt wurde?

Ereignis A : “Augensumme = 6”, B : “wenigstens eine 2 wurde geworfen”

$$A = \{(1, 5), (2, 4), (3, 3), (4, 2), (5, 1)\}$$

$$B = \{(2, 1), (2, 2), (2, 3), (2, 4), (2, 5), (2, 6), (1, 2), (3, 2), (4, 2), (5, 2), (6, 2)\}$$

$$\Rightarrow A \cap B = \{(2, 4), (4, 2)\}$$

$$\Rightarrow P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{2/36}{11/36} = \frac{2}{11}$$

Theorem 1.44 (Multiplikationsregel für Wahrscheinlichkeiten)

Gegeben sei ein Wahrscheinlichkeitsraum (Ω, Σ, P) und die Ereignisse $A, B \in \Sigma$ mit $P(A) > 0$ und $P(B) > 0$. Dann gilt

$$P(A \cap B) = P(B|A)P(A) = P(A|B)P(B). \quad (1.43)$$

Die Multiplikationsregel von Satz 1.44 kann verallgemeinert werden von $P(A \cap B)$ auf $P(A \cap B \cap C)$ durch schrittweise Substitution:

$$P(A \cap B \cap C) = P(A|B \cap C)P(B \cap C) = P(A|B \cap C)P(B|C)P(C) \quad (1.44)$$

... und noch allgemeiner:

$$P\left(\bigcap_{i=1}^n A_i\right) = P(A_n) \prod_{j=1}^{n-1} P\left(A_j \mid \bigcap_{k=j+1}^n A_k\right) \quad (1.45)$$

Diese Formel wird als **BAYESSche Faktorisierung** oder als Kettenregel der Wahrscheinlichkeitsrechnung bezeichnet. Gleichung (1.45) wird verwendet bei der Modellierung von Daten (im data mining) mittels *probabilistischer graphischer Modelle*, Stichwort: *Bayessche Netzwerke*.



Theorem 1.45 (Satz von der totalen Wahrscheinlichkeit)

Gegeben sei ein Wahrscheinlichkeitsraum (Ω, Σ, P) und ein System von Ereignissen $B_i \in \Sigma$ mit den Eigenschaften

- ❶ paarweiser Disjunktivität, d.h. $\forall i \neq j : B_i \cap B_j = \emptyset$,
- ❷ Vollständigkeit, d.h. $\bigcup_{i=1}^n B_i = \Omega$,
- ❸ und $\forall i : P(B_i) > 0$,

dann gilt für beliebige $A \in \Sigma$:
$$P(A) = \sum_{i=1}^n P(A|B_i)P(B_i). \quad (1.46)$$

Beweis für Gl. (1.46).

- a) Wegen ❷ und (1.18) gilt: $P(A) = P(A \cap (\bigcup_{i=1}^n B_i)) = P(\bigcup_{i=1}^n (A \cap B_i))$.
- b) Wegen ❶ und (1.28) gilt: $P(\bigcup_{i=1}^n (A \cap B_i)) = \sum_{i=1}^n P(A \cap B_i)$.
- c) Anwendung vom Satz 1.44 liefert schließlich
$$P(A) = \sum_{i=1}^n P(A|B_i)P(B_i).$$

**Anmerkung 1.46 (Partitionierung des Grundraumes Ω)**

Die im Theorem 1.45 verwendete Zerlegung des Grundraumes mit den Eigenschaften ❶ – ❸ wird auch als **Partition** von Ω bezeichnet.

Theorem 1.47 (Formel von BAYES)

Gegeben sei ein Wahrscheinlichkeitsraum (Ω, Σ, P) und ein System von Ereignissen $B_i \in \Sigma$ mit den Eigenschaften

- ➊ paarweiser Disjunktivität, d.h. $\forall i \neq j : B_i \cap B_j = \emptyset$,
- ➋ Vollständigkeit, d.h. $\bigcup_{i=1}^n B_i = \Omega$,
- ➌ und $\forall i : P(B_i) > 0$,

dann gilt für beliebige $A \in \Sigma$ mit $P(A) > 0$ und beliebige $k \in \{1, \dots, n\}$:

$$P(B_k|A) = \frac{P(A|B_k)P(B_k)}{\sum_{i=1}^n P(A|B_i)P(B_i)}. \quad (1.47)$$

Beweis der BAYESSchen Formel (1.47).

a) Aus (1.43) folgt

$$P(B_k|A) = \frac{P(A|B_k)P(B_k)}{P(A)} \quad (1.48)$$

b) Setzt man nun (1.46) für $P(A)$ ein, folgt sofort (1.47). □

Anmerkungen 1.48 (Interpretation der Bayes-Formel)

- 1 Die $P(B_i)$ in (1.47) werden **a-priori-Wahrscheinlichkeiten** genannt. Diese werden ursächlich als “gegeben” vorausgesetzt.
- 2 Die $P(B_k|A)$ in (1.47) werden **a-posteriori-Wahrscheinlichkeiten** genannt und sind Folge des Bayesschen Schätzprozesses:

a-posteriori-Wahrscheinlichkeit = a-priori-Wahrscheinlichkeit $\times$ Bewertung

- 3 Interpretation: $P(A|B_i)$ vermittelt Ursache-Wirkungs-Zusammenhang, Ursache: B_i , Ergebnis (Wirkung): A .
Das Resultat $P(B_i|A)$ läßt vom Ergebnis A auf Ursache B_i “schließen.”

- ➔ Die Bayes-Formel ist mathematisch korrekt, liefert jedoch **statistische Aussagen**. Man kann daher **nicht** auf einen **kausalen Zusammenhang** schließen.
- 4 Die Bayes-Formel findet häufig Anwendung bei der iterativen Schätzung von Wahrscheinlichkeitsverteilungen.

Beispiel 1.49 (Informationsübertragung bei gestörtem Nachrichtenkanal)

Von einem Sender S werden Wörter (z.B. Bits, Bytes, Bit-Gruppen) aus der Menge $\mathcal{W}$ über einen gestörten Nachrichtenkanal an einen Empfänger E gesendet. Für beliebige Worte $x, y \in \mathcal{W}$ werden die Ereignisse $S_x :=$ “ x wird gesendet” und $E_y :=$ “ y wird empfangen” betrachtet.

Wie groß ist die Wahrscheinlichkeit $P(S_x|E_y)$, daß das empfangene Wort y in Wirklichkeit x war?

Vorausgesetzt, wir kennen die *a-priori*-Wahrscheinlichkeiten für das Auftreten der Worte, die vom Sender kommen, also $P(S_x)$, und die Übertragungsqualität (Bewertung) des Kanals in Form der bedingten Wahrscheinlichkeiten $P(E_y|S_x)$, dann liefert die Bayes-Formel (1.47) unmittelbar:

$$P(S_x|E_y) = \frac{P(E_y|S_x)P(S_x)}{\sum_{z \in \mathcal{W}} P(E_y|S_z)P(S_z)} \quad (1.49)$$



Anwendung: Bayessche Spam-Filterung (Bayes-Klassifizierer)

- Ziel: Emails sollen in Spam S und Ham H klassifiziert werden.
- Idee: Die Emails werden nach Schlüsselworten W_i ($i = 1, \dots, n$) durchsucht. Übersteigt die bedingte Wahrscheinlichkeit $P(S|W_1 \cap \dots \cap W_n)$ einen Schwellwert, wird die Email als Spam klassifiziert.

Annahmen

- 1 Die W_i treten stochastisch unabhängig auf, so daß gilt

$$P(W_1 \cap \dots \cap W_n | S) = P(W_1 | S) \cdot \dots \cdot P(W_n | S) \quad (1.50)$$

$$P(W_1 \cap \dots \cap W_n | H) = P(W_1 | H) \cdot \dots \cdot P(W_n | H) \quad (1.51)$$

Anmerkung: Die $P(W_i | S)$ und $P(W_i | H)$ können durch ihre *relativen Häufigkeiten* geschätzt werden.

- 2 a-priori-Wahrscheinlichkeiten: $P(S) = P(H) = 1/2$
(Annahme nicht zwingend erforderlich, auch $P(S) \neq P(H)$ möglich)



Bestimmung von $P(S|W_1 \cap \dots \cap W_n)$ für $n = 2$

Die Mengen H und S bilden eine Partition, daher kann (1.47) angewandt werden

$$\begin{aligned}
 P(S|W_1 \cap W_2) &\stackrel{(1.47)}{=} \frac{P(W_1 \cap W_2|S)P(S)}{P(W_1 \cap W_2|S)P(S) + P(W_1 \cap W_2|H)P(H)} \\
 &\stackrel{(1.50, 1.51)}{=} \frac{P(W_1|S)P(W_2|S)P(S)}{P(W_1|S)P(W_2|S)P(S) + P(W_1|H)P(W_2|H)P(H)} \\
 &\stackrel{②}{=} \frac{P(W_1|S)P(W_2|S)}{P(W_1|S)P(W_2|S) + P(W_1|H)P(W_2|H)} \quad (1.52)
 \end{aligned}$$

Diese Formel kann verallgemeinert werden auf n Worte:

$$P(S|W_1 \cap \dots \cap W_n) = \frac{P(W_1|S) \cdot \dots \cdot P(W_n|S)}{P(W_1|S) \cdot \dots \cdot P(W_n|S) + P(W_1|H) \cdot \dots \cdot P(W_n|H)} \quad (1.53)$$

Beispiel 1.50

Die Analyse von Emails ergab für die Worte “date” und “sex” die folgenden relativen Häufigkeiten: $P(\text{date}|H) = 0.3$, $P(\text{sex}|H) = 0.01$, $P(\text{date}|S) = 0.35$, $P(\text{sex}|S) = 0.1$. Dann liefert (1.52): $P(S|\text{sex} \cap \text{date}) = 0.035/0.038 \approx 0.92$

Exkurs: Markov-Ketten

Ein für die Technik (Physik, Informatik) wichtiger Teilbereich der Wahrscheinlichkeitsrechnung sind die MARKOVschen Prozesse. Diese dienen als Modelle für zeitdiskrete oder zeitkontinuierliche stochastische Vorgänge.

Homogene Markov-Ketten stellen die einfachste Variante zeitdiskreter stochastischer Prozesse dar: Das stochastische System kann $n = |\Omega|$ verschiedene Zustände (Ergebnisse, Elementarereignisse) $X \in \Omega$ annehmen (z.B. finite-state machine). Diese lassen sich z.B. durch natürliche Zahlen ausdrücken, $i, j \in \mathbb{N}$. Das System befinde sich zum Zeitpunkt t im Zustand $X^{(t)} = i$. Durch den stochastischen Prozeß geht das System zum Zeitpunkt $t + 1$ in den Zustand $X^{(t+1)} = j$ über, und zwar mit der *Übergangswahrscheinlichkeit*

$$p_{ij} = P(X^{(t+1)} = j \mid X^{(t)} = i). \quad (1.54)$$

Die Matrix p_{ij} enthält n^2 bedingte Wahrscheinlichkeiten, die das stochastische Systemverhalten beschreiben.

Es muß offensichtlich gelten:

$$\sum_{j=1}^n p_{ij} = 1. \quad (1.55)$$

Es sei $p_i^{(t)} = P(X^{(t)} = i)$ die Wahrscheinlichkeit, das System im Zustand $X = i$ zu finden. Wie groß ist die Wahrscheinlichkeit $p_j^{(t+1)} = P(X^{(t+1)} = j)$, das System zum Zeitpunkt $t + 1$ im Zustand $X = j$ zu finden?

- ❶ Die Zustände $i, j \in \Omega$ mit $i \neq j$ sind disjunkt und vollständig, sie bilden daher eine Partition und der Satz von der totalen Wahrscheinlichkeit (1.46) kann angewandt werden mit $B_i = \{X = i\}$

$$P(X^{(t+1)} = j) = \sum_{i=1}^n P(X^{(t+1)} = j \mid X^{(t)} = i)P(X^{(t)} = i) \quad (1.56)$$

- ❷ Unter der Verwendung der Symbolik von (1.54) kann man dafür auch schreiben

$$p_j^{(t+1)} = \sum_{i=1}^n p_{ij} p_i^{(t)} \quad (1.57)$$

- ❸ Für den Zeitpunkt $t + 2$ gilt dann unter Verwendung von (1.57)

$$p_k^{(t+2)} = \sum_{j=1}^n p_{jk} p_j^{(t+1)} = \sum_{j=1}^n p_{jk} \sum_{i=1}^n p_{ij} p_i^{(t)} = \sum_{i=1}^n \sum_{j=1}^n p_{ij} p_{jk} p_i^{(t)} \quad (1.58)$$

... wofür wir auch abkürzend schreiben können

$$p_k^{(t+2)} = \sum_{i=1}^n \sum_{j=1}^n p_{ij} p_{jk} p_i^{(t)} =: \sum_{i=1}^n p_{ik}(2) p_i^{(t)} \quad (1.59)$$

- 4 Dies kann auch in Matrix-Vektor-Schreibweise dargestellt werden. Mit $\mathbf{p}^{(t)} := (p_1^{(t)}, \dots, p_n^{(t)})^T$ und $(\mathbf{P})_{ij} = p_{ij}$ erhalten wir für (1.57) und (1.59)

$$\mathbf{p}^{(t+1)T} = \mathbf{p}^{(t)T} \mathbf{P} \quad (1.60)$$

$$\mathbf{p}^{(t+2)T} = \mathbf{p}^{(t)T} \mathbf{P} \mathbf{P} = \mathbf{p}^{(t)T} \mathbf{P}^2 =: \mathbf{p}^{(t)T} \mathbf{P}(2) \quad (1.61)$$

- 5 Induktiv lassen sich so die Wahrscheinlichkeitsvektoren $\mathbf{p}$ für beliebige Zeitschritte herleiten. Beginnt man mit $\mathbf{p}^{(0)T}$, so erhält man schrittweise

$$\mathbf{p}^{(t)T} = \mathbf{p}^{(0)T} \underbrace{\mathbf{P} \cdot \dots \cdot \mathbf{P}}_{t \text{ mal}} = \mathbf{p}^{(0)T} \mathbf{P}^t =: \mathbf{p}^{(0)T} \mathbf{P}(t) \quad (1.62)$$

- 6 Die $\mathbf{P}(\cdot)$ -Matrizen genügen der **CHAPMAN-KOLMOGOROV-Gleichung**

$$\mathbf{P}(t) = \mathbf{P}(s) \mathbf{P}(t-s), \quad \text{also} \quad p_{ij}(t) = \sum_{k=1}^n p_{ik}(s) p_{kj}(t-s). \quad (1.63)$$



Anmerkungen 1.51 (Markov-Ketten)

- Die in (1.62) auftretende “Kette” von multiplikativ verknüpften Übergangsmatrizen bzw. der (zeitliche) Prozeß, der durch diese Wahrscheinlichkeitsmatrizen beschrieben wird, wird **Markov-Kette** genannt.
- Die Übergangsmatrizen sind in (1.62) alle gleich, d.h. die Übergangswahrscheinlichkeiten zwischen den Zuständen verändern sich nicht über die Zeit, derartige Markov-Ketten nennt man **homogen**.
- Ist die Übergangsmatrix jedoch zeitlich veränderlich, spricht man von einer **inhomogenen Markov-Kette**.
- Anwendungsspektrum:
 - ▶ Modelle in der statistischen Thermodynamik, Elektronik
 - ▶ Modellierung von Warteschlangen
 - ▶ Monte-Carlo-Simulationen
 - ▶ Analyse probabilistischer iterativer Algorithmen, z.B. Evolutionäre Algorithmen, Metropolis-Algorithmus (und Simulated Annealing)
 - ▶ Hidden Markov Models (Texterkennung, Textgenerierung, Sequenzerkennungen in der Bioinformatik)
 - ▶ Finanzmarktdynamik, Random-Walk-Modelle

Die einfachste Markov-Kette

- werden nur zwei mögliche Zustände $i = 1, 2$ betrachtet, so erhält man die einfachste Markov-Kette mit der 2×2 Übergangsmatrix


$$P = \begin{pmatrix} 1-r & r \\ s & 1-s \end{pmatrix} \quad (1.64)$$

- mittels vollständiger Induktion zeigt man leicht, daß

$$P(t) = P^t = \frac{1}{r+s} \begin{pmatrix} s & r \\ s & r \end{pmatrix} + \frac{(1-r-s)^t}{r+s} \begin{pmatrix} r & -r \\ -s & s \end{pmatrix} \quad (1.65)$$

Beispiel 1.52 (Wetter als Markov-Prozeß (extrem vereinfacht!))

Es werden die zwei Zustände “Sonne (nschein)” $i = 1$ und “Regen” $i = 2$ betrachtet. Das System wechselt von Sonne zu Regen mit $P = r$ und von Regen zu Sonne mit $P = s$.



Einige Eigenschaften von Markov-Ketten

Gleichung (1.62) beschreibt die Evolution des Wahrscheinlichkeitsvektors $\mathbf{p}$ der Zustände i . Was passiert, wenn $t \rightarrow \infty$?

Definition 1.53 (Stationäre Verteilung einer Markov-Kette)

Der Grenzwert (falls er existiert) $\boldsymbol{\pi} := \lim_{t \rightarrow \infty} \mathbf{p}^{(t)}$ wird *stationäre Verteilung* der Markov-Kette mit der Übergangsmatrix $\mathbf{P}$ genannt.

Beispiel 1.54 (Stationäre Verteilung der Markov-Kette mit 2 Zuständen)

Aus (1.62) und (1.64) folgt mit (1.65) für beliebiges initiales $\mathbf{p}^{(0)}$ unter der Bedingung $r + s < 2$

$$\boldsymbol{\pi}^T = \mathbf{p}^{(0)T} \lim_{t \rightarrow \infty} \mathbf{P}^t = \frac{1}{r+s} \mathbf{p}^{(0)T} \begin{pmatrix} s & r \\ s & r \end{pmatrix} = \left(\frac{s}{r+s}, \frac{r}{r+s} \right) \quad (1.66)$$

Betrachtet man die Matrix $\lim_{t \rightarrow \infty} \mathbf{P}^t$ in (1.66), so erkennt man, daß bereits in jeder Zeile der Vektor $\boldsymbol{\pi}$ der stationären Verteilung auftritt.

Übergangsmatrizen, die diese Eigenschaft haben, werden *ergodisch* genannt:



Definition 1.55 (Ergodizität einer Markov-Kette)

Eine Markov-Kette mit Übergangsmatrix $\mathbf{P} = (p_{ij})$ heißt *ergodisch*, falls für $p_{ij}(t)$ die Grenzwerte

$$\pi_j = \lim_{t \rightarrow \infty} p_{ij}(t) \quad (1.67)$$

- ❶ für jedes $j = 1, \dots, n$ existieren,
- ❷ positiv sind und nicht von i abhängen und
- ❸ $\sum_{j=1}^n \pi_j = 1$ gilt.

Theorem 1.56 (Bestimmung der stationären Verteilung)

Gegeben sei eine ergodische Markov-Kette mit Übergangsmatrix $\mathbf{P} = (p_{ij})$, dann kann die stationäre Verteilung als Grenzwert (1.67) durch das folgende Gleichungssystem bestimmt werden:

$$\pi_j = \sum_{i=1}^n \pi_i p_{ij}, \quad (1.68)$$

$$1 = \sum_{j=1}^n \pi_j \quad (1.69)$$

Anmerkung 1.57 (Nicht jede Markov-Kette ist ergodisch.)

Man betrachte die Markov-Kette Gln. (1.64, 1.65), doch anders als im Beispiel 1.54 jetzt mit $r = s = 1$. Dann folgt unmittelbar aus (1.65)

$$P(t) = \begin{cases} P, & \text{falls } t \text{ ungerade,} \\ I, & \text{falls } t \text{ gerade.} \end{cases} \quad (1.70)$$

Diese Markov-Kette wird **periodisch** genannt. Und es gibt noch andere Arten.

Beispiel 1.58 (Markov-Kette mit absorbierenden Zuständen)

Gibt es ein i , für das die Übergangswahrscheinlichkeit $p_{ii} = 1$, so wird dieser Zustand als **absorbierend** bezeichnet. Hat das System einen derartigen Zustand erreicht, kann es diesen nicht mehr verlassen.

$$P = \begin{pmatrix} 1 & 0 & 0 & 0 \\ \frac{1}{4} & 0 & \frac{3}{4} & 0 \\ 0 & \frac{1}{4} & 0 & \frac{3}{4} \\ 0 & 0 & 0 & 1 \end{pmatrix} \xrightarrow{t \rightarrow \infty} \lim_{t \rightarrow \infty} P(t) = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0.3077 & 0 & 0 & 0.6923 \\ 0.0769 & 0 & 0 & 0.9231 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

Anmerkung 1.59 (zu Beispiel 1.58)

- Die p 's in der 1. und 4. Spalte von $P(t)$ sind die Wahrscheinlichkeiten, mit denen man, beginnend von einem Zustand i , im Zustand $j = 1$ bzw. $j = 4$ für $t \rightarrow \infty$ endet.
- Derartige Markov-Ketten können zur Berechnung von Irrfahrt-Modellen verwendet werden, z.B. Spielerbankrott (engl.: gambler's ruin problem), Diffusions-Kondensations-Vorgänge in der Physik, etc.

Definition des Spieler-Problems (gambler's ruin problem)

- 1 Ein Spieler starte mit einem gewissen Guthaben $X^{(0)} = i$.
- 2 In jedem Zeitschritt gewinnt er eine Einheit, also $X^{(t+1)} = X^{(t)} + 1$ mit Wahrscheinlichkeit p und verliert mit $q = 1 - p$ eine Einheit, also $X^{(t+1)} = X^{(t)} - 1$
- 3 Das Spiel endet entweder, wenn sein Guthaben $X^{(t)} = 0$ ist, oder wenn er einen vorgegebenen Gewinn $X^{(t)} = n$ erreicht hat
- 4 Man berechne die Wahrscheinlichkeit $P_i := P(X^{(\infty)} = n | X^{(0)} = i)$, daß beim Einsatz eines Startguthabens i , der Gewinn n erreicht wird.



Analyse des Spieler-Problems (gambler's ruin problem)

- ❶ Die $(n+1) \times (n+1)$ -Übergangsmatrix enthält offensichtlich nur die folgenden von null verschiedenen Einträge: $p_{00} = p_{nn} = 1$, $p_{i,i+1} = p$ und $p_{i,i-1} = q = 1 - p$ für $i = 1, \dots, n-1$.
- ❷ Die $\mathbf{P}(t)$ -Matrix ergibt sich wegen (1.63) und ❶ als Matrixprodukt $\mathbf{P}(t) = \mathbf{P} \cdot \mathbf{P}(t-1)$, also

$$\begin{aligned}
 \mathbf{P}(t) &= \begin{matrix} \text{[i] } \downarrow \\ \text{[i] } \rightarrow \end{matrix} \begin{pmatrix} 1 & 0 & & \cdots & 0 \\ & \ddots & & & \\ & & \ddots & & \\ \cdots & & q & 0 & p & \cdots \\ & & & \ddots & \\ 0 & \cdots & & & & 1 \end{pmatrix} \cdot \begin{pmatrix} 1 & \cdots & \cdots & 0 \\ & & & p_{1n}(t-1) \\ & & & \vdots \\ \vdots & & \cdots & p_{in}(t-1) \\ & & & \vdots \\ 0 & \cdots & \cdots & 1 \end{pmatrix} \quad (1.71)
 \end{aligned}$$

- ❸ Da wir uns nur für die n -te Spalte von $\mathbf{P}$ interessieren, folgt:

$$p_{in}(t) = q \cdot p_{i-1n}(t-1) + p \cdot p_{i+1n}(t-1) \quad (1.72)$$



- ④ Wie wir in Beispiel 1.58 gesehen haben, gibt es keine ergodische Verteilung π . Sehr wohl aber existiert der Grenzwert von $\lim_{t \rightarrow \infty} P(t)$. Für $t \rightarrow \infty$ gilt somit $p_{ij}(t) = p_{ij}(t-1)$ und speziell für $j = n$: $p_{in}(t) = p_{in}(t-1) = P_i$. Damit folgt aus (1.72) das **Gleichungssystem**

$$P_i = q \cdot P_{i-1} + p \cdot P_{i+1}, \quad i = 1, \dots, n-1, \quad P_0 = 0, P_n = 1. \quad (1.73)$$

- ⑤ Das lineare System (1.73) wird schrittweise gelöst (NB: $1 = q + p$):

$$qP_i + pP_i = qP_{i-1} + pP_{i+1}, \quad i = 1, \dots, n-1 \quad (1.74)$$

$$\begin{aligned} \Rightarrow P_{i+1} - P_i &= \frac{q}{p}(P_i - P_{i-1}) \\ &= \left(\frac{q}{p}\right)^2 (P_{i-1} - P_{i-2}) \\ &\vdots \\ &= \left(\frac{q}{p}\right)^i (P_1 - P_0) \stackrel{(1.73)}{=} \left(\frac{q}{p}\right)^i P_1 \quad (1.75) \end{aligned}$$

- ⑥ Schrittweise Rücksubstitution liefert mit (1.75)

$$\begin{aligned}
 P_2 &= P_1 + \frac{q}{p}P_1 = \left[1 + \frac{q}{p}\right] P_1 \\
 P_3 &= P_2 + \left(\frac{q}{p}\right)^2 P_1 = \left[1 + \frac{q}{p} + \left(\frac{q}{p}\right)^2\right] P_1 \\
 &\vdots \\
 P_i &= \left[1 + \frac{q}{p} + \left(\frac{q}{p}\right)^2 + \dots + \left(\frac{q}{p}\right)^{i-1}\right] P_1 \quad (1.76)
 \end{aligned}$$

- ⑦ Anwendung der geometrischen Reihenformel $\sum_{k=0}^{i-1} d^k = \frac{1-d^i}{1-d}$ (für $d \neq 1$) liefert

$$P_i = \begin{cases} \frac{1-(q/p)^i}{1-q/p} P_1, & \text{für } q \neq p \\ iP_1, & \text{für } q = p \end{cases} \quad (1.77)$$



- 8 Es verbleibt die Bestimmung von P_1 . Mit $P_n = 1$ in (1.77) folgt

$$P_1 = \begin{cases} \frac{1-q/p}{1-(q/p)^n}, & \text{für } p \neq q \\ \frac{1}{n}, & \text{für } p = q \end{cases} \quad (1.78)$$

- 9 Setzt man (1.78) in (1.77) folgt schließlich

$$P_i = \begin{cases} \frac{1-\left(\frac{1-p}{p}\right)^i}{1-\left(\frac{1-p}{p}\right)^n}, & \text{für } p \neq \frac{1}{2} \\ \frac{i}{n}, & \text{für } p = \frac{1}{2} \end{cases} \quad (1.79)$$

Anmerkungen 1.60

- *Bemerkenswert: bei einem “fairen” Spiel mit $p = q = 1/2$ und unbegrenzter Bank ($n \rightarrow \infty$) verliert der Spieler immer (gambler’s ruin).*
- *Die P_i ergaben sich aus der Lösung des Gleichungssystems (1.73). Umgekehrt kann man Irrfahrten zur approximativen Lösung von derartigen Systemen verwenden.*
*Derartige Lösungsverfahren werden **Monte-Carlo-Verfahren** genannt.*

Monte-Carlo Simulation der Laplaceschen Differentialgleichung

Betrachtet man das Gleichungssystem (1.73) für den Fall $p = q = 1/2$, so fällt auf, daß man dafür auch

$$P_{i+1} - 2P_i + P_{i-1} = 0 \quad (1.80)$$

schreiben kann. Die linke Seite von (1.80) ist aber auch formal äquivalent zum Differenzenschema der zweiten Ableitung einer Funktion $\varphi(x)$, wie eine Taylor-Entwicklung zeigt

$$\varphi(x+h) - 2\varphi(x) + \varphi(x-h) = \frac{d^2\varphi}{dx^2}h^2 + O(h^4). \quad (1.81)$$

Damit kann (1.80) als Diskretisierung der eindimensionalen *Laplace-Gleichung vom Dirichlet-Typ (Randwertproblem, RWP)* interpretiert werden

$$\frac{d^2\varphi}{dx^2} = 0, \quad \varphi(0) = 0, \quad \varphi(n) = 1 \quad (1.82)$$


deren Lösung durch die zweite Zeile in (1.79) gegeben ist.



Im Folgenden erfolgt die Entwicklung des Monte-Carlo-Verfahrens zur Lösung des 2-dimensionalen RWP (Übergang zu 3D ist dann trivial)

$$\Delta\varphi(x,y) = \frac{\partial^2\varphi}{\partial x^2} + \frac{\partial^2\varphi}{\partial y^2} = 0, \quad (x,y)^T \in A \subset \mathbb{R}^2, \quad \varphi(x,y)|_{\partial A} = u(x,y) \quad (1.83)$$

wobei ∂A der Rand des Gebietes ist und $u(x,y)$ das Potential auf dem Rand.



- ❶ zur numerischen Behandlung von (1.83) erfolgt eine Diskretisierung mit Gitterweite h (siehe (1.84), nächste Folie)
- ❷ die inneren Gitterpunkte werden durch die Indizes (i,j) etc. gekennzeichnet
- ❸ der Einfachheit halber werde angenommen, daß der Rand ∂A durch Gitterpunkte $\vec{R}_k = (x,y)^T$ abgedeckt ist
- ❹ es gelte $\varphi(\vec{R}_k) = u_k$, vgl. (1.83)



- 5 Diskretisierung von (1.83) auf einem Gitternetz liefert in Verallgemeinerung von (1.81)

$$\varphi(x, y) = \frac{1}{4} [\varphi(x - h, y) + \varphi(x + h, y) + \varphi(x, y - h) + \varphi(x, y + h)] \quad (1.84)$$

$$\varphi_{i,j} = \frac{1}{4} [\varphi_{i-1,j} + \varphi_{i+1,j} + \varphi_{i,j-1} + \varphi_{i,j+1}] \quad (1.85)$$

- 6 es werden 2D-Irrfahrten auf dem Gitter durchgeführt:

$P_{i,j}(\vec{R}_k)$ sei die Wahrscheinlichkeit, daß die Irrfahrt in einem inneren Gitterpunkt (i, j) beginnt und im Randpunkt $\vec{R}_k$ endet

- 7 $P_{k'}(\vec{R}_k)$ sei die Wahrscheinlichkeit für den Übergang vom Randpunkt k' zum Randpunkt k ; es gilt offensichtlich (*absorbierender Zustand*, Irrfahrt endet dort)

$$P_{k'}(\vec{R}_k) = \delta_{k'k} \quad (1.86)$$

- 8 wird auf einer Irrfahrt, die im Randpunkt k endet, der Punkt (i, j) besucht, so konnte dies nur über die 4 an (i, j) angrenzenden Gitterpunkte erfolgen, daher gilt der Satz von der totalen Wahrscheinlichkeit (1.46)

$$P_{i,j}(\vec{R}_k) = \frac{1}{4} [P_{i-1,j}(\vec{R}_k) + P_{i+1,j}(\vec{R}_k) + P_{i,j-1}(\vec{R}_k) + P_{i,j+1}(\vec{R}_k)] \quad (1.87) \blacktriangleright$$

- 9 das Gleichungssystem (1.87) stimmt bis auf eine lineare Transformation (da Wahrscheinlichkeiten) mit (1.85) überein
 $\Rightarrow$ Irrfahrt-Simulation von (1.87) liefert daher Näherungslösung zu (1.85):
 Wenn von N Irrfahrten, die im Punkt (i, j) beginnen, $H_k(i, j)$ im Randpunkt $\vec{R}_k$ enden, so ergibt sich $P_{i,j}(\vec{R}_k)$ näherungsweise als relative Häufigkeit

$$P_{i,j}(\vec{R}_k) \approx \frac{H_k(i, j)}{N} \quad (1.88)$$

- 10 Einarbeitung der Randbedingungen: (1.87) wird mit $u_k = \varphi(\vec{R}_k)$ multipliziert und über alle Randpunkte summiert; mit der Abkürzung

$$v_{i,j} := \sum_k u_k P_{i,j}(\vec{R}_k) \quad (1.89)$$

folgt aus (1.87)

$$v_{i,j} = \frac{1}{4} [v_{i-1,j} + v_{i+1,j} + v_{i,j-1} + v_{i,j+1}] \quad (1.90)$$

und für die Randpunkte $\vec{R}_{k'}$ folgt wegen (1.86) unmittelbar

$$v_{k'} = \sum_k u_k P_{k'}(\vec{R}_k) = \sum_k \varphi(\vec{R}_k) \delta_{k'k} = \varphi(\vec{R}_{k'}) \quad (1.91) \blacktriangleright$$

⇒ die $v_{i,j}$ erfüllen die Randbedingungen in (1.83)

- ❶ da die Randbedingungen von v erfüllt werden, stimmen (1.90) und (1.85) überein und (1.89) stellt die Näherungslösung von (1.83) dar $\varphi_{i,j} = v_{i,j}$
- ❷ Einsetzen von (1.88) in (1.89) liefert schließlich mit (1.91) die Monte-Carlo Strategie

$$\varphi_{i,j} = \sum_k \varphi(\vec{R}_k) P_{i,j}(\vec{R}_k) \approx \frac{1}{N} \sum_k H_k(i,j) \varphi(\vec{R}_k) \quad (1.92)$$

⇒ das Potential φ im Gitterpunkt ergibt sich näherungsweise aus der gewichteten Summe der Potentiale auf dem Rand, wobei die Wichtung (1.88) durch die Ankunftshäufigkeiten der Irrfahrten festgelegt ist

Anmerkungen 1.61

- (1.92) liefert lediglich das Potential in einem Gitterpunkt
- der 3D-Fall folgt analog zu (1.92), es gibt dann bei der Irrfahrt auf dem Gitter 6 gleichwahrscheinliche Zufallsrichtungen an Stelle von 4

Zufallsvariablen

Motivation und Begrifflichkeiten

Zur weiteren Mathematisierung des Zufalls (wir wollen zufällige Experimente weiter quantifizieren, Kennzahlen ableiten etc.) ist die Einführung des Begriffes *Zufallsvariable* erforderlich.

- Im Kapitel 1 (Folien 1ff) haben wir uns mit verschiedenen zufälligen Experimenten befaßt, mit vollkommen unterschiedlichen Ergebnissen.
- Es gibt jedoch häufig Gemeinsamkeiten zwischen völlig unterschiedlichen zufälligen Prozessen, die durch eine mathematische Formulierung besser herausgearbeitet werden können:
- Zum Beispiel gibt es zwei Ausgänge beim Münzwurf, links oder rechts auf einer Ebene beim Galton-Brett, Inkrement oder Dekrement bei 1D Irrfahrt auf $\mathbb{Z}$, Funktion oder Nichtfunktion eines Sensors
- Den o.g. Beispielen ist gemein, daß es jeweils zwei Ergebnisse (Elementarereignisse) gibt. Es bietet sich daher die mathematische Abstraktion an, dem einen Ergebnis die Zahl 0 und dem anderen Ergebnis die Zahl 1 zuzuordnen.



- Betrachtet man die Farben einer Ampel als Elementarereignisse, so bietet sich die Zuweisung der Zahlen 0,1,2 an.
- Und völlig natürlich und offensichtlich ist die Verwendung von Zahlen in den Beispielen von Folie 6.
- ☞ Es macht Sinn, eine Funktion $X(\omega)$ einzuführen, die den Ergebnissen des Zufallversuchs Zahlen zuweist.
- Bei den Markov-Ketten haben wir bereits (explizit) davon Gebrauch gemacht, indem wir im Beisp. 1.52, Folie 44, die Zustände “Sonnenschein” und “Regen” durch die Indexzahlen $i = 1, 2$ ausgedrückt haben.

Definition 2.1 (Zufallsvariable, Zufallsvektor)

Sei (Ω, Σ, P) ein Wahrscheinlichkeitsraum. Eine Abbildung $X : \Omega \rightarrow \mathbb{R}^n$, $\omega \mapsto X(\omega)$, heißt **Zufallsvariable** (für $n = 1$) bzw. **Zufallsvektor** (für $n > 1$).

Anmerkung 2.2 (Zufallsgröße, Zufallsveränderliche)

*Die Bezeichnung “Zufallsvariable” (engl.: random variable) – obwohl fast ausschließlich verwendet – ist etwas irreführend, da es sich um eine **Funktion** der Elementarereignisse handelt. “Zufallsgröße” (oder Zufallsveränderliche, engl.: random variate) wäre eine angemessenere Bezeichnung.*

Anmerkungen 2.3 (Notationen)

- Zufallsvariablen (Zufallsgrößen) werden i.d.R. mit lateinischen großen Buchstaben bezeichnet, z.B. $X, Y, Z_i, \dots$
 - Zufallsvektoren sind einfach Vektoren, deren Komponenten Zufallsgrößen sind, sie werden in dieser Lehrveranstaltung durch ein Vektorsymbol über dem Großbuchstaben oder in Komponentenschreibweise dargestellt, also z.B. $\vec{X} = (X_1, \dots, X_n)^T$.
 - Der Definitionsbereich der Funktion $X(\omega)$ ist Ω
 - Der Wertebereich der Funktion $X(\omega)$ ist die Menge der Werte der Zufallsgröße X
 - Der Wert, den die Zufallsgröße X in einem konkreten Experiment annimmt, wird als eine **Realisation** der Zufallsvariable bezeichnet und wird i.d.R. durch den korrespondierenden Kleinbuchstaben symbolisiert.
- ☞ $X = x$ bedeutet, daß die Zufallsvariable X den Wert x im Experiment realisiert.


So wie wir im Kapitel 1 durch die Wahrscheinlichkeitsaxiome, Folie 17, jedem Ereignis A seine Wahrscheinlichkeit $P(A)$ zugeordnet haben, ist dies auch für Zufallsvariablen sinnvoll. Der zentrale Begriff ist hier die (kumulative) Verteilungsfunktion:

Definition 2.4 ((kumulative) Verteilungsfunktion einer Zufallsvariablen)

Sei (Ω, Σ, P) ein Wahrscheinlichkeitsraum und $X : \Omega \rightarrow \mathbb{R}$ eine Zufallsvariable. Die Funktion $F_X(t) = P(X \leq t)$ heißt (kumulative) **Verteilungsfunktion** der Zufallsvariablen X .

Beispiel 2.5 (Verteilungsfunktion des Würfel experiments)

Als Zufallsvariable werde die identische Funktion $X(\text{“Augenzahl } x\text{”}) = x$ genommen. $F_X(x)$ beschreibt die Wahrsch., daß die Zufallsvariable (Augenzahl) einen Wert annimmt, der kleiner oder gleich einem vorgegebenen t ist. Z.B. ist $F_X(3) = P(X \leq 3) = 0.5$, $F_X(7) = P(X \leq 7) = 1$ und $F_X(0.99) = P(X \leq 0.99) = 0$.



Anmerkungen 2.6

Für die Verteilungsfunktionen $F_X(t)$ gilt offensichtlich:

❶ Der Definitionsbereich ist $(-\infty, \infty)$.

❷ Der Wertebereich ist in $[0, 1]$, also $0 \leq F_X(t) \leq 1$. (2.1)

❸ $F_X(t)$ ist eine monoton nichtfallende Funktion

❹ Es gilt
$$\lim_{t \rightarrow -\infty} F_X(t) = 0$$
 (2.2)

und
$$\lim_{t \rightarrow \infty} F_X(t) = 1.$$
 (2.3)

Im Englischen wird die Verteilungsfunktion “cumulative distribution function” (cdf) genannt.

Die in Beispiel 2.5 betrachtete Zufallsvariable wird als *diskret* bezeichnet:

Definition 2.7 (diskrete Zufallsvariable)

Eine Zufallsvariable wird als *diskret* bezeichnet, wenn ihr Wertebereich eine endliche oder eine höchstens *abzählbare* Menge ist.

Definition 2.8 ((Wahrscheinlichkeits-) Verteilung)

Ist X eine *diskrete* Zufallsvariable, die die Werte $x_1, x_2, \dots$ annimmt, dann bezeichnet man die Gesamtheit der mit den Ereignissen assoziierten Einzelwahrscheinlichkeiten

$$p_i = p(x_i) := P(X = x_i) \quad (2.4)$$

als (Wahrscheinlichkeits-) **Verteilung** (oder Wahrscheinlichkeitsfunktion) der diskreten Zufallsvariablen X . Die Funktion $p(x_i)$ wird *probability mass function* (pmf) im Englischen genannt.

Theorem 2.9 (Zusammenhang von Verteilung und Verteilungsfunktion)

Aus der Kenntnis der Verteilung einer diskreten Zufallsvariablen X kann man die Verteilungsfunktion berechnen:

$$F_X(t) = P(X \leq t) = \sum_{i: x_i \leq t} P(X = x_i) = \sum_{i: x_i \leq t} p_i. \quad (2.5)$$

Umgekehrt erhält man die $p_i = P(X = x_i)$ als die Sprunghöhen (Zuwächse) an den Unstetigkeitsstellen $t = x_i$ der Verteilungsfunktion F_X

$$p_i = P(X = x_i) = P(X \leq x_i) - P(X < x_i) = F_X(x_i) - \lim_{x \rightarrow x_i - 0} F_X(x). \quad (2.6)$$


Beispiel 2.10 (Vierfacher Münzwurf)

X sei die Zufallsvariable, die die Anzahl der Z zählt beim vierfachen Münzwurf. X nimmt die diskreten Werte $0, 1, 2, 3, 4$ an. Der Grundraum hat Kardinalität $|\Omega| = 2^4 = 16$. Bestimmung der “günstigen” Fälle $\#$ liefert:


x		$\#$	$p_i = P(X = x)$
0	WWWW	1	1/16
1	WWWZ	$\frac{4!}{3!1!}$	1/4
2	WWZZ	$\frac{4!}{2!2!}$	3/8
3	WZZZ	$\frac{4!}{1!3!}$	1/4
4	ZZZZ	1	1/16

Damit erhält man für die Verteilung $p(x)$ und die Verteilungsfunktion $F_X(x)$:

$$p(x) = P(X = x)$$



$$F_X(x)$$



Theorem 2.11

Die Wahrscheinlichkeit, daß eine diskrete Zufallsvariable X einen Wert x im linksoffenen Intervall $(t_1, t_2]$ annimmt, ergibt sich zu

$$\begin{aligned} P(t_1 < X \leq t_2) &= \sum_{i: t_1 < x_i \leq t_2} P(X = x_i) = \sum_{i: x_i \leq t_2} P(X = x_i) - \sum_{i: x_i \leq t_1} P(X = x_i) \\ P(t_1 < X \leq t_2) &\stackrel{(2.5)}{=} F_X(t_2) - F_X(t_1). \end{aligned} \quad (2.7)$$

Beispiel 2.12 (geometrische Verteilung (abzählbar unendliche Menge))

Sei p die Wahrscheinlichkeit, daß ein Datenpaket (Telegramm) auf einem Feldbus erfolgreich gesendet wird und $q = 1 - p$ die Komplementärwahrscheinlichkeit für Re-Transmission. Man bestimme die Verteilung $P(X = k)$, daß das k -te Paket re-transmittet werden muß.

Sei A_i das Ereignis, daß das i -te Paket fehlerfrei übermittelt wird, so gilt:

$$P(\text{“das } k\text{-te Paket muß re-transmittet werden”}) = P(A_1 \cap \dots \cap A_{k-1} \cap \bar{A}_k)$$

$$\Rightarrow P(X = k) = P(A_1) \cdot \dots \cdot P(A_{k-1}) \cdot P(\bar{A}_k) = p^{k-1}(1 - p). \quad (2.8)$$

Neben den diskreten Zufallsgrößen spielen die *stetigen* Zufallsvariablen eine wichtige Rolle, z.B. bei der Modellierung von Messungenauigkeiten, der Beschreibung von physikalischen Phänomenen, als Approximation diskreter Variablen und vieles mehr.

Definition 2.13 (stetige Zufallsvariable, Zufallsgröße)

Eine Zufallsvariable X wird *stetig* (engl.: *continuous*) genannt, wenn es eine Funktion $f_X(x)$, *Dichtefunktion* (engl.: *probability density function, pdf*) genannt, gibt, die folgende Bedingungen erfüllt:

❶
$$f_X(x) \geq 0, \quad -\infty < x < \infty, \quad (2.9)$$

- ❷ die Verteilungsfunktion $F_X(t) = P(X \leq t)$ läßt sich für alle reellen t als Integral darstellen

$$F_X(t) = \int_{x=-\infty}^{x=t} f_X(x) dx, \quad (2.10)$$

- ❸ $\lim_{t \rightarrow \infty} F_X(t) = 1$ impliziert

$$\int_{-\infty}^{\infty} f_X(x) dx = 1. \quad (2.11)$$




Abb. 1: Geometrische Interpretation der (kumulativen) Verteilungsfunktion als Flächeninhalt bis $x \leq t$.




Abb. 2: Geometrische Interpretation der Wahrscheinlichkeit, X im Intervall $(t_1, t_2]$ zu finden.

Theorem 2.14

Die Wahrscheinlichkeit, daß eine stetige Zufallsvariable X einen Wert x im linksoffenen Intervall $(t_1, t_2]$ annimmt, ergibt sich zu (vgl. Abb. 2)

$$P(t_1 < X \leq t_2) = \int_{t_1 < x \leq t_2} f_X(x) dx = \int_{x=-\infty}^{x=t_2} f_X(x) dx - \int_{x=-\infty}^{x=t_1} f_X(x) dx$$

$$P(t_1 < X \leq t_2) = \int_{x=t_1}^{x=t_2} f_X(x) dx \stackrel{(2.10)}{=} F_X(t_2) - F_X(t_1). \quad (2.12)$$

Mit Kenntnis der Verteilungsfunktion $F_X(t)$ lässt sich die Dichtefunktion $f_X(t)$ berechnen:

Die grüne Fläche in Abbildung 3 ist $P(t < X \leq t + dx) = f_X(t) \cdot dx$. Nach (2.12) gilt außerdem $P(t < X \leq t + dx) = F_X(t + dx) - F_X(t)$. Gleichsetzen der Wahrscheinlichkeiten liefert $F_X(t + dx) - F_X(t) = f_X(t)dx$ und damit folgt $f_X(t) = \frac{F_X(t+dx) - F_X(t)}{dx}$.

Interpretiert man $dx \rightarrow 0$ als Differential, liegt hier die Definition der Ableitung von $F_X(x)$ nach x an der Stelle $x = t$ vor.




Abb. 3: Das infinitesimale Flächenstück (grüner Bereich) stellt die Wahrscheinlichkeit dar, $X \in (t, t + dx]$ zu finden.

Theorem 2.15

Die Dichtefunktion $f_X(t)$ einer stetigen Zufallsvariablen X ergibt sich aus $F_X(t)$ durch Differentiation

$$f_X(t) = \frac{dF_X(t)}{dt}. \quad (2.13)$$

Anmerkungen 2.16

- Satz 2.15 kann man bei Kenntnis der Differentiationstechnik für Parameterintegrale direkt durch Differentiation von (2.10) nach t erhalten. Die generelle Differentiationsregel für Parameterintegrale lautet

$$\begin{aligned} \frac{d}{dt} \int_{x=g_1(t)}^{x=g_2(t)} f(x, t) dx \\ = f(g_2(t), t) \frac{dg_2}{dt} - f(g_1(t), t) \frac{dg_1}{dt} + \int_{x=g_1(t)}^{x=g_2(t)} \frac{\partial}{\partial t} f(x, t) dx. \end{aligned} \quad (2.14)$$

- Die Schreibweisen $F_X(x)$ und $f_X(x)$ mit der tiefgestellten Zufallsvariablen wird häufig dahingehend vereinfacht, daß die Zufallsvariable als Index weggelassen wird, falls aus dem Kontext erschießbar (z.B. durch das Argument x).

NB: Die Wahrscheinlichkeit P , daß eine stetige Zufallsvariable X den Wert x realisiert, ist null (vorausgesetzt es gilt Dichtefunktion $f(x) < \infty$), also $P(X = x) = 0$. Das folgt auch unmittelbar anschaulich aus Abb. 3.

Beispiel 2.17 (CAUCHY Verteilung (auch LORENTZ Verteilung))

Man zeige, daß es sich bei


$$f(x) = \frac{1}{\pi} \frac{1}{1+x^2} \quad (2.15)$$

um eine Dichtefunktion handelt; man bestimme die Verteilungsfunktion $F(x)$:

Wegen (2.11) muß gelten $\lim_{x \rightarrow \infty} F(x) = 1$. Mit (2.10) folgt

$$F(x) = \int_{z=-\infty}^{z=x} \frac{1}{\pi} \frac{1}{1+z^2} dz = \frac{1}{\pi} \arctan(z) \Big|_{-\infty}^x = \frac{1}{\pi} \left(\arctan(x) - -\frac{\pi}{2} \right) \quad (2.16)$$

Da $\arctan(\infty) = \pi/2$ folgt in der Tat $F(\infty) = 1$.



Kennwerte von Verteilungen

- Die Wahrscheinlichkeitsfunktion (bzw. Dichtefunktion) beinhaltet die gesamte Information über die Zufallsvariable.
 - Diese Information ist häufig schwer zu interpretieren, daher ist es sinnvoll, aggregierte Kennzahlen zur Charakterisierung zu verwenden:
- 1 Quantile, Perzentile, Median
 - 2 Erwartungswert
 - 3 Varianz, Standardabweichung, Interquartilabstand
 - 4 Schiefe, Exzeß
 - 5 Entropie

Einige dieser Kenngrößen werden wir im Folgenden besprechen.



Definition 2.18 (Quantil)

Gegeben sei eine Zufallsgröße X und eine Zahl p mit $0 < p < 1$. Die Zahl $Q_p \in \mathbb{R}$ mit der Eigenschaft

$$F_X(Q_p) = p \quad (2.17)$$

heißt *Quantil der Ordnung p* , auch *p -Quantil* von X .

Anmerkungen 2.19

- *Ausgehend von der anschaulichen Definition von $F_X(x)$ als Flächeninhalt folgt, daß das p -Quantil Q_p der x -Wert ist, der die Fläche unter der Dichtefunktion $f_X(x)$ in die linksseitige Fläche mit Inhalt p und in die rechtsseitige Fläche mit Inhalt $1 - p$ unterteilt.*
- *Falls $F_X(x)$ streng monoton wachsend ist, ist die Quantilfunktion einfach die Umkehrfunktion von $F_X(x)$*

$$Q_p = F_X^{-1}(p) \quad (2.18)$$

- *Im diskreten Fall ist die Umkehrbarkeit nicht für jedes p gegeben, das Quantil existiert dann nicht eindeutig.*

Definition 2.20 (Median)

Das Quantil $Q_{1/2}$, das zu $p = \frac{1}{2}$ gehört, wird als *Median* bezeichnet.

Anmerkung 2.21

Der Median $Q_{1/2}$ teilt die Fläche unter der Dichtekurve $f(x)$ in zwei gleich-große Flächenstücke. Die Wahrscheinlichkeit, daß $X < Q_{1/2}$ oder $X > Q_{1/2}$ ist, ist damit genau $\frac{1}{2}$.

Beispiel 2.22 (Quantil der CAUCHY Verteilung)

Ausgehend von (2.17) und mit (2.16) liefert die Auflösung nach Q_p :

$$\frac{1}{2} + \frac{1}{\pi} \arctan(Q_p) = p \quad \Rightarrow \quad Q_p = \tan\left(\pi p - \frac{\pi}{2}\right). \quad (2.19)$$

Mit $p = \frac{1}{2}$ folgt als Median $Q_{1/2} = 0$, was auch anschaulich aus der linken Graphik von Beispiel 2.17 folgt.

Definition 2.23 (Perzentil)

Perzentil ist das spezielle Quantilmaß mit $p = P/100$ und $P \in \{1, \dots, 99\}$, also $F_X(Q_P) = P/100$. Es definiert den $x = Q_P$ Wert, zu dessen Linken, $P\%$ der Verteilung einer Zufallsgröße liegen.

Definition 2.24 ((Inter-) Quartilabstand)

Der Quartilabstand QA mißt den Abstand zwischen dem $Q_{3/4}$ und $Q_{1/4}$ einer Verteilung, also $QA := Q_{3/4} - Q_{1/4}$.

Anmerkung 2.25 (Quartilabstand ist ein Dispersionsmaß)

Definition 2.24 bedeutet, daß mit Wahrscheinlichkeit $1/2$ die Realisierungen einer Zufallsgröße X im Intervall der Breite QA liegen. Der Quartilabstand macht somit eine Aussage über die Ausdehnung (Dispersion) der Verteilung und gehört daher zu den Dispersionsmaßen (weitere folgen weiter unten).

Beispiel 2.26 (Quartilabstand der CAUCHY Verteilung)

Mit (2.19) und Definition 2.24 folgt:

$$QA = \tan(\pi/4) - \tan(-\pi/4) = 1 + 1 = 2 \quad (2.20)$$

Erwartungswert

Motivation

- Mathematisierung des Alltagsbegriffes *Durchschnitt* und *Mittelwert* durch Abstraktion von der Alltagserfahrung
- Zugang über die *relative Häufigkeit* im Fall *diskreter* Zufallsvariablen:
- Es werde eine Serie von N Zufallsexperimenten betrachtet, z.B. 2-faches Würfeln und die Zufallsvariable X “Summe der Augenzahl”. Die Realisation des n ten Experiments werde mit $X^{(n)} = x^{(n)}$ bezeichnet.
- Der Wertebereich von X sei durch die Menge $\{x_1, \dots, x_K\}$ gegeben (im Beispiel also $\{2, 3, \dots, 12\}$, $K = 11$).
- Bildung des Mittelwertes $\langle X \rangle$, wie er aus dem alltäglichen Sprachgebrauch bekannt ist: Es wird über die N Realisierungen der Zufallsvariablen X summiert und durch N dividiert: $\langle X \rangle := \frac{1}{N} \sum_{n=1}^N x^{(n)}$.
- Führt man die *Häufigkeiten* H_k ($k = 1, \dots, K$) ein, die angeben, wie oft die Realisierung x_k in der Summe vorkommt (es gilt $\sum_{k=1}^K H_k = N$), so folgt

$$\langle X \rangle = \frac{1}{N} \sum_{n=1}^N x^{(n)} = \frac{1}{N} \sum_{k=1}^K H_k x_k = \sum_{k=1}^K x_k \frac{H_k}{N}. \quad (2.21) \blacktriangleright$$

- die Größe H_k/N wird als *relative Häufigkeit*:

$$h_k := \frac{H_k}{N} \quad (2.22)$$

für das Auftreten des Ereignisses $X = x_k$ in N Versuchen bezeichnet.

- Also gilt

$$\langle X \rangle = \sum_{k=1}^K x_k h_k. \quad (2.23)$$

- Die relative Häufigkeit h_k hat die Eigenschaft einer Wahrscheinlichkeitsfunktion:

$$\sum_{k=1}^K h_k = 1 \quad (2.24)$$

und kann in der *frequentistischen* Interpretation des Wahrscheinlichkeitsbegriffs (vgl. Folie 24) für $N \rightarrow \infty$ als Wahrscheinlichkeit $p_k = P(X = x_k)$ interpretiert werden.

Das gibt Anlaß zu folgender Definition:



Definition 2.27 (Erwartungswert einer diskreten Zufallsvariablen)

Es sei X eine diskrete Zufallsgröße mit den Werten x_k und den Einzelwahrscheinlichkeiten $p_k = P(X = x_k)$. Falls die Summe $\sum_k x_k p_k$ absolut konvergiert, also $\sum_k |x_k| p_k < \infty$, wird

$$E[X] := \sum_k x_k p_k \quad (=: \mu) \quad (2.25)$$

als **Erwartungswert** der diskreten Zufallsvariablen X bezeichnet.

Beispiel 2.28 (Erwartungswert der Augenzahl X beim Würfeln)

Es ist $p_k = P(X = k) = \frac{1}{6}$. Mit (2.25) folgt $E[X] = \sum_{k=1}^6 k p_k = \sum_{k=1}^6 \frac{k}{6} = \frac{7}{2}$.

Beispiel 2.29 (Erwartungswert Augensumme beim zweimaligen Würfeln)

Für das Auftreten der Augensummen $X = 2, \dots, 12$ ergeben sich die Wahrscheinlichkeiten $(p_2, \dots, p_{12})$ gemäß (Aufgabe!):

$x_k =$	2	3	4	5	6	7	8	9	10	11	12
$p_k =$	$\frac{1}{36}$	$\frac{1}{18}$	$\frac{1}{12}$	$\frac{1}{9}$	$\frac{5}{36}$	$\frac{1}{6}$	$\frac{5}{36}$	$\frac{1}{9}$	$\frac{1}{12}$	$\frac{1}{18}$	$\frac{1}{36}$

Die Rechnung unter Verwendung von (2.25) ergibt $E[X] = 7$.

Beispiel 2.30 (Erwartungswert der geometrischen Verteilung)

In Beispiel 2.12 wurde die geometrische Verteilung $p_k = p^{k-1}(1-p)$ hergeleitet. Die Definition (2.25) des Erwartungswerts ergibt zunächst:

$$E[X] = \sum_{k=1}^{\infty} kp_k = \sum_{k=1}^{\infty} kp^{k-1}(1-p) = (1-p) \sum_{k=1}^{\infty} kp^{k-1}. \quad (2.26)$$

Da offensichtlich $kp^{k-1} = \frac{d}{dp}p^k$ ist, kann man dafür formal auch schreiben:

$$E[X] = (1-p) \frac{d}{dp} \sum_{k=1}^{\infty} p^k. \quad (2.27)$$

In (2.27) steht im Wesentlichen die unendliche geometrische Reihe; es gilt $\sum_{i=0}^{\infty} x^i = 1/(1-x)$ und damit $\sum_{i=1}^{\infty} x^i = 1/(1-x) - 1 = x/(1-x)$, also

$$E[X] = (1-p) \frac{d}{dp} \frac{p}{1-p} = (1-p) \frac{(1-p) - -p}{(1-p)^2} = \frac{1}{1-p}. \quad (2.28)$$

Im Beispiel 2.12 war $(1-p)$ die Wahrscheinlichkeit für Re-Transmission. Im Mittel (Erwartung!) muß daher jedes $1/(1-p)$ -te Paket retransmittet werden.

Definition 2.31 (Erwartungswert einer stetigen Zufallsvariablen)

Es sei X eine stetige Zufallsvariable mit der Dichtefunktion $f_X(x)$, dann wird das Integral

$$E[X] := \int_{-\infty}^{\infty} x f_X(x) dx \quad (=: \mu) \quad (2.29)$$

als *Erwartungswert der stetigen Zufallsvariablen X* bezeichnet, falls das uneigentliche Integral *absolut konvergent* ist

$$\int_{-\infty}^{\infty} |x| f_X(x) dx < \infty. \quad (2.30)$$

Beispiel 2.32 (Erwartungswert der uniformen (Gleich-) Verteilung)

Es werde die stetige Dichteverteilung $f_X(x)$ auf dem Intervall $x \in [a, b]$ ($a < b$) betrachtet

$$f_X(x) = \begin{cases} \frac{1}{b-a}, & \text{für } a \leq x \leq b, \\ 0, & \text{ansonsten.} \end{cases} \quad (2.31)$$

Anwendung von (2.29) liefert

$$E[X] = \int_{x=a}^{x=b} \frac{x}{b-a} dx = \frac{1}{2} \frac{1}{b-a} x^2 \Big|_a^b = \frac{1}{2} \frac{b^2 - a^2}{b-a} = \frac{a+b}{2}. \quad (2.32)$$

Theorem 2.33 (Erwartungswert von $g(X)$)

Gegeben sei eine reelle Funktion $g(x)$. Der Erwartungswert der mit g gebildeten Zufallsvariablen $Y = g(X)$ ist dann

$$E[g(X)] = \begin{cases} \sum_k g(x_k)p_k, & \text{falls } X \text{ diskret,} \\ \int_{-\infty}^{\infty} g(x)f_X(x)dx, & \text{falls } X \text{ stetig.} \end{cases} \quad (2.33)$$

Es werde die lineare Funktion $g(x) = ax + b$ mit $a, b \in \mathbb{R}$ betrachtet, dann folgt mit (2.33)

$$E[aX+b] = \begin{cases} \sum_k (ax_k + b)p_k \\ \int_{-\infty}^{\infty} (ax + b)f_X(x)dx \end{cases} = \begin{cases} a \sum_k x_k p_k + b \sum_k p_k \\ a \int_{-\infty}^{\infty} x f_X(x)dx + b \int_{-\infty}^{\infty} f_X(x)dx \end{cases}$$

Damit folgt unmittelbar:

Theorem 2.34 (Linearität des Erwartungswertes)

Gegeben sei eine Zufallsvariable X sowie zwei Konstanten $a, b \in \mathbb{R}$, dann gilt für die Zufallsvariable $aX + b$

$$E[aX + b] = aE[X] + b. \quad (2.34)$$

Varianz und Standardabweichung

- Die Angabe des Erwartungswertes $\mu = E[X]$ einer Verteilung stellt eine erste Charakterisierung der Zufallsgröße X dar.
- Diese gibt jedoch keine Auskunft darüber, wie stark die Realisierungen von dem μ -Wert abweichen.
- ☞ Es macht daher Sinn, die Abweichung der Realisierungen vom Erwartungswert zu bewerten, also $X - \mu$.
- Man könnte daher versucht sein, $E[X - \mu]$ als Maß der Ausdehnung (Dispersionsmaß) zu definieren.
- Jedoch gilt wegen (2.34) $E[X - \mu] = E[X] - \mu = \mu - \mu = 0$, daher muß entweder $E[|X - \mu|]$ oder $E[(X - \mu)^2]$ betrachtet werden, letzteres wird vorrangig verwendet:

Definition 2.35 (Varianz und Standardabweichung)

Es sei X eine Zufallsgröße. Dann wird mit

$$\text{Var}[X] := E[(X - \mu)^2] \quad (2.35)$$

die **Varianz** von X bezeichnet. Die Wurzel aus der Varianz heißt **Standardabweichung** $\sigma_X := \sqrt{\text{Var}[X]}$.

Die Berechnung der Gl. (2.35) kann vereinfacht werden unter Berücksichtigung von (2.34):

$$\text{Var}[X] = E[(X - \mu)^2] = E[X^2 - 2\mu X + \mu^2] = E[X^2] - 2\mu E[X] + \mu^2. \quad (2.36)$$

Wegen $\mu = E[X]$ folgt daher:

Theorem 2.36 (Berechnung der Varianz σ^2)

$$\sigma^2 = E[X^2] - (E[X])^2 = m_2 - \mu^2 \quad (2.37)$$

In Satz 2.36 wurde für $E[X^2]$ ersatzweise m_2 geschrieben:

Definition 2.37 (Momente einer Verteilung)

Der Erwartungswert der k -ten Potenz einer Zufallsgröße X mit $k = 1, 2, \dots$ wird als

$$\textbf{Moment } k\text{-ter Ordnung: } m_k := E[X^k] \quad (2.38)$$

bezeichnet. Für $k = 1$ wird an Stelle von m_1 häufig μ geschrieben.

Definition 2.38 (zentrale Momente einer Verteilung)

Der Erwartungswert der k -ten Potenz einer Zufallsgröße $X - E[X]$ mit $k = 1, 2, \dots$ wird als

$$\text{zentrales Moment } k\text{-ter Ordnung: } \mu_k := E[(X - \mu)^k] \quad (2.39)$$

bezeichnet. Wegen Definition 2.37 gilt $\mu_2 = \text{Var}[X] = \sigma^2$.

Beispiel 2.39 (Varianz der Augenzahl beim Würfeln)

Aufgrund von (2.37) und Beispiel 2.28 verbleibt die Berechnung des 2. Momentes $E[X^2] = \sum_{k=1}^6 k^2 p_k = \sum_{k=1}^6 \frac{k^2}{6} = \frac{91}{6}$. Damit folgt für $\text{Var}[X] = \frac{91}{6} - \frac{49}{4} = \frac{35}{12}$. Die Standardabweichung ist $\sigma_X = \sqrt{35/12} \approx 1.71$.

In Satz 2.34 wurde $E[Y]$ der linearen Transformation $Y = aX + b$ berechnet. Hier betrachten wir den Effekt auf die Varianz

$$\begin{aligned} \text{Var}[aX + b] &\stackrel{(2.35)}{=} E[(aX + b - E[aX + b])^2] \stackrel{(2.34)}{=} E[(aX + b - aE[X] - b)^2] \\ &= E[a^2(X - E[X])^2] \stackrel{(2.33)}{=} a^2 E[(X - E[X])^2]. \end{aligned}$$

Damit folgt:



Theorem 2.40 (Varianz bei linearer Transformation)

Gegeben sei eine Zufallsvariable X sowie zwei Konstanten $a, b \in \mathbb{R}$, dann gilt für die Varianz der Zufallsvariablen $aX + b$

$$\text{Var}[aX + b] = a^2 \text{Var}[X] \quad \text{und} \quad \sigma_{aX+b} = |a| \sigma_X. \quad (2.40)$$

Zur Berechnung von Wahrscheinlichkeiten bei komplizierten Dichtefunktionen wird häufig auf Verteilungsfunktionstabellen zurückgegriffen. Die Werte in derartigen Tabellen werden in der Regel in *standardisierter Form* angegeben. Das führt auf die:

Definition 2.41 (Standardisierung einer Zufallsvariablen)

Gegeben sei eine Zufallsgröße X mit Erwartungswert $\mu_X = E[X]$ und Standardabweichung $\sigma_X > 0$, dann wird die Zufallsvariable Z mit

$$Z := \frac{X - \mu_X}{\sigma_X} \quad (2.41)$$

als *standardisierte Zufallsgröße* bezeichnet. Es gilt $E[Z] = 0$ und $\text{Var}[Z] = 1$.

Zur weiteren Charakterisierung von Verteilungen und Dichtefunktionen werden weiterhin die folgenden Kennwerte verwendet:

Definition 2.42 (Schiefe einer Verteilung)

Das auf die 3. Potenz der Standardabweichung bezogene zentrale Moment 3. Ordnung wird als *Schiefe* (engl: skewness) γ_1 der Zufallsgröße X bezeichnet:

$$\gamma_1[X] := \frac{\mu_3[X]}{\sigma[X]^3} \quad (2.42)$$

Anmerkungen 2.43

- ❶ *Wie man unmittelbar sieht, ist die Schiefe das Moment 3. Ordnung der standardisierten Zufallsgröße (2.41)*
- ➡ *Zwei Zufallsvariablen X und Y , deren Verteilungsfunktionen F_X und F_Y sich nur im Erwartungswert und in der Standardabweichung unterscheiden, haben die gleiche Schiefe.*
- ➡ *Die Schiefe einer Verteilung ist invariant gegenüber linearen Transformationen der Zufallsvariablen.*
- ❷ *Symmetrische Verteilungen haben die Schiefe $\gamma_1 = 0$.*

Definition 2.44 (Exzeß einer Verteilung)

Der Exzeß γ_2 (engl.: kurtosis) einer Zufallsgröße X ist definiert als

$$\gamma_2[X] := \frac{\mu_4[X]}{\sigma[X]^4} - 3 \quad (2.43)$$

Anmerkungen 2.45

- ❶ *Wie man unmittelbar sieht, ist der Exzeß das Moment 4. Ordnung der standardisierten Zufallsgröße (2.41) von X vermindert um 3.*
- ❷ *Während die Schiefe einer Verteilung anschaulich ihre Abweichung von der Symmetrie der Wahrscheinlichkeitsfunktion bzw. Dichtefunktion beschreibt (Linksschiefe vs. Rechtsschiefe), ist der Exzeß ein Maß für die Wölbung (Spitzförmigkeit oder Stumpfförmigkeit) der Verteilung.*




Beispiele stetiger Verteilungen: Die Normalverteilung

- Die Dichtefunktion der (GAUSSschen) Normalverteilung ist definiert als

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2} \quad (2.44)$$

- Eine Zufallsgröße X , die normalverteilt ist, wird durch die Notation $X \sim \mathcal{N}(\mu, \sigma^2)$ symbolisiert, wobei $E[X] = \mu$ und $\text{Var}[X] = \sigma^2$ gilt.
- Die Standardnormalverteilung hat $E[X] = 0$ und $\text{Var}[X] = 1$. Die Dichtefunktion dieser Verteilung wird durch $f_X(x) =: \phi(x)$, die Verteilungsfunktion durch $F_X(x) =: \Phi(x)$ abgekürzt. Diese sehen wie folgt aus:



Eigenschaften der $\mathcal{N}(0, 1)$ -Verteilung

- Die Verteilungsfunktion $\Phi(x)$ kann *nicht* durch (endlich viele) elementare Funktionen dargestellt werden.
- Auf manchen Taschenrechnern und in Standard-Bibliotheken (z.B. `cmath: math.h`) findet man die *Error-Funktion*

$$\operatorname{erf}(x) := \frac{2}{\sqrt{\pi}} \int_{t=0}^{t=x} e^{-t^2} dt. \quad (2.47)$$

Durch lineare Transformation (Substitution) zeigt man leicht:

$$\Phi(x) = \frac{1}{2} \left(1 + \operatorname{erf} \left(\frac{x}{\sqrt{2}} \right) \right). \quad (2.48)$$

- Wie man in den Graphiken von Folie 87 sieht, ist die Dichtefunktion symmetrisch um den Nullpunkt: $\phi(x) = \phi(-x)$ (gerade Funktion!).
- Wegen der Symmetrie gilt für die Verteilungsfunktion $\Phi(x) + \Phi(-x) = 1$:

$$\Phi(-x) = 1 - \Phi(x). \quad (2.49) \blacklozenge$$

Tabelle (Ausschnitt) der Φ -Werte

	.00	.01	.02	.03	.04	.05	.06	.07	.08	.09
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
0.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
0.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
0.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
0.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1.0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1.2	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980	0.8997	0.9015
1.3	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1.4	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9279	0.9292	0.9306	0.9319
1.5	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1.6	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.7	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1.8	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1.9	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756	0.9761	0.9767
2.0	0.9772	0.9778	0.9783	0.9788	0.9793	0.9798	0.9803	0.9808	0.9812	0.9817
2.1	0.9821	0.9826	0.9830	0.9834	0.9838	0.9842	0.9846	0.9850	0.9854	0.9857
2.2	0.9861	0.9864	0.9868	0.9871	0.9875	0.9878	0.9881	0.9884	0.9887	0.9890
2.3	0.9893	0.9896	0.9898	0.9901	0.9904	0.9906	0.9909	0.9911	0.9913	0.9916
2.4	0.9918	0.9920	0.9922	0.9925	0.9927	0.9929	0.9931	0.9932	0.9934	0.9936
2.5	0.9938	0.9940	0.9941	0.9943	0.9945	0.9946	0.9948	0.9949	0.9951	0.9952

Beispiele: a) $P(X \leq 0.92) = \Phi(0.92) \approx 0.8212$

b) $P(X \leq -0.5) = \Phi(-0.5) = 1 - \Phi(0.5) \approx 0.3085$

c) $P(-2 \leq X \leq 2) = \Phi(2) - \Phi(-2) = \Phi(2) - (1 - \Phi(2)) \approx 0.9544$ 

Der allgemeine Fall der $\mathcal{N}(\mu, \sigma^2)$ -Verteilung (2.44)


Theorem 2.46 (Besonderheit der $\mathcal{N}(\mu, \sigma^2)$ Normalverteilung)

*Die Normalverteilung ist durch die Angabe der Kenngrößen: Erwartungswert μ und Standardabweichung σ **vollständig** festgelegt.*

Anwendungsspektrum:

- Modellierung von Beobachtungs- und Meßfehlern, Produktionstoleranzen
- Boltzmannverteilung einer Geschwindigkeitskomponente in der statistischen Mechanik, Brownsche Bewegungen
- Finanzmarktmodelle
- Approximation der diskreten Binomialverteilung (Galton-Brett)
- oft sind logarithmierte Zufallsgrößen approximativ normalverteilt
- Grenzverteilung der Statistik (Zentraler Grenzwertsatz)
- breites Anwendungsfeld in der induktiven Statistik





Berechnung von Wahrscheinlichkeiten bei $\mathcal{N}(\mu, \sigma^2)$ -Zufallsgrößen

- Es sei $X \sim \mathcal{N}(\mu, \sigma^2)$. Man bestimme $P(X \leq x)$.
- Mit (2.44) und (2.46) folgt: $P(X \leq x) = \frac{1}{\sigma} \int_{t=-\infty}^{t=x} \phi\left(\frac{t-\mu}{\sigma}\right) dt$.
- Substitution $z = \frac{t-\mu}{\sigma}$ liefert $dt = \sigma dz$ und für die obere Grenze $z = \frac{x-\mu}{\sigma}$

$$P(X \leq x) = \int_{z=-\infty}^{z=\frac{x-\mu}{\sigma}} \phi(z) dz \stackrel{(2.46)}{=} \Phi\left(\frac{x-\mu}{\sigma}\right). \quad (2.50)$$

Analog erhält man für die Zufallsvariable $X \sim \mathcal{N}(\mu, \sigma^2)$

$$P(x_1 \leq X \leq x_2) = \Phi\left(\frac{x_2 - \mu}{\sigma}\right) - \Phi\left(\frac{x_1 - \mu}{\sigma}\right). \quad (2.51)$$

Beispiel 2.47

Eine Zufallsvariable sei $\mathcal{N}(1, 2^2)$ verteilt. Man bestimme die Wahrscheinlichkeit, daß $X > 3$ ist.

$$P(X > 3) = 1 - P(X \leq 3) = 1 - \Phi\left(\frac{3-1}{2}\right) = 1 - \Phi(1) \approx 0.1587$$

Beispiel 2.48

Eine Zufallsvariable Y beschreibe die Wasserhöhe eines Flusses. Sie sei $\mathcal{N}(10, 4)$ verteilt. Man bestimme die Höhe h einer Schutzmauer, die mit 99% Wahrscheinlichkeit einen Übertritt des Wassers verhindert.

$P(Y \leq h) = 0.99$ und h ist gesucht.

Mit (2.50) folgt $P(Y \leq h) = \Phi\left(\frac{h-10}{2}\right) = 0.99$.

Umstellen nach h : $h = 10 + 2\Phi^{-1}(0.99) \approx 10 + 2 * 2.33 = 14.66$

Theorem 2.49 (Zentrale Momente, Schiefe, Exzeß der Normalverteilung)

Eine Zufallsvariable X sei $\mathcal{N}(\mu, \sigma^2)$ verteilt. Dann gilt für die zentralen Momente (2.39)

$$\mu_k = \mathbb{E}[(X - \mu)^k] = \begin{cases} 1 \cdot 3 \cdot \dots \cdot (k-1) \sigma^k, & \text{falls } k \text{ gerade} \\ 0, & \text{falls } k \text{ ungerade} \end{cases} \quad (2.52)$$

Die Schiefe γ_1 , Gl. (2.42), und der Exzeß γ_2 , Gl. (2.43), sind null.

Anmerkung 2.50 (Schiefe und Exzeß als Abweichung von der Normalität)

Während die Schiefe die Abweichung einer Verteilung von einer symmetrischen Verteilung bewertet, mißt der Exzeß die Abweichung von der Normalverteilung. Dies ist einer der Gründe, warum in der Formel für den Exzeß (2.43) die 3 abgezogen wird.



Weitere stetige Verteilungen

- ❶ Gleichverteilung, definiert in Beispiel 2.32, mit Dichtefunktion (2.31), Erwartungswert (2.32) und Varianz

$$\text{Var}[X] = \frac{(b - a)^2}{12}. \quad (2.53)$$

... ist anzuwenden, wenn außer dem Intervall, auf dem die Zufallsgröße definiert ist, nichts weiter über die Zufallsgröße bekannt ist.

- ❷ Exponentialverteilung, definiert durch

$$f_X(x) := \begin{cases} \lambda e^{-\lambda x}, & x \geq 0, \\ 0, & x < 0 \end{cases} \quad (2.54)$$

$$F_X(x) = \begin{cases} 1 - e^{-\lambda x}, & x \geq 0, \\ 0, & x < 0 \end{cases} \quad (2.55)$$

- Für Erwartungswert und Varianz erhält man

$$E[X] = \frac{1}{\lambda} \quad \text{und} \quad \text{Var}[X] = \frac{1}{\lambda^2}. \quad (2.56)$$

- ist anzuwenden, wenn nur der Erwartungswert bekannt ist und die Varianz dem Quadrat des Erwartungswerts gleicht 

- ▶ findet als einfachste Lebensdauer- u. Wartezeitverteilung weite Anwendung
- ▶ hat die Eigenschaft der “Gedächtnislosigkeit” als einzige stetige Verteilung (mit $X \geq 0$), d.h. es gilt

$$P(T > t + x | T > t) = P(T > x) \quad (2.57)$$

- ▶ In der Verwendung als Lebensdauerverteilung und insbesondere in der Zuverlässigkeitstheorie wird der Parameter $1/\lambda$ auch als *mittlere Betriebsdauer zwischen Ausfällen MTBF (engl.: mean time between failure)* bzw. *mittlere Betriebsdauer MTTF (engl.: mean time to failure)* bezeichnet.


3 Cauchy-Verteilung, definiert in Beispiel 2.17, mit Dichtefunktion (2.15), und Verteilungsfunktion (2.16).

NB: diese Verteilung besitzt *keine* Momente

- ▶ sogen. *heavy tail* Verteilung (es befindet sich “viel” Wahrscheinlichkeitsmasse in den “Schwänzen”).
- ▶ Verteilung wird zur Modellierung von Ausreißern benutzt.
- ▶ Eine Cauchy-verteilte Zufallsvariable C entsteht z.B. als Quotient von zwei standardnormalverteilten Zufallsvariablen

$$C = \frac{X_1}{X_2}, \quad X_1, X_2 \sim \mathcal{N}(0, 1) \quad (2.58) \quad \blacktriangledown$$

4 Gamma-Verteilung, hat die Dichtefunktion



$$f(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}, \quad x \geq 0 \quad (2.59)$$

$$E[X] = \frac{\alpha}{\lambda} \quad (2.60)$$

$$\text{Var}[X] = \frac{\alpha}{\lambda^2} \quad (2.61)$$


- ▶ die Gamma-Funktion ist definiert als $\Gamma(x+1) = x\Gamma(x)$ mit $\Gamma(1) = 1$
- ▶ wenn $\alpha \in \mathbb{N}$, dann gilt offensichtlich $\Gamma(\alpha) = (\alpha-1)!$
- ▶ es gibt keine Darstellung für $F_X(x)$ durch elementare Funktionen, es muß die sogen. unvollständige Γ -Funktion $\gamma(a, t)$ definiert werden:

$$F(x) = \frac{\gamma(\alpha, \lambda x)}{\Gamma(\alpha)} \quad \text{mit} \quad \gamma(a, t) := \int_{z=0}^{z=t} z^{a-1} e^{-z} dz, \quad \Gamma(\alpha) = \gamma(\alpha, \infty) \quad (2.62)$$

- ▶ Gammaverteilung enthält die Exponentialverteilung für $\alpha = 1$
- ▶ für $\alpha = k \in \mathbb{N}$ beschreibt (2.59) die Verteilung einer Summe von k exponentialverteilten Zufallsgrößen mit Parameter λ .



5 Weibull-Verteilung:



$$f(x) = \beta \lambda (\lambda x)^{\beta-1} e^{-(\lambda x)^\beta}, \quad x \geq 0 \quad (2.63)$$

$$F(x) = 1 - e^{-(\lambda x)^\beta}, \quad x \geq 0 \quad (2.64)$$

$$E[X] = \frac{1}{\lambda} \Gamma \left(1 + \frac{1}{\beta} \right) \quad (2.65)$$

$$\text{Var}[X] = \frac{1}{\lambda^2} \left[\Gamma \left(1 + \frac{2}{\beta} \right) - \Gamma^2 \left(1 + \frac{1}{\beta} \right) \right] \quad (2.66)$$

- ▶ die Weibull-Verteilung (2.63) wird häufig zur Modellierung der Ausfallwahrscheinlichkeit von elektronischen Bauelementen verwendet
- ▶ $\frac{1}{\lambda} =: T$ ist der Lebensdauerparameter:
nach Zeit $x = T = \frac{1}{\lambda}$ sind $1 - e^{-1} \approx 63\%$ der Bauelemente ausgefallen
- ▶ β ist der Formfaktor: $0 < \beta < 1$ beschreibt die *Frühhausfallphase*
 $\beta > 1$ beschreibt das Verhalten in der *Ermüdungs-* und *Alterungsphase*
- ▶ $\beta = 1$ zufällige Ausfälle in *Nutzungsphase*, Exponentialverteilung (2.54) ➡

²Zur Definition der Γ -Funktion siehe Gl. (2.62).

Anmerkungen 2.51 (Zuverlässigkeit und Ausfallrate (Fehlerrate))

- die Verteilungen (2.54) und (2.64) dienen zur Modellierung des Ausfallverhaltens von (Bau)Elementen
- $R(t) := 1 - F(t)$ ist die **Überlebenswahrscheinlichkeit (Zuverlässigkeit)**
- von N Elementen sind somit zur Zeit t noch $NR(t)$ funktionsfähig
- im Zeitintervall $(t, t + \Delta t]$ fallen $Nf(t)\Delta t$ Elemente aus
- das Verhältnis von in Δt ausfallenden zu den noch funktionsfähigen $NR(t)$ Elementen pro Zeiteinheit Δt wird als **Ausfallrate** oder **Fehlerrate** $h(t)$ bezeichnet

$$\frac{Nf(t)\Delta t}{NR(t)} \frac{1}{\Delta t} = \boxed{\frac{f(t)}{R(t)} =: h(t)} \quad (2.67)$$

- $h(t)$ (für engl.: **hazard rate**) kann durch $F(t)$ ausgedrückt werden

$$h(t) = \frac{dF(t)}{dt} \frac{1}{1 - F(t)} = -\frac{d}{dt} \ln(1 - F(t)) \quad (2.68)$$

- für (2.64) folgt $h(t) = \beta\lambda(\lambda t)^{\beta-1}$
- $\beta < 1 \Rightarrow h(t)$ fallend, $\beta = 1 \Rightarrow h(t) = \lambda$, $\beta > 1 \Rightarrow h(t)$ steigend

Beispiele diskreter Verteilungen: 0-1-Verteilung

- auch BERNOULLI-Verteilung genannt. Das Zufallsexperiment hat nur zwei Ausgänge, die mit den Zahlen $X = 0$ und 1 assoziiert werden:

$$p(x) = \begin{cases} q = 1 - p, & \text{für } x = 0 \\ p, & \text{für } x = 1 \end{cases} \quad (2.69)$$

- Beispiele: Münzwurf, Erfolg-Mißerfolgsexperimente, Qualitätstests etc.
- Für das Moment k ter Ordnung m_k erhält man unmittelbar

$$m_k = E[X^k] = 0^k \cdot q + 1^k \cdot p = p. \quad (2.70)$$

- Für die Varianz liefern (2.37) und (2.70)

$$\sigma^2 = \text{Var}[X] = m_2 - m_1^2 = p - p^2 = p(1 - p). \quad (2.71)$$




Beispiele diskreter Verteilungen: Binomialverteilung

- Es werde eine Anzahl von n unabhängigen Bernoulli-Experimenten durchgeführt. Wie groß ist die Wahrscheinlichkeit, daß genau k dieser Experimente “1” liefern (oder erfolgreich ausgehen etc.)?
- Visualisierung der Binomialverteilung durch das GALTON-Brett:



(3)

1
1 1
1 2 1
1 3 3 1
1 4 6 4 1



(4)

$\binom{0}{0}$
 $\binom{1}{0} \binom{1}{1}$
 $\binom{2}{0} \binom{2}{1} \binom{2}{2}$
 $\binom{3}{0} \binom{3}{1} \binom{3}{2} \binom{3}{3}$
 $\binom{4}{0} \binom{4}{1} \binom{4}{2} \binom{4}{3} \binom{4}{4}$

³Quelle: <http://vorsam.uni-ulm.de/Versuche/TH/Bilder/TH077B50.jpg>

⁴Quelle: http://upload.wikimedia.org/wikipedia/de/2/2d/Galtonbrett_mathe.PNG



- die Wahrscheinlichkeit, daß *eine* Kugel k mal nach rechts (entspricht “1” oder “Erfolg” etc.) und $n - k$ nach links (entspricht “0” oder Mißerfolg) fällt, ist $p^k(1 - p)^{n-k} = p^k q^{n-k}$
- es gibt $\binom{n}{k}$ gleichwahrscheinliche Möglichkeiten, das Experimentergebnis mit k “1”, also die Realisation $X = k$, zu erreichen: $\frac{n!}{k!(n-k)!}$, damit folgt die

Binomialverteilung:

$$p_k = P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}. \quad (2.72)$$

Aufgrund $1 \equiv [p + (1 - p)]^n$ gilt wegen des Binomischen Lehrsatzes:



$$[p + (1 - p)]^n = \sum_{k=0}^n \binom{n}{k} p^k (1 - p)^{n-k} = \sum_{k=0}^n p_k = 1. \quad (2.73)$$

- Die Verteilungsfunktion $F_X(x)$ folgt dann mit (2.5)



$$F_X(x) = \sum_{k=0}^{k \leq x} \binom{n}{k} p^k (1 - p)^{n-k}. \quad (2.74)$$

Beispiel: Binomialverteilung mit $n = 14$



$$p = 0.2$$



$$p = 0.5$$



$$p = 0.9$$



Anmerkung: Der Binomialverteilung sind wir bereits beim 4-fachen Münzwurf begegnet im Beispiel [2.10](#) auf Folie [64](#).



- Berechnung des Erwartungswertes der Binomialverteilung

$E[X] = \sum_{k=0}^n kp_k$. Mit (2.72) folgt

$$E[X] = \sum_{k=0}^n k \binom{n}{k} p^k (1-p)^{n-k} = \sum_{k=1}^n k \binom{n}{k} p^k (1-p)^{n-k} \quad (2.75)$$

Wegen $k \binom{n}{k} = k \frac{n!}{k!(n-k)!} = \frac{n(n-1)!}{(k-1)!((n-1)-(k-1))!} = n \binom{n-1}{k-1}$ folgt

$$E[X] = \sum_{k=1}^n n \binom{n-1}{k-1} p p^{k-1} (1-p)^{(n-1)-(k-1)} \quad (2.76)$$

Mit der Substitution $m = k - 1$ folgt

$$E[X] = np \sum_{m=0}^{n-1} \binom{n-1}{m} p^m (1-p)^{(n-1)-m} \stackrel{(2.73)}{=} np. \quad (2.77)$$

- Für die Varianz liefert eine ähnliche Rechnung (man berechnet zunächst $E[X(X-1)]$)

$$\text{Var}[X] = np(1-p). \quad (2.78) \blacklozenge$$

Beispiele diskreter Verteilungen: POISSON-Verteilung

- Es werde eine Folge von Bernoulli-Experimente betrachtet, bei denen das Ergebnis “1” (oder der Erfolg) ein *seltene*s Ereignis ist, z.B.:
 - ▶ der Zerfall eines Atomkerns
 - ▶ Emission eines Elektrons (ausgelöst durch ein Photon)
 - ▶ Transaktion von einem Bankomat
 - ▶ ein Anruf von Frau Meyer beim Call-Center
- Wie groß ist die Wahrscheinlichkeit p_k , daß $X = k$ derartige Ereignisse auftreten, wenn n Bernoulli-Experimente betrachtet werden (also z. B. 10^{23} Atome, 10000 Bankomaten an dem Bankcomputer angeschlossen sind, viele Photonen auf eine Photodiode treffen)?

☞ Binomial-Verteilung liegt eigentlich vor, jedoch:

- Die Wahrscheinlichkeit p für derartige seltene Ereignisse soll gegen null gehen, dafür $n \rightarrow \infty$, so daß $np \rightarrow \lambda$. Damit ist der folgende Grenzwert der Binomialverteilung (2.72) zu betrachten

$$p_k = P(X = k) = \lim_{\substack{n \rightarrow \infty \\ np \rightarrow \lambda}} \binom{n}{k} p^k (1-p)^{n-k}. \quad (2.79)$$



- Ersetzt man $p = \frac{\lambda}{n}$ in (2.79), so folgt

$$\begin{aligned}
 p_k &= \lim_{n \rightarrow \infty} \frac{1}{k!} (n(n-1) \dots (n-k+1)) \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} \\
 &= \frac{\lambda^k}{k!} \lim_{n \rightarrow \infty} \underbrace{\frac{n}{n} \left(1 - \frac{1}{n}\right)}_{\rightarrow 1} \dots \underbrace{\left(1 - \frac{k-1}{n}\right)}_{\rightarrow 1} \underbrace{\left(1 - \frac{\lambda}{n}\right)^n}_{\rightarrow e^{-\lambda}} \underbrace{\left(1 - \frac{\lambda}{n}\right)^{-k}}_{\rightarrow 1}
 \end{aligned}$$



Poisson-Verteilung:

$$p_k = \frac{\lambda^k}{k!} e^{-\lambda}$$

(2.80)

- Der Erwartungswert folgt gemäß $E[X] = \sum_{k=0}^{\infty} k p_k = \sum_{k=1}^{\infty} k p_k$ zu

$$E[X] = \sum_{k=1}^{\infty} k \frac{\lambda^k}{k!} e^{-\lambda} = e^{-\lambda} \lambda \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} = e^{-\lambda} \lambda \sum_{m=0}^{\infty} \frac{\lambda^m}{m!} = \lambda \quad (2.81)$$

- Die Varianz erhält man z.B. durch differenzieren der aus (2.81) folgenden Identität $\sum_{k=1}^{\infty} k \frac{\lambda^k}{k!} = \lambda e^{\lambda}$ nach λ (... und etwas Umstellen ...)

$$\text{Var}[X] = \lambda.$$

(2.82)



Anmerkung 2.52 (Eine Interpretation des λ -Parameters)

Mit der Poisson-Verteilung hat man die Wahrscheinlichkeit, in einem festen Zeitraum T genau k Ereignisse zu erhalten. Hierbei ist λ die mittlere Auftretshäufigkeit des Ereignisses im betrachteten Zeitintervall der Länge T .

Beispiel 2.53

Ein Datei-Server bediene durchschnittlich 300 Downloads pro Stunde. Die Kapazität des Servers ist dahingehend ausgelegt, daß maximal 10 Anfragen pro Minute bedient werden können. Wie groß ist die Wahrscheinlichkeit, daß der Server eine Anfrage wegen Überlastung zurückweist?

X = “Zufällige Anzahl von Download-Anfragen in einer Minute” und
 $\lambda = E[X] = 300/60 = 5$, gesucht $P(X > 10)$

$$P(X > 10) = 1 - P(X \leq 10) = 1 - \sum_{k=0}^{10} p_k = 1 - e^{-5} \sum_{k=0}^{10} \frac{5^k}{k!} \approx 0.01369$$

Beispiel 2.54

Auf einer Fläche von 5cm^2 befinden sich 1000 *Pseudomonas* (oder Defekte auf einem Wafer, etc.). Es werde angenommen, daß diese gleichverteilt sind. Wie groß ist die Wahrscheinlichkeit, auf einer Teilfläche von 5mm^2 höchstens 6 Bakterien (oder Defekte, etc.) zu finden?

X = “Zufällige Anzahl von Bakterien auf 5mm^2 ” und
 $\lambda = E[X] = 1000/100 = 10$, gesucht $P(X \leq 6)$

$$P(X \leq 6) = \sum_{k=0}^6 p_k = e^{-10} \sum_{k=0}^6 \frac{10^k}{k!} \approx 0.130$$

Anmerkung 2.55 (Poisson als Approximation der Binomialverteilung)

Aufgrund der Definition (2.79) der Poisson-Verteilung als Grenzverteilung der Binomial-Verteilung kann die Poisson-Verteilung zur Approximation der Binomial-Verteilung verwendet werden. Es gilt die Empfehlung:

$$\text{falls } n \geq 30, p \leq 0.05, \lambda = np \quad \Rightarrow \quad \text{Binomial}(n, p) \approx \text{Poisson}(\lambda) \quad (2.83)$$

Beispiel 2.56 (Schrotrauschen (shot noise) von Photodioden, Z-Dioden)

- elektrischer Strom I ist aufgrund der Elementarladung q_e granular
 - wenn der Stromfluß aufgrund unabhängiger Bewegung der Elektronen zustande kommt, wie z.B. in Vakuumröhren, Photodioden, oder bei Z-Dioden in Sperrichtung, treffen die Elektronen bei der Anode statistisch unregelmäßig ein
- ☞ I besteht daher aus einem Gleichanteil I_0 und einem Rauschanteil $\Delta I(t)$
- es gilt somit $E[\Delta I(t)] = 0$ und $E[I(t)] = I_0$
 - die Anzahl N (Zufallsgröße!) der Elektronen, die im Zeitintervall T bei der Anode eintreffen, bestimmen den Strom $I = \frac{Q}{T} = \frac{Nq_e}{T}$
 - es gilt daher $E[I(t)] = \frac{q_e}{T} E[N] = I_0 \implies E[N] = I_0 \frac{T}{q_e} \stackrel{(2.81)}{=} \lambda$
 - wegen (2.82) ist $\text{Var}[N] = \lambda = I_0 \frac{T}{q_e}$ und $\text{Var}[I] = \text{Var}\left[\frac{q_e}{T} N\right] = \frac{q_e^2}{T^2} \text{Var}[N]$
 - und mit $\text{Var}[N] = E[N] = I_0 \frac{T}{q_e} \implies \text{Var}[I] = \frac{q_e}{T} I_0$
- $\implies \sigma[\Delta I] = \sigma[I] = \sqrt{\text{Var}[I]} = \sqrt{q_e/T} \sqrt{I_0} \implies$
- $\implies$ **Standardabweichung des Stroms ist proportional zur Wurzel des Stroms**

Weitere diskrete Verteilungen

- ❶ Gleichverteilung, (auch gleichmäßige Verteilung genannt), z.B. Augenzahl beim Würfeln, Beispiel 2.5, allgemein gilt bei n möglichen Realisationen der Zufallsvariablen X :

$$p_k = P(X = x_k) = \frac{1}{n} \quad (2.84)$$

und damit folgt

$$E[X] = \frac{1}{n} \sum_{k=1}^n x_k \quad \text{und} \quad \text{Var}[X] = \frac{1}{n} \sum_{k=1}^n x_k^2 - \left(\frac{1}{n} \sum_{k=1}^n x_k \right)^2. \quad (2.85)$$

- ❷ Geometrische Verteilung, vgl. Beispiele 2.12, 2.30, beschreibt die Anzahl der Bernoulli-Experimente bis zum ersten Mißerfolg (p ist Wahrscheinlichkeit für Erfolg beim Bernoulli-Experiment). Wahrscheinlichkeitsfunktion wurde in Gl. (2.8) hergeleitet, Erwartungswert in Gl. (2.28). Es gilt

$$E[X] = \frac{1}{1-p} \quad \text{und} \quad \text{Var}[X] = \frac{p}{(1-p)^2}. \quad (2.86) \blacktriangleright$$

- ③ Hypergeometrische Verteilung, liefert die Wahrscheinlichkeiten des Urnenschemas der Qualitätskontrolle, Beispiel 1.40, Folie 30.

In einer Urne befinden sich N Kugeln, davon sind K schwarz. Es werden n Kugeln ohne Zurücklegen gezogen. Wie groß ist die Wahrscheinlichkeit p_k , k schwarze Kugeln zu ziehen?

$$p_k = P(X = k) = \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}} \quad (2.87)$$

Für Erwartungswert und Varianz findet man

$$E[X] = n \frac{K}{N} \quad \text{und} \quad \text{Var}[X] = n \frac{K}{N} \left(1 - \frac{K}{N}\right) \frac{N-n}{N-1}. \quad (2.88)$$

Anmerkung 2.57

Man kann K/N als Wahrscheinlichkeit p für das Auftreten schwarzer Kugeln in der Urne (vor der Ziehung) interpretieren. Damit kann man an Stelle von K auch pN schreiben:

$$p = \frac{K}{N} \quad \Rightarrow \quad E[X] = np, \quad \text{Var}[X] = np(1-p) \frac{N-n}{N-1}. \quad (2.89)$$

Mehrdimensionale Zufallsvariablen

• Beispiele:

- ▶ Augenzahlen beim Wurf von 4 Würfeln $\vec{X} = (X_1, X_2, X_3, X_4)^T$ mit $X_i \in \{1, \dots, 6\}$ stellt eine *diskrete* 4-dimensionale Zufallsgröße dar,
- ▶ Geschwindigkeit $\vec{v} = (v_x, v_y, v_z)^T$ eines Gasmoleküls im Raum mit $\vec{v} \in \mathbb{R}^3$ stellt eine 3-dimensionale *stetige* Zufallsgröße dar,
- ▶ die n -malige Ausführung von Bernoulli-Experimenten kann als binärwertiger Zufallsvektor $\vec{B} = (B_1, \dots, B_n)^T \in \mathbb{B}^n$ interpretiert werden,
- ▶ eine Meßreihe aus m Meßwerten kann als eine m -dimensionale Zufallsgröße aufgefaßt werden.

➡ mehrdimensionale Zufallsvariablen können auch als Zufallsvektoren bezeichnet/interpretiert werden; die Verteilungen nennt man *multivariat*.

Definition 2.58 ((kumulative) Verteilungsfunktion eines Zufallsvektors)

Sei (Ω, Σ, P) ein Wahrscheinlichkeitsraum und $\vec{X} : \Omega \rightarrow \mathbb{R}^n$ eine Zufallsvektor. Die Funktion $F_{\vec{X}}(\mathbf{x}) = P(X_1 \leq x_1, \dots, X_n \leq x_n)$ heißt (kumulative) *Verteilungsfunktion* des Zufallsvektors $\vec{X}$.


Im Folgenden werden wir uns zunächst auf 2D-Zufallsgrößen beschränken. ➡

Theorem 2.59 (Wahrscheinlichkeit für ein 2-dimensionales Intervall)

Die Wahrscheinlichkeit, einen 2-dimensionalen Zufallsvektor $\vec{X}$ im Intervall $(a_1, b_1] \times (a_2, b_2]$ zu finden, ergibt sich zu

$$\begin{aligned} P(a_1 < X_1 \leq b_1, a_2 < X_2 \leq b_2) \\ = F_{\vec{X}}(a_1, a_2) + F_{\vec{X}}(b_1, b_2) - F_{\vec{X}}(a_1, b_2) - F_{\vec{X}}(b_1, a_2). \end{aligned} \quad (2.90)$$

Proof.



$$\begin{aligned} P(a_1 < X_1 \leq b_1, a_2 < X_2 \leq b_2) \\ = F_{\vec{X}}(b_1, b_2) \\ - F_{\vec{X}}(a_1, b_2) \\ - F_{\vec{X}}(b_1, a_2) \\ + F_{\vec{X}}(a_1, a_2). \end{aligned}$$

□

Definition 2.60 (2-dimensionaler diskreter Zufallsvektor)

Ein zweidimensionaler Zufallsvektor $(X, Y)^T$ heißt *diskreter* Zufallsvektor, wenn er mit positiver Wahrscheinlichkeit höchstens abzählbar viele Wertepaare (x, y) annimmt.

Definition 2.61 (Wahrscheinlichkeitsfunktion oder Verteilung)

Die Wahrscheinlichkeit p_{ik} , daß der Zufallsvektor $(X, Y)^T$ das Wertepaar $(x_i, y_k)^T$ annimmt, wird *Wahrscheinlichkeitsfunktion* oder Verteilung des Zufallsvektors $(X, Y)^T$ genannt

$$P(X = x_i, Y = y_k) = P((X = x_i) \cap (Y = y_k)) = p_{ik}. \quad (2.91)$$

$P(X = x_i, Y = y_k)$ wird auch *Verbundwahrscheinlichkeit* genannt.

Analog zum Eindimensionalen, Gl. (2.5), ergibt sich die Verteilungsfunktion aus der Wahrscheinlichkeitsfunktion

$$F_{(X,Y)}(x, y) = \sum_{\substack{x_i \leq x \\ y_k \leq y}} P(X = x_i, Y = y_k) = \sum_{\substack{x_i \leq x \\ y_k \leq y}} p_{ik}. \quad (2.92)$$

Definition 2.62 (stetiger zweidimensionaler Zufallsvektor)

Ein Zufallsvektor $(X, Y)^T \in \mathbb{R}^2$ wird *stetig* genannt, wenn es eine *Dichtefunktion* $f_{(X,Y)}(x, y)$ gibt, die folgende Bedingungen erfüllt:

❶ $f_{(X,Y)}(x, y) \geq 0, \quad -\infty < x < \infty, \quad -\infty < y < \infty, \quad (2.93)$

❷ die (kumulative) Verteilungsfunktion $F_{(X,Y)}(s, t) = P(X \leq s, Y \leq t)$ lässt sich für alle reellen s, t als Doppelintegral darstellen

$$F_{(X,Y)}(s, t) = \int_{x=-\infty}^{x=s} \int_{y=-\infty}^{y=t} f_{(X,Y)}(x, y) dy dx, \quad (2.94)$$

❸ $\lim_{\substack{s \rightarrow \infty \\ t \rightarrow \infty}} F_{(X,Y)}(s, t) = 1$ impliziert

$$\int_{x=-\infty}^{x=\infty} \int_{y=-\infty}^{y=\infty} f_{(X,Y)}(x, y) dy dx = 1. \quad (2.95)$$

Die Dichtefunktion $f_{(X,Y)}(x, y)$ wird auch *Verbunddichte* genannt.

In Analogie zum Theorem 2.15, Gl. (2.13), kann bei Stetigkeit von $f_{(X,Y)}(x,y)$ im Punkt (x,y) die Dichtefunktion durch die zweite partielle Ableitung von $F_{(X,Y)}(x,y)$ nach x und y erhalten werden

$$f_{(X,Y)}(x,y) = \frac{\partial^2 F_{(X,Y)}(x,y)}{\partial x \partial y} \quad (2.96)$$

Beispiel 2.63 (n -dimensionale Normalverteilung $\vec{X} \sim \mathcal{N}(\vec{\mu}, \mathbf{C})$)

$$f_{\vec{X}}(\vec{x}) = \frac{1}{\sqrt{2\pi}^n} \frac{1}{\sqrt{\det[\mathbf{C}]}} e^{-\frac{1}{2}(\vec{x}-\vec{\mu})^T \mathbf{C}^{-1}(\vec{x}-\vec{\mu})} \quad (2.97)$$



$\mathbf{C} = \mathbf{C}^T$ ist die sogen.
Kovarianzmatrix.

$\mathbf{C}$ muß positiv definit
sein, d. h.:

$$\forall \vec{a} \neq \vec{0} : \vec{a}^T \mathbf{C} \vec{a} > 0.$$

Im Beispiel: $n = 2$,

$$\vec{\mu} = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \mathbf{C} = \begin{pmatrix} 1 & 1 \\ 1 & 3 \end{pmatrix}$$



Definition 2.64 (diskrete Randverteilung (auch Marginalverteilung))

Gegeben sei ein diskreter Zufallsvektor $(X, Y)^T$ mit der Wahrscheinlichkeitsfunktion $p_{ik} = P(X = x_i, Y = y_k)$, $i = 1, \dots, m$, $k = 1, \dots, n$, dann werden die Summationen über i bzw. k als **Randverteilungen** $p_{\cdot k} := P(Y = y_k)$ der Zufallsvariablen Y bzw. $p_{i \cdot} := P(X = x_i)$ der Zufallsvariablen X bezeichnet:

$$p_{i \cdot} := P(X = x_i) = \sum_{k=1}^n p_{ik} = \sum_{k=1}^n P(X = x_i, Y = y_k), \quad i = 1, \dots, m \quad (2.98)$$

$$p_{\cdot k} := P(Y = y_k) = \sum_{i=1}^m p_{ik} = \sum_{i=1}^m P(X = x_i, Y = y_k), \quad k = 1, \dots, n \quad (2.99)$$

Anmerkung 2.65 (zu Definition 2.64)

- ❶ *Randverteilungen “blenden” den Einfluß von Komponenten des Zufallsvektors aus; nur die Verteilung der in der Randverteilung auftretenden Zufallsvariablen wird betrachtet.*

❷ *Es gilt*

$$\sum_{i=1}^m p_{i \cdot} = \sum_{k=1}^n p_{\cdot k} = 1. \quad (2.100)$$

Randverteilungsfunktion und Randdichte

- Aufgrund der Definition 2.64 der Verteilungsfunktion einer mehrdimensionalen Zufallsgröße und der Definition 2.58 der Randverteilung (im zweidimensionalen Fall) ist die Verteilungsfunktion der Randverteilung von X gegeben durch

$$F_X(x) = F_{(X,Y)}(x, \infty) = P(X \leq x, Y < \infty) \quad (2.101)$$

- Im Fall diskreter Zufallsvektoren folgt daher mit (2.92)

$$F_X(x) = \sum_{x_i \leq x} p_{i\cdot} = \sum_{x_i \leq x} \sum_k p_{ik}. \quad (2.102)$$

- Im Fall stetiger Zufallsvektoren folgt analog mit (2.94)

$$F_X(x) = \int_{s=-\infty}^{s=x} \int_{y=-\infty}^{y=\infty} f_{(X,Y)}(s, y) dy ds. \quad (2.103)$$

- Die Randdichtefunktion im stetigen Fall folgt durch Differentiation von (2.103)

$$f_X(x) = \int_{y=-\infty}^{y=\infty} f_{(X,Y)}(x, y) dy. \quad (2.104) \quad \blacktriangleright$$

Bedingte Verteilungen

Der Begriff der bedingten Wahrscheinlichkeit wurde in Definition 1.41, Gl. (1.42) (Folie 31), eingeführt. Er kann unmittelbar auf Zufallsvariablen übertragen werden:

Definition 2.66 (Bedingte Wahrscheinlichkeit, diskreter Fall)

Gegeben sei ein diskreter Zufallsvektor $(X, Y)^T$ mit der Wahrscheinlichkeitsfunktion $p_{ik} = P(X = x_i, Y = y_k)$, $i = 1, \dots, m$, $k = 1, \dots, n$. Die Größen

$$P(X = x_i | Y = y_k) := \frac{P(X = x_i, Y = y_k)}{P(Y = y_k)} \quad (2.105)$$

werden *bedingte Einzelwahrscheinlichkeiten der Zufallsgröße X unter der Bedingung $Y = y_k$* und die

$$P(Y = y_k | X = x_i) := \frac{P(X = x_i, Y = y_k)}{P(X = x_i)} \quad (2.106)$$

werden *bedingte Einzelwahrscheinlichkeiten der Zufallsgröße Y unter der Bedingung $X = x_i$* genannt.

Aus (2.105) und (2.106) und der Definition der Randverteilungen (2.98) und (2.99) folgt unmittelbar

$$P(X = x_i | Y = y_k) = \frac{p_{ik}}{p_{\cdot k}}, \quad (2.107)$$

$$P(Y = y_k | X = x_i) = \frac{p_{ik}}{p_{i \cdot}}. \quad (2.108)$$

Im Fall stetiger Zufallsgrößen geht man wieder von Definition (1.42) aus und betrachtet die Ereignisse $A = \{Y \leq y\}$ und $B = \{x \leq X \leq x + h\}$

$$\begin{aligned} P(Y \leq y | x \leq X \leq x + h) &= \frac{P(Y \leq y, x \leq X \leq x + h)}{P(x \leq X \leq x + h)} \\ &= \frac{\int_{s=x}^{s=x+h} \int_{t=-\infty}^{t=y} f_{(X,Y)}(s, t) dt ds}{\int_{s=x}^{s=x+h} \int_{t=-\infty}^{t=\infty} f_{(X,Y)}(s, t) dt ds}. \end{aligned} \quad (2.109)$$

Da wir an der Verteilungsfunktion unter der Bedingung $X = x$ interessiert sind, muß der Grenzwert $h \rightarrow 0$ im Zähler und Nenner von (2.109) genommen werden. Dazu werden Zähler und Nenner mit $\frac{1}{h}$ erweitert und die Definition des Differentialquotienten wird erinnert. Damit folgt:



$$\begin{aligned}
 F(y|x) &= \lim_{h \rightarrow 0} P(Y \leq y | x \leq X \leq x+h) \\
 &= \frac{\lim_{h \rightarrow 0} \frac{1}{h} \int_{s=x}^{s=x+h} \int_{t=-\infty}^{t=y} f_{(X,Y)}(s,t) dt ds}{\lim_{h \rightarrow 0} \frac{1}{h} \int_{s=x}^{s=x+h} \int_{t=-\infty}^{t=\infty} f_{(X,Y)}(s,t) dt ds}
 \end{aligned}$$

$$(2.104) \quad \Rightarrow \quad \boxed{F_{(X,Y)}(y|x) = \frac{\int_{t=-\infty}^{t=y} f_{(X,Y)}(x,t) dt}{f_X(x)}}. \quad (2.110)$$

Die *bedingte Dichtefunktion* folgt aus der bedingten Verteilungsfunktion (2.110) durch Differentiation nach y (Parameterintegral-Regel (2.14))

$$\boxed{f_{(X,Y)}(y|x) = \frac{f_{(X,Y)}(x,y)}{f_X(x)}}. \quad (2.111)$$

Multipliziert man in (2.110) beide Seiten mit $f_X(x)$ und integriert man über x , dann erhält man auf der rechten Seite in Analogie zu (2.103) die Randverteilung für Y , also:



$$F_Y(y) = \int_{x=-\infty}^{x=\infty} F_{(X,Y)}(y|x)f_X(x)dx. \quad (2.112)$$

Anmerkungen 2.67

- ❶ Gleichung (2.112) kann als eine Verallgemeinerung des **Satzes von der totalen Wahrscheinlichkeit**, Gl. (1.46), auf stetige Zufallsvariablen angesehen werden.
- ❷ Die **Formel von Bayes**, Gl. (1.47), kann auch für stetige Zufallsgrößen formuliert werden. Unter Zuhilfenahme von (2.111) und (2.112) findet man:

$$f(x|y) = \frac{f(y|x)f_X(x)}{\int_{-\infty}^{\infty} f_{(X,Y)}(y|x)f_X(x)dx}. \quad (2.113)$$

- ❸ Formel (2.113) findet u.a. Anwendung im Bereich der Bayesschen Schätzverfahren, in der Signalverarbeitung (Kalman-Filter) und bei Klassifikationsproblemen.

Aus (2.111) folgt nach Multiplikation mit $f_X(x)$ und Integration über x die Randdichte

$$f_Y(y) = \int_{x=-\infty}^{x=\infty} f_{(X,Y)}(y|x)f_X(x)dx. \quad (2.114)$$

- Gleichung (2.114) ist das Pendant zu (1.57) bei Markov-Ketten mit diskreten Zuständen
- $f_{(X,Y)}(y|x)$ wird als *Markov-Kern* oder *Übergangsdichte* bezeichnet
- die Markov-Kette ist dann die Hintereinanderausführung von Integrationen der Art (2.114)

Beispiel 2.68 (Gaußsche Übergangsdichte und Diffusion)

Als Modell einer BROWNSchen Bewegung (Diffusion) im Eindimensionalen kann man die Gaußsche Irrfahrt im $\mathbb{R}^1$ betrachten mit der Übergangsdichte

$$f_Y(y|x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(y-x)^2}{2\sigma^2}} \quad (2.115)$$

Beispiel 2.68 (... Fortsetzung)

- *beginnt die Bewegung bei $x = 0$, so erhält man für $f_Y(y) =: f^{(1)}(y)$ rein anschaulich*

$$f^{(1)}(y) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2} \frac{y^2}{\sigma^2}} \quad (2.116)$$

- *und nach einer zweiten Anwendung von (2.114) mit $f_X(x) =: f^{(1)}(x)$ und $f_Y(y) =: f^{(2)}(y)$ (Aufgabe: Integration mit quadratischer Ergänzung)*

$$f^{(2)}(y) = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{\infty} e^{-\frac{1}{2} \frac{(y-x)^2}{\sigma^2}} f^{(1)}(x) dx = \frac{1}{\sqrt{2\pi}\sqrt{2}\sigma} e^{-\frac{1}{2} \frac{y^2}{2\sigma^2}} \quad (2.117)$$

- *und allgemein*

$$f^{(t)}(y) = \frac{1}{\sqrt{2\pi}\sqrt{t}\sigma} e^{-\frac{1}{2} \frac{y^2}{t\sigma^2}} \quad (2.118)$$

⇒ *die Standardabweichung von $y^{(t)}$ wächst mit der Wurzel der Zeit*

☞ *interpretiert man t als kontinuierliche Zeit, so beschreibt $f(y, t)$ die Diffusion von Teilchen und $f(y, t)$ genügt der Diffusionsgleichung*

$$\frac{\partial f(y, t)}{\partial t} = \frac{\sigma^2}{2} \frac{\partial^2 f(y, t)}{\partial y^2} \quad (2.119)$$

Stochastische Unabhängigkeit von Zufallsvariablen

- Der Begriff der stochastischen Unabhängigkeit wurde im Zusammenhang mit der Wahrscheinlichkeit des Schnitts (Produkt) zweier Ereignisse in Definition 1.29, Gl. (1.33), eingeführt. Er kann damit auf die speziellen Ereignisse $A = \{X \leq x\}$, $B = \{Y \leq y\}$ übertragen werden:

$$P(X \leq x, Y \leq y) = P(\{X \leq x\} \cap \{Y \leq y\}) = P(X \leq x) \cdot P(Y \leq y)$$

- Mit der Definition der (mehrdimensionalen) kumulativen Verteilungsfunktion (2.58) kann damit in Verallgemeinerung auf n -dimensionale Zufallsgrößen $\vec{X} = (X_1, \dots, X_n)^T$ geschrieben werden:

stochastische Unabhängigkeit:

$$F_{\vec{X}}(\vec{x}) = F_{X_1}(x_1) \cdot \dots \cdot F_{X_n}(x_n) \quad (2.120)$$

- Im Fall stetiger Zufallsgrößen folgt aus (2.120) in Analogie zu (2.96) die *Dichtefunktion* als n -te partielle Ableitung nach den n Zufallskomponenten

stochastische Unabhängigkeit:

$$f_{\vec{X}}(\vec{x}) = f_{X_1}(x_1) \cdot \dots \cdot f_{X_n}(x_n) \quad (2.121)$$

- Im Fall diskreter zweidimensionaler Zufallsgrößen liefert die allgemeine Definition der stochastischen Unabhängigkeit von Ereignissen direkt $P(X = x_i, Y = y_k) = P(\{X = x_i\} \cap \{Y = y_k\}) = P(X = x_i)P(Y = y_k)$ und daher

stochastische Unabhängigkeit:
$$p_{ik} = p_{xi} \cdot p_{yk} \quad (2.122)$$

Die Übertragung auf n -dimensionale Zufallsvariablen ist offensichtlich.

Anmerkungen 2.69

- 1 *Eine alternative, aber äquivalente, Sichtweise der stochastischen Unabhängigkeit, die zudem anschaulich ist, geht von der bedingten Verteilungsfunktion bzw. Dichtefunktion aus:*

stochastische Unabhängigkeit:
$$F(x|y) = F_X(x), \quad f(x|y) = f_X(x). \quad (2.123)$$

Das bedeutet, daß y keinen Einfluß auf x hat (und umgekehrt).

- 2 *Die Gleichungen (2.120–2.123) können als Kriterium zum Nachweis der stochastischen Unabhängigkeit verwendet werden.*

Beispiel 2.70 (Eigenschaften der bivariaten $\mathcal{N}(\vec{\mu}, \mathbf{C})$ -Verteilung)

Sind die Komponenten der bivariaten (2-dimensionalen) $\mathcal{N}(\vec{\mu}, \mathbf{C})$ -Verteilung (mit $\vec{\mu} = (\mu_X, \mu_Y)^T$), Gl. (2.97), stochastisch unabhängig?

Gemäß (2.121) müßte sich die Dichtefunktion (2.97) als Produkt der Dichten $f_X(x)$ und $f_Y(y)$ darstellen lassen. Dazu müßte der Exponent in der e-Funktion von (2.97) durch zwei additiv separable Teilfunktionen $g_1(x)$ und $g_2(y)$ darstellbar sein. Also $(\vec{x} - \vec{\mu})^T \mathbf{C}^{-1} (\vec{x} - \vec{\mu}) = g_1(x) + g_2(y)$ (NB: $\vec{x} = (x, y)^T$). Mit den Kovarianzmatrixelementen $d_{ij} := (\mathbf{C}^{-1})_{ij}$ folgt:

$$\begin{aligned} & (\vec{x} - \vec{\mu})^T \mathbf{C}^{-1} (\vec{x} - \vec{\mu}) \\ &= d_{11}(x - \mu_X)^2 + (d_{12} + d_{21})(x - \mu_X)(y - \mu_Y) + d_{22}(y - \mu_Y)^2 \end{aligned} \quad (2.124)$$

Separabilität ist nur gegeben, wenn $d_{12} + d_{21} = 0$. Da $d_{12} = d_{21}$, folgt $d_{12} = d_{21} = 0$ und man kann $d_{11} = \sigma_X^{-2}$, $d_{22} = \sigma_Y^{-2}$ interpretieren. Das heißt, nur wenn die **Kovarianzmatrix diagonal** ist, also wenn

$$\mathbf{C} = \begin{pmatrix} \sigma_X^2 & 0 \\ 0 & \sigma_Y^2 \end{pmatrix}, \quad (2.125)$$

dann sind die **Zufallsgrößen** X und Y **stochastisch unabhängig**.

Beispiel 2.71 (Verteilung von $\vec{v}$ im idealen Gas (Maxwell-Verteilung))

Modellannahmen des idealen Gases (Gleichgewichts-Thermodynamik):

- Dichtefunktion $f(\vec{v}) = f(v_x, v_y, v_z)$ des Geschwindigkeitsvektors eines (elastischen) Teilchens in einem abgeschlossenen System ist zeitlich konstant (stationär) und ist isotrop, d.h. es ist keine Richtung ausgezeichnet

$$E[\vec{v}] = \vec{0} \quad \text{und} \quad f(v_x, v_y, v_z) = f(-v_x, v_y, v_z), \quad \text{etc.} \quad (2.126)$$

⇒ da keine Richtung ausgezeichnet ist, hängt die Dichtefunktion $f(\vec{v})$ nur vom Betrag und damit vom Betragsquadrat der Geschwindigkeit ab

$$f(v_x, v_y, v_z) = f(\|\vec{v}\|^2) =: bg(v_x^2 + v_y^2 + v_z^2) \quad (2.127)$$

- die Bewegung des Teilchens in x - (oder y -, z -) Richtung ist stochastisch unabhängig von den anderen Raumrichtungen

$$f(v_x, v_y, v_z) = f_x(v_x)f_y(v_y)f_z(v_z) \quad (2.128)$$

- und wegen der Isotropie muß außerdem $f_x = f_y = f_z =: ag(\cdot)$ gelten, also

$$bg(v_x^2 + v_y^2 + v_z^2) = ag(v_x^2)ag(v_y^2)ag(v_z^2) \quad (2.129)$$

Beispiel 2.71 (... Fortsetzung)

- mit $b = a^3$ geht (2.128) über in

$$g(v_x^2 + v_y^2 + v_z^2) = g(v_x^2)g(v_y^2)g(v_z^2) \quad (2.130)$$

- Gleichung (2.129) stellt eine sogen. CAUCHY **Funktionalgleichung** vom Exponentialtyp dar

$$g(x+y) = g(x)g(y) \quad \text{mit der allgem. Lösung} \quad g(x) = e^{cx} \quad (2.131)$$

$\Rightarrow$ der Vergleich mit (2.130) liefert $g(v_x^2) = e^{cv_x^2}$ und

$$f_x(v_x) = ae^{cv_x^2}, \quad f_y(v_y) = ae^{cv_y^2}, \quad f_z(v_z) = ae^{cv_z^2} \quad (2.132)$$

- mit $c = -\frac{1}{2\sigma^2}$ erhält man also die Dichtefunktion der Normalverteilung (2.44) mit $\mu = 0$, wobei $a = \frac{1}{\sqrt{2\pi}\sigma}$
- Einsetzen von (2.131) in (2.129) liefert schließlich mit $\sigma^2 = \frac{k_B T}{m}$ die **MAXWELL-BOLTZMANN Verteilung des idealen Gases**

$$f(v_x, v_y, v_z) = \left(\frac{m}{2\pi k_B T} \right)^{\frac{3}{2}} \exp \left(-\frac{m(v_x^2 + v_y^2 + v_z^2)}{2k_B T} \right) \quad (2.133)$$

Eigenschaften der Summe von Zufallsgrößen

Wegen der großen praktischen Relevanz betrachten wir im Folgenden die Summe S zweier Zufallsgrößen X und Y

$$S = X + Y \quad (2.134)$$

und berechnen Erwartungswert, Varianz, und Verteilungsfunktion.

Erwartungswert

- NB: Summe zweier Zufallsvariablen ist wieder eine Zufallsvariable.
- Der Erwartungswert ergibt sich für diskrete Zufallsvariablen als Erwartungswert aller möglichen Realisationen der (X, Y) -Tupel

$$\begin{aligned} E[S] &= E[X + Y] = \sum_i \sum_k (x_i + y_k) P(X = x_i, Y = y_k) \\ &= \sum_i \sum_k (x_i + y_k) p_{ik} = \sum_i \sum_k (x_i p_{ik} + y_k p_{ik}) \\ &= \sum_i x_i \left(\sum_k p_{ik} \right) + \sum_k y_k \left(\sum_i p_{ik} \right) \end{aligned} \quad (2.135)$$

$$E[S] \stackrel{(2.98)}{=} \sum_i x_i P(X = x_i) + \sum_k y_k P(Y = y_k)$$

$$\Rightarrow \boxed{E[X + Y] = E[X] + E[Y]} \quad (2.136)$$

- Gleichung (2.136) gilt auch für stetige Zufallsvariablen.
- Gleichung (2.136) kann auf die Linearkombination von beliebig vielen Zufallsvariablen X_i ($i = 1, \dots, n$) verallgemeinert werden

$$\boxed{E \left[\sum_{i=1}^n a_i X_i \right] = \sum_{i=1}^n a_i E[X_i]} \quad (2.137)$$

- Gleichung (2.136) kann auf die Summe von Funktionen $g(X)$ und $h(Y)$ der Zufallsgrößen X, Y verallgemeinert werden (falls die Erwartungswerte existieren)

$$\boxed{E[g(X) + h(Y)] = E[g(X)] + E[h(Y)]} \quad (2.138) \blacktriangleright$$

Beispiel 2.72 (Mittlere kinetische Energie eines idealen Gasteilchens)

- die kinetische Energie eines Körpers der Masse m ist $W_{\text{kin}} = \frac{m}{2} \vec{v}^2$
- da $\vec{v}$ ein Zufallsvektor ist, ist W_{kin} eine Zufallsvariable und der Erwartungswert von W_{kin} ergibt sich zu

$$\begin{aligned} E[W_{\text{kin}}] &= E\left[\frac{m}{2}(v_x^2 + v_y^2 + v_z^2)\right] \stackrel{(2.138)}{=} E\left[\frac{m}{2}v_x^2\right] + E\left[\frac{m}{2}v_y^2\right] + E\left[\frac{m}{2}v_z^2\right] \\ &= \frac{m}{2}E[v_x^2] + \frac{m}{2}E[v_y^2] + \frac{m}{2}E[v_z^2] \end{aligned} \quad (2.139)$$

- im idealen Gas (unter Gleichgewichtsbedingungen) ist der Geschwindigkeitsvektor $\vec{v} = (v_x, v_y, v_z)^T$ gemäß Gl. (2.133) verteilt, damit folgt z.B.

$$E[v_x^2] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} v_x^2 f(v_x, v_y, v_z) dv_x dv_y dv_z \stackrel{(2.104)}{=} \int_{-\infty}^{\infty} v_x^2 f_x(v_x) dv_x \quad (2.140)$$

- da $f_x(v_x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{v_x^2}{2\sigma^2}}$ folgt wegen (2.52) $E[v_x^2] = \sigma^2$ und mit $\sigma^2 = \frac{k_B T}{m}$
- $$E[v_x^2] = \frac{k_B T}{m} \quad (= E[v_y^2] = E[v_z^2]) \quad (2.141)$$

Beispiel 2.72 (... Fortsetzung)

- setzt man das Ergebnis (2.141) in (2.139) ein, so folgt

$$E[W_{\text{kin}}] = \frac{1}{2}k_B T + \frac{1}{2}k_B T + \frac{1}{2}k_B T = \frac{3}{2}k_B T \quad (2.142)$$

⇒ die mittlere kinetische Energie eines Atoms ist also proportional zur absoluten Temperatur T

- dabei ist $k_B \approx 1.38 \cdot 10^{-23} \text{Ws/K}$ die BOLTZMANN-Konstante
- das Teilchen besitzt 3 Freiheitsgrade; allgemein gilt im thermodynamischen Gleichgewicht das **Äquipartitionstheorem (Gleichverteilungssatz)**

pro Freiheitsgrad: $E[W_{\text{kin}}] = \frac{1}{2}k_B T$

 (2.143)



Beispiel 2.73 (Druck P in der statistischen Mechanik)

- Druck $P = \frac{F}{A}$ ist das Ergebnis der zeitlichen Impulsänderung $\frac{\Delta p}{\Delta t} = F$ (Kraft) der auftreffenden Teilchen auf eine Fläche A
- ein auf die Wand (y - z -Ebene) auftreffendes Teilchen wird reflektiert, daher beträgt die Impulsänderung $\Delta p = 2mv_x$ (für alle $v_x > 0$) und die Gegenkraft, die die Wand aufbringen muß, ist

$$F = \frac{\Delta p}{\Delta t} = \frac{2mv_x}{\Delta t} \quad (2.144)$$

- in der Zeit Δt legt das Teilchen einen Weg $\Delta x = v_x \Delta t$ zurück, daher folgt aus (2.144) $F = \frac{2mv_x v_x}{\Delta x}$
- Division von F durch A liefert den Druck eines Teilchens in einem Volumen $\Delta V = A \Delta x$

$$\tilde{P}(v_x) = \frac{2mv_x^2}{\Delta V} \quad (2.145)$$

Beispiel 2.73 (... Fortsetzung)

- da im Gesamtvolumen V die Teilchenzahl N ist, ist $\Delta V = V/N$ und aus (2.145) folgt $\tilde{P}(v_x) = \frac{2mv_x^2}{V}N$ und der Erwartungswert des Drucks ist

$$P = \int_{v_x=0}^{\infty} \frac{2mv_x^2}{V} N f_X(v_x) dv_x = \frac{Nm}{V} \int_{-\infty}^{\infty} v_x^2 f_X(v_x) dv_x = \frac{Nm}{V} E[v_x^2] \quad (2.146)$$

- und mit (2.141) folgt die **Gleichung des idealen Gases**

$$PV = Nk_B T \quad (2.147)$$



Varianz und Kovarianz und Erwartungswert von Produkten

- Die Varianz der Summe S zweier Zufallsvariablen X und Y ergibt

$$\text{Var}[X + Y] = \text{Var}[S]$$

$$\stackrel{(2.35)}{=} E[(X + Y - E[X + Y])^2] \stackrel{(2.136)}{=} E[(X + Y - \mu_X - \mu_Y)^2]$$

$$= E\left[\left((X - \mu_X) + (Y - \mu_Y)\right)^2\right]$$

$$\stackrel{(2.138)}{=} E[(X - \mu_X)^2] + 2E[(X - \mu_X)(Y - \mu_Y)] + E[(Y - \mu_Y)^2] \quad (2.148)$$

- Der mittlere Erwartungswertterm in (2.148) wird *Kovarianz* $\text{Cov}[X, Y]$ *der Zufallsvariablen X und Y* genannt

$$\boxed{\text{Cov}[X, Y] = E[(X - \mu_X)(Y - \mu_Y)]} \quad (2.149)$$

- Damit folgt für (2.148)

$$\boxed{\text{Var}[X + Y] = \text{Var}[X] + \text{Var}[Y] + 2\text{Cov}[X, Y]} \quad (2.150)$$

- Zur Berechnung der Kovarianz (2.149) gibt es eine alternative Formel:

$$\begin{aligned}
 \text{Cov}[X, Y] &= E[(X - \mu_X)(Y - \mu_Y)] \\
 &= E[XY - \mu_Y X - \mu_X Y + \mu_X \mu_Y] \\
 &= E[XY] - \mu_Y E[X] - \mu_X E[Y] + \mu_X \mu_Y \\
 &\Rightarrow \boxed{\text{Cov}[X, Y] = E[XY] - E[X]E[Y]} \quad (2.151)
 \end{aligned}$$

- Der Erwartungswert $E[XY]$ kann im Falle *stochastischer Unabhängigkeit* von X und Y vereinfacht werden. Das wird exemplarisch für stetige Zufallsvariablen gezeigt

$$\begin{aligned}
 E[XY] &= \int_{x=-\infty}^{x=\infty} \int_{y=-\infty}^{y=\infty} xy f_{(X,Y)}(x, y) dy dx \\
 &= \int_{x=-\infty}^{x=\infty} \int_{y=-\infty}^{y=\infty} xy f_X(x) f_Y(y) dy dx \\
 &= \int_{x=-\infty}^{x=\infty} x f_X(x) dx \int_{y=-\infty}^{y=\infty} y f_Y(y) dy = E[X]E[Y] \quad (2.152)
 \end{aligned}$$

Setzt man (2.152) in (2.151) ein, sowie das Ergebnis in (2.150), so folgt:

Theorem 2.74 ((Ko)Varianz bei stochastischer Unabhängigkeit)

Es seien zwei Zufallsvariablen X und Y stochastisch unabhängig, dann gilt

$$\text{Cov}[X, Y] = 0, \quad (2.153)$$

und für die Summe $X + Y$

$$\text{Var}[X + Y] = \text{Var}[X] + \text{Var}[Y]. \quad (2.154)$$

Anmerkung 2.75 (Die Umkehrung vom Theorem 2.74 gilt nicht.)

Aus $\text{Cov}[X, Y] = 0$ kann man im allgemeinen nicht auf die stochastische Unabhängigkeit der Zufallsvariablen X und Y schließen.

Definition 2.76 (Korrelationskoeffizient)

Der *Korrelationskoeffizient* zweier Zufallsvariablen X und Y ist definiert als:

$$\rho[X, Y] := \frac{\text{Cov}[X, Y]}{\sqrt{\text{Var}[X] \text{Var}[Y]}}. \quad (2.155)$$

Anmerkungen 2.77 (Eigenschaften des Korrelationskoeffizienten)

Man kann zeigen, daß:

- ❶ $-1 \leq \rho[X, Y] \leq 1$,
- ❷ $\rho[X, Y] = 0$, falls X und Y stochastisch unabhängig sind,
- ❸ im Fall linearer Abhängigkeit der Y -Größe von X

$$Y = aX + b \quad \Rightarrow \quad \rho[X, Y] = \text{sign}(a) \quad (2.156)$$

- ❹ Zufallsgrößen mit $\rho[X, Y] > 0$ heißen **positiv korreliert**,
Zufallsgrößen mit $\rho[X, Y] < 0$ heißen **negativ korreliert**,
- ❺ im Fall der bivariaten Gaußschen Normalverteilung $(X, Y)^T \sim \mathcal{N}(\vec{\mu}, \mathbf{C})$,
PDF (2.97), liefert die Rechnung für $(\mathbf{C})_{12} = \rho\sigma_X\sigma_Y$ und daher

$$\rho = \frac{(\mathbf{C})_{12}}{\sigma_X\sigma_Y}, \quad (2.157)$$

wobei $\sigma_X = \sqrt{\text{Var}[X]} = \sqrt{(\mathbf{C})_{11}}$, $\sigma_Y = \sqrt{\text{Var}[Y]} = \sqrt{(\mathbf{C})_{22}}$.

- ❻ ρ findet häufig in der Statistik Verwendung.

Varianzen und Kovarianzen eines Zufallsvektors können in einer Matrix zusammengefaßt werden:

Definition 2.78 (Kovarianzmatrix $\mathbf{C}$ (häufig auch mit Σ symbolisiert))

Gegeben sei ein Zufallsvektor $\vec{X} = (X_1, \dots, X_n)^T$ und der Erwartungswertvektor $\vec{\mu} = E[\vec{X}] = (E[X_1], \dots, E[X_n])^T$

$$\mathbf{C} := E[(\vec{X} - \vec{\mu})(\vec{X} - \vec{\mu})^T] \quad (2.158)$$

Anmerkungen 2.79

- durch Ausmultiplizieren von (2.158) erhält man alternativ


$$\mathbf{C} = E[\vec{X}\vec{X}^T] - E[\vec{X}]E[\vec{X}]^T \quad (2.159)$$

- NB: die Produkte in (2.158) und (2.159) sind keine Skalarprodukte
- die Diagonalelemente von $\mathbf{C}$ sind die Varianzen der Komponenten X_i
- für die multivariate Normalverteilung $\vec{X} \sim \mathcal{N}(\vec{\mu}, \mathbf{C})$ kann man zeigen:
 - a) $E[\vec{X}] = \vec{\mu}$,
 - b) $E[(\vec{X} - \vec{\mu})(\vec{X} - \vec{\mu})^T] = \mathbf{C}$,
 die $\mathbf{C}$ -Matrix in (2.97) ist also in der Tat eine Kovarianzmatrix.

Die Verteilung der Summe zweier Zufallsgrößen

- Bisher haben wir nur Kenngrößen der Summe $S = X + Y$ untersucht, jetzt berechnen wir die Verteilungsfunktion $F_S(s)$. Es gilt

$$F_S(s) = P(S \leq s) = P(X + Y \leq s) = P(Y \leq s - X) \quad (2.160)$$



$$F_S(s) = \int_{x=-\infty}^{x=\infty} \int_{y=-\infty}^{y=s-x} f_{(X,Y)}(x,y) dy dx$$

Im Fall der stochastischen Unabhängigkeit $f_{(X,Y)}(x,y) = f_X(x)f_Y(y)$ kann das Doppelintegral weiter bearbeitet werden

$$F_S(s) = \int_{x=-\infty}^{x=\infty} f_X(x) \int_{y=-\infty}^{y=s-x} f_Y(y) dy dx. \quad (2.161)$$

$$F_S(s) = \int_{x=-\infty}^{x=\infty} f_X(x) F_Y(s-x) dx$$

(2.162)



- Differenziert man (2.161) oder (2.162) nach s , so erhält man die Dichtefunktion von $S = X + Y$, im Fall der *stochastischen Unabhängigkeit* von X und Y

$$f_S(s) = \int_{x=-\infty}^{x=\infty} f_X(x)f_Y(s-x) dx \quad (2.163)$$

- Integrale der Form (2.162, 2.163) werden *Faltungsintegrale* genannt.
- Im Fall diskreter Zufallsgrößen sind Doppelsummen zu berechnen

$$\begin{aligned} p_k &= P(S = s_k) = P(X + Y = s_k) \\ &= \sum_{i,j: x_i + y_j = s_k} P(X = x_i, Y = y_j) = \sum_{i,j: x_i + y_j = s_k} p_{ij} \end{aligned} \quad (2.164)$$

und

$$F_S(s) = P(S \leq s) = \sum_{i,j: x_i + y_j \leq s} P(X = x_i, Y = y_j) = \sum_{i,j: x_i + y_j \leq s} p_{ij}. \quad (2.165)$$

Vereinfachungen bei stochastischer Unabhängigkeit von X und Y hängen vom konkreten Fall ab.




Beispiel 2.80 (Dichte von 2 iid $[0, 1]$ gleichverteilten Zufallszahlen)

Anmerkung: “iid” steht für “independent and identically distributed.”

Die Summe $S = X + Y$ liegt im Intervall $[0, 2]$. Dementsprechend muß $f_S(s)$ für $s \notin [0, 2]$ null sein. Die Dichtefunktionen $f_X(x), f_Y(y)$ beider Zufallsgrößen X und Y sind konstant 1 im Intervall $[0, 1]$, **außerhalb jedoch null!** Die Dichte-funktion ergibt sich aus dem Faltungsintegral (2.163). Bei der Berechnung des Integrals ist daher sicherzustellen, daß $0 \leq s - x \leq 1$ ist. Also $x \leq s \leq 1$ oder $x \geq s - 1$ für $2 \geq s > 1$. Damit folgt

$$f_S(s) = \int_{x=-\infty}^{x=\infty} f_X(x)f_Y(s-x)dx = \begin{cases} \int_{x=0}^{x=s} 1dx, & 0 \leq s < 1, \\ \int_{x=s-1}^{x=1} 1dx, & 1 \leq s \leq 2, \\ 0, & \text{ansonsten.} \end{cases} \quad (2.166)$$

$$f_S(s) = \begin{cases} s, & 0 \leq s < 1, \\ 2 - s, & 1 \leq s \leq 2, \\ 0, & \text{ansonsten.} \end{cases} \quad (2.167)$$



Der zentrale Grenzwertsatz der Statistik

Motivation

- häufig wird die Verteilung der Summe von $n \gg 1$ (stochastisch unabhängigen) Zufallsvariablen X_i benötigt


$$S = \sum_{i=1}^n X_i \quad \xrightarrow{?} \quad F_S(s) = P(S \leq s) \quad (2.168)$$

(z.B. wenn man die Verteilung von Mittelwerten in der Statistik untersucht: $\langle X \rangle = \sum_{i=1}^n \frac{X_i}{n}$)

- technisch gesehen, ist dazu die n -fache Faltung der Wahrscheinlichkeits- bzw. Dichtefunktionen der Zufallsvariablen erforderlich (vgl. (2.162–2.165))
- manchmal kann das Ergebnis in geschlossener Form dargestellt werden; z.B. im Fall der Summe von n 0-1-Bernoulli-Experimenten (vgl. Folie 99) erhält man die Binomialverteilung (2.72) für die Summe k der Einsen:



Verteilung der Summe von n 0-1-Zufallsvariablen mit $p = P(X = 1) = 0.5$:



- Wie man sehen kann, wird mit größer werdendem n die Form der Verteilung immer Gauß-förmiger und konzentrierter.
- Man kann zeigen, daß die Verteilungsfunktion $F_{Y_n}(y) = P(Y_n \leq y)$ der Folge (Y_n) der *standardisierten* Zufallsvariablen $Y_n := \frac{\sum_{i=1}^n X_i - np}{\sqrt{np(1-p)}}$ für $n \rightarrow \infty$ gegen die Verteilungsfunktion $\Phi(y)$ der $\mathcal{N}(0, 1)$ -Verteilung konvergiert (MOIVRE-LAPLACESche Grenzwertsatz).
- Die soeben gemachte Beobachtung, basierend auf iid 0-1-Variablen, ist nur ein Beispiel für die Eigenschaft von Summen von gewissen Zufallsvariablen, wenn die Anzahl der Summanden sehr groß wird:

Das Ergebnis ist asymptotisch normalverteilt.



Theorem 2.81 (Zentraler Grenzwertsatz (der Statistik))

Es sei $(X_i)_{i=1,2,\dots}$ eine Folge von iid Zufallsvariablen X_i mit endlichem Erwartungswert $\mu = E[X_i]$ und $\sigma^2 = \text{Var}[X_i] < \infty$. Für die Summe $S_n = \sum_{i=1}^n X_i$ gilt dann ($z_1 < z_2$)

$$\lim_{n \rightarrow \infty} P \left(z_1 < \frac{S_n - n\mu}{\sqrt{n} \sigma} \leq z_2 \right) = \Phi(z_2) - \Phi(z_1), \quad (2.169)$$

wobei $\Phi(z)$ die (kumulative) Verteilungsfunktion der Standardnormalverteilung ist

$$\Phi(z) := \frac{1}{\sqrt{2\pi}} \int_{t=-\infty}^{t=z} e^{-\frac{t^2}{2}} dt. \quad (2.170)$$

Anmerkungen 2.82

- Es gibt Verallgemeinerungen des Theorems 2.81, die die Bedingung der identischen Verteilung der Zufallsvariablen fallen lassen.
- NB: Aus der Konvergenz gegen die Normalverteilungsfunktion kann **im allgemeinen nicht auf die Konvergenz gegen die Dichtefunktion $\phi(z)$ geschlossen werden.**

Beispiel 2.83

Ein lokales Kleinkraftwerk zur Versorgung eines Dorfes hat eine Nominalleistung von 400kW. Es gibt 150 Haushalte. Der durchschnittliche Bedarf pro Haushalt beträgt 2kW mit einer Standardabweichung von 4kW.

Wie wahrscheinlich ist es, daß Elektroenergie zugekauft werden muß?

Wegen des zentralen Grenzwertsatzes ist die Summe S des Leistungsbedarfs der 150 Haushalte approximativ normalverteilt mit

$$\mu_s = 150 \cdot 2\text{kW} = 300\text{kW} \text{ und } \sigma_s = \sqrt{150 \cdot 4^2}\text{kW} \approx 49\text{kW}.$$

Zur Berechnung von $P(S > 400\text{kW}) = 1 - P(S \leq 400\text{kW})$ betrachtet man $S \leq 400\text{kW}$ und geht zu den standardisierten Größen über

$$Z = \frac{S - 300\text{kW}}{49\text{kW}} \leq \frac{400\text{kW} - 300\text{kW}}{49\text{kW}} \approx 2.04.$$

Damit folgt unter Verwendung der Tabelle von Folie 89

$$P(S > 400\text{kW}) \approx 1 - \Phi(2.04) \approx 1 - 0.9793 = 0.0207$$

Exkurs in die Statistik

Motivation und Grundidee

- In den Kapiteln 1 und 2 wurden die Wahrscheinlichkeiten der Ergebnisse von Zufallsversuchen vorgegeben oder durch Symmetrieprinzipien bestimmt.
- Dabei war die Verteilung der betrachteten Zufallsgrößen als bekannt vorausgesetzt.
- In der Praxis müssen diese jedoch i.d.R. durch reale Experimente bestimmt werden.
- Das betrifft sowohl die Art der Verteilung der Zufallsgrößen als auch notwendigerweise deren Kennwerte, wie Erwartungswert, Varianz etc.
- Durch die realen Experimente werden *Daten* erhalten, die i.d.R. mit *Unsicherheiten* behaftet sind.
- ➡ Die Kennwerte müssen daher aus dem vorliegenden Datenmaterial *geschätzt* werden.
- ➡ Verlässlichkeit der Schätzungen ist dann mit Methoden der Wahrscheinlichkeitsrechnung zu beurteilen.



Damit ergeben sich u.a. die folgenden Aufgaben/Fragestellungen:

- ❶ Beschreibung der Daten = *“deskriptive Statistik”*
(auch beschreibende oder empirische Statistik)
 - ▶ Visualisierung der Daten $\Rightarrow$ Einführung in dieser LV
 - ▶ Berechnung einfacher Kennwerte der Daten $\Rightarrow$ Inhalt dieser LV
- ❷ wahrscheinlichkeits-theoretisch Analyse der Daten = *“induktive Statistik”* (auch schließende oder Inferenz-Statistik)
 - ▶ Schätzung von Verteilungsparametern $\Rightarrow$ Einführung in dieser LV
 - ▶ Bewertung der Zuverlässigkeit der Schätzungen (Konfidenz)
 $\Rightarrow$ Inhalt der LV “Statistik und Qualität”
 - ▶ Hypothesentests $\Rightarrow$ Inhalt der LV “Statistik und Qualität”
 - ▶ Aufdeckung von Korrelationen $\Rightarrow$ Einführung in dieser LV
 - ▶ Modellbildung und Vorhersage (Regression) $\Rightarrow$ Einführung in dieser LV
- ❸ explorative Statistik = *“data mining”* (hypothesengenerierende Statistik)
 - ▶ kann als Mischform von ❶ und ❷ angesehen werden
 - ▶ verwendet jedoch zusätzliche mathematisch/informatische Ansätze, hauptsächlich zur Modellbildung und Vorhersage, wie beispielsweise *Neuronale Netze, Fuzzy-Logik, Evolutionäre Algorithmen* = *“Computational Intelligence”* und andere *machine learning* Methoden
 $\Rightarrow$ Inhalt einer Vertiefungsrichtung im Master-Studium Informatik



Beschreibende Statistik

Das Wissenschaftsgebiet der Statistik ist hoch mathematisch und sehr weit entwickelt (mit sehr leistungsfähigen und komplizierten Methoden), dennoch gilt folgender Rat:

Bevor man irgend etwas mit den Daten macht, sollte man sich die Daten anschauen (z.B. graphisch darstellen).

Graphische Dateninspektion liefert wertvolle Hinweise, beispielsweise:

- mögliche Art der Verteilung der Daten
- Vorliegen von Ausreißern (Fehler in der Versuchsdurchführung etc.)
- Wahl der statistischen Methoden
- Muster und Trends in den Daten

Erste Schritte bei der Datenanalyse:

- absolute und relative Häufigkeitstabellen (vgl. Folien 75f)
- graphische Darstellungen






Graphische Darstellungen


- Histogramm
- Stamm-Blatt-Diagramm (auch stem[-and-leaf] plot)
- Boxplot (auch Box-Whisker-Plot oder Kastengrafik)
- Streudiagramm (Punktwolke, Scatter-Graphik)

Histogramm


- Darstellung der (rel.) Häufigkeiten (2.22) von N Daten in K Klassen.
- Für große N und K (Verhältnis K/N ist geeignet zu wählen) nimmt das Histogramm (mit relativer Häufigkeitsdarstellung) die Form der Wahrscheinlichkeitsfunktion bzw. Dichtefunktion an.
- Die Wahl von K bei gegebenem N ist kritisch (bei gleichen Daten):




Beispiele, mit Vermutung des Verteilungstyps:




Gleichverteilung



Exponentialverteilung



Gammaverteilung



Mischverteilung

- 1 Wie sicher kann man sein, daß die Histogramme wirklich von Daten der vermuteten Verteilungstypen stammen?
- 2 Wie bestimmt man die Verteilungsparameter (λ , α etc.)?



Stamm-Blatt-Diagramm (stem and leaf plot)

- ähnlich dem Histogramm, aber numerisch-symbolisch (enthält damit mehr Information)
- die numerischen Werte der Daten werden zerlegt:
 - 1 die ersten (ein oder zwei) Ziffern der Zahlen bilden den Stamm, diese werden gemäß ihrer Größe (aufsteigend) vertikal angeordnet aufgeschrieben
 - 2 die nächste Ziffer der Zahlen bildet die Blätter, die in entsprechender Höhe horizontal aufgeschrieben werden (diese bilden sozusagen einen Zweig)
 - 3 die Ziffern in den horizontalen Zweigen werden aufsteigend sortiert aufgeschrieben, Wiederholungen erscheinen explizit
- Beispiel: die Daten (122, 125, 125, 127, 132, 135, 153) würden wie folgt

dargestellt werden:

12		2 5 5 7
13		2 5
14		
15		3


- Anmerkung: Eine Drehung des Stamm-Blatt-Diagramms um 90° erzeugt ein histogramm-ähnliches Aussehen



Beispiel 3.1 (Lebensdauerverteilung von Energiesparlampen)

Die Lebensdauer T einer Sorte Energiesparlampen wurde an 30 Zufallsproben empirisch erhoben mit den Ergebnissen (in Monate)

$$T = (48, 53, 37, 34, 43, 18, 69, 50, 73, 127, 53, 24, 81, 35, 47, 10, 61, 82, 33, 63, 37, 27, 59, 56, 33, 38, 14, 23, 23, 30) \quad (3.1)$$



Stamm	Blätter
1	048
2	3347
3	03345778
4	378
5	03369
6	139
7	3
8	12
9	
10	
11	
12	7

Stammeinheit: 10

Die wichtigsten statistischen Maßzahlen

Definition 3.2 ((arithmetischer) Mittelwert)

Gegeben seien N Datenwerte X_i , dann ergibt sich der *Mittelwert* $\bar{X}$ der Daten gemäß

$$\bar{X} := \frac{1}{N} \sum_{i=1}^N X_i. \quad (3.2)$$

NB: $\bar{X}$ darf *nicht* mit dem Komplement eines Ereignisses verwechselt werden. Gegebenenfalls sollte die (in der Statistik jedoch unübliche) $\langle X \rangle$ Notation zur Kennzeichnung des Mittelwertes verwendet werden.

Definition 3.3 (empirische Varianz (Stichprobenvarianz))

Gegeben seien N Datenwerte X_i , dann ergibt sich die *empirische Varianz* s^2 der Daten gemäß

$$s^2 := \frac{1}{N-1} \sum_{i=1}^N (X_i - \bar{X})^2 \quad (3.3)$$

Für *Stichprobenstandardabweichung* s gilt $s = \sqrt{s^2}$.

Für die Summe in (3.3) kann man auch alternativ schreiben:

$$\sum (X_i - \bar{X})^2 = \sum X_i^2 - 2\bar{X} \sum X_i + \sum \bar{X}^2 = \sum X_i^2 - 2\bar{X}N\bar{X} + N\bar{X}^2 = \sum X_i^2 - N\bar{X}^2$$

und daher

$$s^2 = \frac{1}{N-1} \left(\sum_{i=1}^N X_i^2 - N\bar{X}^2 \right) \quad (3.4)$$

Definition 3.4 (Stichproben-Median)

Gegeben seien N Datenwerte X_i , sowie die aufsteigend sortierte Liste dieser Datenwerte $X_1^* \leq X_2^* \leq \dots \leq X_N^*$, dann ergibt sich der *Median der Stichprobe* $\tilde{X}$ der Daten gemäß

$$\tilde{X} := \begin{cases} X_{k+1}^*, & \text{falls } N = 2k + 1, \\ \frac{1}{2}(X_k^* + X_{k+1}^*), & \text{falls } N = 2k. \end{cases} \quad (3.5)$$

Gelegentlich wird auch $\mu_{1/2}$ zur Symbolisierung des Medians verwendet.

Anmerkung 3.5

- ❶ *Der Median $\tilde{X}$ einer Stichprobe teilt die Daten, so daß höchstens die Hälfte der Daten in der Stichprobe einen Wert kleiner als $\tilde{X}$ und höchstens die Hälfte der Daten einen Wert größer als $\tilde{X}$ hat.*
- ❷ *Im Fall einer geraden Anzahl von Daten wird i.d.R. der Mittelwert der geordneten Daten X^* von den Positionen $N/2$ und $N/2 + 1$ genommen.*
- ☞ *In manchen Fällen wird an Stelle von ❷ auch nur der Wert an der Positionen $N/2$ oder $N/2 + 1$ als Median (im Fall N gerade) genommen.*
- ❸ *Es gilt für:*
 - symmetrische Verteilungen $\Rightarrow \tilde{X} = \bar{X}$*
 - links-schiefe Verteilungen $\Rightarrow \tilde{X} > \bar{X}$*
 - rechts-schiefe Verteilungen $\Rightarrow \tilde{X} < \bar{X}$*

NB: Die Umkehrung gilt nicht!

- ☞ *Während der Mittelwert empfindlich gegenüber Ausreißern ist, ist der Median eine robuste Maßzahl.*

Definition 3.6 (1. und 3. Stichproben-Quartil)

Gegeben seien N Datenwerte X_i , sowie die aufsteigend sortierte Liste dieser Datenwerte $X_1^* \leq X_2^* \leq \dots \leq X_N^*$.

- Das **1. Quartil** $\tilde{Q}_1$ ist der Datenwert an der Stelle $k_1 = \lceil 0.25N \rceil$ in der sortierten Liste, also $\tilde{Q}_1 := X_{k_1}^*$
- Das **3. Quartil** $\tilde{Q}_3$ ist der Datenwert an der Stelle $k_3 = \lceil 0.75N \rceil$ in der sortierten Liste, also $\tilde{Q}_3 := X_{k_3}^*$

Definition 3.7 ((Inter-) Quartilabstand der Stichprobe)

Die Differenz des 3. und 1. Quartils stellt den Interquartilabstand $\tilde{Q}A$ dar

$$\tilde{Q}A := \tilde{Q}_3 - \tilde{Q}_1. \quad (3.6)$$

Anmerkung 3.8

Der Quartilabstand $\tilde{Q}A$ stellt ein robustes Streumaß dar.

Hingegen verhält sich die Varianz sensitive gegenüber Datenausreißern.


Visualisierung von Maßzahlen durch Box-Plots

Zum Vergleich von Zufallsverteilungen unter verschiedenen Bedingungen (z.B. Lebensdauer von Lampen in unterschiedlichen Umwelten) bietet sich die Darstellung durch Box-Plots an (dazu sind natürlich mehrere Boxen erforderlich):

Erstellung eines Box-Plots:


- ❶ Die Daten der Verteilung sind zu sortieren. Im Fall von Beispiel 3.1 wäre das die folgende Liste ($N = 30$):

$$\mathcal{T}^* = (10, 14, 18, 23, 23, 24, 27, 30, 33, 33, 34, 35, 37, 37, 38, 43, 47, 48, 50, 53, 53, 56, 59, 61, 63, 69, 73, 81, 82, 127)$$
- ❷ $\tilde{Q}_1, \tilde{X}, \tilde{Q}_3$ bilden die horizontalen Linien der Box.
- ❸ Aus $\mathcal{T}^*$ liest man ab: $\tilde{Q}_1 = 30, \tilde{Q}_3 = 59, \tilde{X} = \frac{38+43}{2}$
- ❹ Die horizontalen “Antennen” (Whisker) sind die letzten Daten, die noch im Intervall $1.5\tilde{Q}A = \pm 43.5$ unter- bzw. oberhalb der Box liegen (das sind $T = 10$ und $T = 82$).
- ❺ Ausreißer werden durch “o” dargestellt (hier 127).
- ❻ Der Mittelwert $\bar{X} = 46.0333$ wird durch “+” dargestellt.



Statistik bei zwei Merkmalen: Streudiagramm

- Gegeben seien N Datenpaare (X_i, Y_i) , dann bietet sich das **Streudiagramm** in Form von Punkten in einem x, y -Koordinatensystem an.
- Aus dem Streudiagramm können Trends oder Cluster erkannt werden.
- Mehrere Datensätze können durch unterschiedliche Symbole dargestellt werden.



Streudiagramm

Empirische Kovarianz:

- Neben den empirischen Varianzen s_X^2 und s_Y^2 für X und Y , definiert entsprechend Gl. (3.3), ist hier auch die **empirische Kovarianz s_{XY}** von Bedeutung

$$s_{XY} := \frac{1}{N-1} \sum_{i=1}^N (X_i - \bar{X})(Y_i - \bar{Y}). \quad (3.7)$$



- Gleichung (3.7) kann umgeschrieben werden auf

$$s_{XY} = \frac{1}{N-1} \left(\sum_{i=1}^N X_i Y_i - N \bar{X} \bar{Y} \right) \quad (3.8)$$

- In Analogie zu (2.155) definiert man den *empirischen Korrelationskoeffizienten*

$$r_{XY} := \frac{s_{XY}}{s_X s_Y} \quad (3.9)$$

- Für den empirischen Korrelationskoeffizienten haben die Anmerkungen 2.77, ❶–❹, von Folie 138 Gültigkeit.
- Ein Blick auf das Streudiagramm von Folie 159 läßt vermuten, daß es einen linearen Zusammenhang zwischen X und Y gibt. Das Finden der Geraden $y(x) = \hat{a}x + \hat{b}$, die die Daten am besten beschreibt, wird als *lineare Regression* bezeichnet.
- Die Bestimmung von $\hat{a}$ und $\hat{b}$ erfolgt durch **Minimierung der Summe der quadratischen Fehler** $\delta_i(a, b) := (Y_i - y(X_i))^2$, also

$$\Delta(a, b) := \sum_{i=1}^N \delta_i(a, b) = \sum_{i=1}^N (Y_i - (aX_i + b))^2 \rightarrow \min! \quad (3.10) \blacktriangleright$$


Lösung des linearen Regressionsproblems

- Mit der Standardmethode der Differentialrechnung erhält man als Lösung

$$\hat{a} = \frac{s_{XY}}{s_X^2} = r_{XY} \frac{s_Y}{s_X}, \quad \hat{b} = \bar{Y} - \frac{s_{XY}}{s_X^2} \bar{X}. \quad (3.11)$$

- Die (optimale) **Regressionsgerade** lautet damit

$$y(x) = \bar{Y} + r_{XY} \frac{s_Y}{s_X} (x - \bar{X}). \quad (3.12)$$



Induktive Statistik: Parameterschätzung

Das Schätzproblem

- In der Statistik geht es um die wahrscheinlichkeitstheoretische Charakterisierung von (beobachteten) Merkmal(en) X (Meßwerten etc.).
 - Die Charakterisierung kann aber i.d.R. nur auf der Basis einer beschränkten Anzahl von Messungen, Experimenten etc. vorgenommen werden.
 - Es werden also Aussagen über eine große Gesamtheit auf der Basis von (vergleichsweise) wenigen Beobachtungen (Stichprobe) gemacht.
- ☞ Ergebnisse sind i.d.R. *nicht* exakt (fehlerbehaftet).

Definition 3.9 (Population (Grundgesamtheit))

Eine Zufallsgröße X , die ein Merkmal X beschreibt, wird als *Grundgesamtheit* oder *Population* bezeichnet.


Definition 3.10 ((konkrete) Stichprobe)

Eine Menge von N Realisierungen $\{x_1, \dots, x_N\}$ einer Population X wird als *konkrete Stichprobe* vom Umfang N mit den *Stichprobenelementen* x_i bezeichnet.

Definition 3.11 (mathematische Stichprobe)

Die N -dimensionale Zufallsgröße $(X_1, \dots, X_N)$ mit N untereinander iid (unabhängigen und identisch verteilten) Komponenten X_i aus der Grundgesamtheit X wird als *mathematische Stichprobe* oder *Zufallsstichprobe* bezeichnet.

Aufgabe der induktiven Statistik ist es, aus den Informationen, die in der Stichprobe enthalten sind, Aussagen über die Grundgesamtheit abzuleiten:



- ➊ Schätzung der Kennwerte der Population (z.B. μ, σ^2) in Form von
 - ➊ *Punktschätzung* (konkreter Wert für μ, σ etc.)
 - ➋ *Intervallschätzung* (Intervall, das eine Kenngröße, z.B. μ , mit gewisser Wahrscheinlichkeit überdeckt)
- ➋ Überprüfung von *Hypothesen* über die Population (z.B. “stammen zwei Stichproben von derselben Grundgesamtheit?”)



Fehlerquellen

- ❶ **Stichprobenfehler** (engl. sampling errors), auch Zufallsfehler:
diese entstehen durch den Zufallsprozeß der Probennahme:
z.B. kann es beim Urnenschema mit 20% schwarzen und 80% weißen Kugeln passieren, daß die Schätzung der Wahrscheinlichkeit von schwarzen Kugeln 100% liefert, da beim Ziehen von 20 Kugeln immer nur schwarze Kugeln gezogen wurden.
- ❷ **Design-Fehler**, nichtrepräsentative Probennahme (statistische Verzerrung):
diese entstehen durch falsche Versuchsschemata oder Stichprobenauswahl oder falsche Verwendung von statistischen Methoden:
z.B. durch subjektive Auswahl der Daten, systematische Datenauswahl (z.B. Daten, die nicht zur Hypothese passen, werden unterschlagen);
Anwendung von statistischen Tests, deren wahrscheinlichkeitstheoretischen Voraussetzungen bei der konkreten Problemstellung nicht erfüllt sind etc.



Punktschätzung

Notation:

- Ein Kennwert/Parameter der Population werde mit θ gekennzeichnet.
Z.B. kann $\theta = \mu = E[X]$ der Erwartungswert sein.
- Ein **Schätzer** von θ , auch **Stichprobenfunktion** genannt, wird mit $\hat{\theta}$ gekennzeichnet.
Z.B. könnte der Mittelwert $\bar{X}$ der Stichprobe ein Schätzer sein: $\hat{\theta} = \bar{X}$.

NB: Zur Schätzung eines Parameters (= Punktschätzung) kann es verschiedene alternative Funktionen $\hat{\theta}_1(X_1, \dots, X_N), \hat{\theta}_2(X_1, \dots, X_N), \dots$ geben. Diese Funktionen werden (**Punkt-**) **Schätzfunktionen** genannt.

Beispiel 3.12 (Schätzfunktionen für den Erwartungswert)

Als mögliche Schätzfunktion für den Erwartungswert kommt sofort der Mittelwert $\hat{\theta}_1(X_1, \dots, X_N) = \bar{X}$, Gl. (3.2), in den Sinn.

Aber, auch der Stichprobenmedian $\tilde{X}$, Gl. (3.5), ist eine Alternative, also $\hat{\theta}_2(X_1, \dots, X_N) = \tilde{X}$.

Welche Schätzfunktion soll man nun nehmen?



Gewünschte Eigenschaften einer Schätzfunktion

- ➊ Konsistenz
- ➋ Erwartungstreue
- ➌ Effizienz: bestmögliche Qualität des Schätzers wird angestrebt
- ➍ Suffizienz:

Die durch die Schätzfunktion vorgenommene Transformation der N Daten der Stichprobe sollte zu keinen Verlusten von wesentlichen Information über den Parameter θ der Population führen.

Definition 3.13 (Erwartungstreue)

Eine (Punkt-) Schätzfunktion $\hat{\theta}$ wird als *erwartungstreu* (unverzerrt, engl.: *unbiased*) bezeichnet, wenn gilt:

$$E[\hat{\theta}(X_1, \dots, X_N)] = \theta. \quad (3.13)$$

Sie wird als *asymptotisch erwartungstreu* bezeichnet, wenn für wachsende Stichprobengröße N gilt:

$$\lim_{N \rightarrow \infty} E[\hat{\theta}(X_1, \dots, X_N)] = \theta. \quad (3.14)$$

Beispiel 3.14 (Mittelwert ist ein erwartungstreuer Schätzer)

Der Mittelwert (3.2) ist ein erwartungstreuer Schätzer, da:

$$E[\bar{X}] = E\left[\frac{1}{N} \sum_{i=1}^N X_i\right] = \frac{1}{N} \sum_{i=1}^N E[X_i] = \frac{1}{N} \sum_{i=1}^N \mu = \frac{1}{N} N\mu = \mu. \quad (3.15)$$

Beispiel 3.15 (Die empirische Varianz ist ein erwartungstreuer Schätzer)

Wir betrachten zunächst nur die Klammer in (3.4), es gilt

$$\begin{aligned} \sum_{i=1}^N X_i^2 - N\bar{X}^2 &= \sum_{i=1}^N X_i^2 - \frac{1}{N} \left(\sum_{i=1}^N X_i \right) \left(\sum_{k=1}^N X_k \right) \\ &= \left(1 - \frac{1}{N}\right) \sum_{i=1}^N X_i^2 - \frac{1}{N} \sum_{i=1}^N \sum_{k \neq i} X_i X_k. \end{aligned} \quad (3.16)$$

Die Erwartungswertbildung liefert für die 1. Summe in (3.16) $NE[X^2]$ und für die Doppelsumme $(N^2 - N)E[X]^2 = N(N - 1)\mu^2$. Damit folgt für (3.4)

$$E[s^2] = \frac{1}{N-1} \left(\frac{N-1}{N} NE[X^2] - (N-1)\mu^2 \right) \stackrel{(2.37)}{=} \sigma^2. \quad (3.17)$$

Anmerkungen 3.16

- ❶ *Beispiel 3.15 liefert die Erklärung für den “merkwürdigen” Nenner $N - 1$ in (3.4) an Stelle des “logisch” erscheinenden N .*
- ☞ *Würde man $1/N$ in (3.4) verwenden, wäre der Schätzer nur asymptotisch erwartungstreu.*
- ☞ *$\frac{1}{N} \sum_{i=1}^N (X_i - \mu)^2$ ist hingegen ein erwartungstreuer Varianzschätzer.*

Exemplarische Anmerkungen:

- ❷ *Ist die Grundgesamtheit normal, so ist der Median $\tilde{X}$, Gl. (3.5), ein asymptotisch erwartungstreuer Schätzer des Erwartungswertes.*
- ❸ *Der Mittelwert ist ein erwartungstreuer Schätzer für den λ Parameter der Poisson-Verteilung (2.80).*

Definition 3.17 (Konsistenz)

Eine (Punkt-) Schätzfunktion $\hat{\theta}$ wird als **konsistent** (passend) bezeichnet, wenn gilt:

$$\lim_{N \rightarrow \infty} \mathbb{P}(|\hat{\theta}(X_1, \dots, X_N) - \theta| > \epsilon) = 0. \quad (3.18)$$

Definition 3.18 (relative Effizienz (Wirksamkeit))

Die *Effizienz* bewertet die Qualität eines (erwartungstreuen) Punktschätzers $\hat{\theta}$ anhand des Erwartungswertes seiner quadratischen Abweichung vom Populationskennwert θ .

Eine (Punkt-) Schätzfunktion $\hat{\theta}_1$ wird als *effizienter* (wirksamer) als $\hat{\theta}_2$ bezeichnet, wenn gilt:

$$E[(\hat{\theta}_1 - \theta)^2] < E[(\hat{\theta}_2 - \theta)^2]. \quad (3.19)$$

Der Quotient

$$\eta := \frac{E[(\hat{\theta}_1 - \theta)^2]}{E[(\hat{\theta}_2 - \theta)^2]} \quad (3.20)$$

wird als *relative Effizienz* bezeichnet.

Ein erwartungstreuer Schätzer $\hat{\theta}$ mit der *kleinstmöglichen Varianz* $E[(\hat{\theta} - \theta)^2]$ wird als *wirksamste* (effiziente) Schätzung bezeichnet.

Gibt es systematische Methoden, um effiziente Schätzfunktionen zu finden?



Systematische Methoden zur Punktschätzung (Schätzmethoden):

1 Momentenmethode:

- ▶ Wird die Verteilung durch k Parameter beschrieben, so sind zunächst k geeignete Momente (2.38) der Verteilung empirisch zu schätzen.
- ▶ Der Zusammenhang zwischen den Verteilungsparametern und den Momenten führt auf ein (nichtlineares) Gleichungssystem mit k Unbekannten, das dann zu lösen ist.

NB: Die Methode liefert *keine* Konsistenzgarantie.

2 *Maximum-Likelihood-Schätzungsverfahren:*

- ▶ Im Fall der Schätzung eines Parameters θ hängt der Wert der Wahrscheinlichkeits- bzw. Dichtefunktion von der Realisierung X_i und dem unbekannten θ ab: $f(\theta) = p(X_i; \theta)$.
- ▶ Da die N Elemente der Stichprobe stochastisch unabhängig sind, gilt für ihre Verbunddichte (bzw. Wahrscheinlichkeit)
$$L(X_1, \dots, X_N; \theta) := \prod_{i=1}^N p(X_i; \theta).$$
- ▶ $L(\theta)$ wird als *Likelihood-Funktion* bezeichnet. Der Logarithmus von L ist bei gegebener Stichprobe bzgl. θ zu maximieren und $\hat{\theta} = \arg \max_{\theta} \ln L(\theta)$ ist der gesuchte *Maximum-Likelihood-Schätzer*.

3 Regressionsverfahren (siehe Folie 166f)

4 Spezielle Verfahren (z.B. Minimum χ^2 Methode) ...



Beispiel 3.19 (Schätzer für λ -Parameter der Poisson-Verteilung (2.80))**a) Momentenmethode:**

Aufgrund von Gl. (2.81) wissen wir, daß $\mu = E[X] = \lambda$.

Ein (erwartungstreuer) Schätzer für den Erwartungswert ist nach (3.15) der Mittelwert, daher gilt $\hat{\lambda} = \frac{1}{N} \sum_{i=1}^N X_i$.

b) Maximum-Likelihood-Methode:**1** Aufstellung der Likelihood-Funktion:

$$\begin{aligned} L(X_1, \dots, X_N; \lambda) &= \ln \left(\prod_{i=1}^N \frac{\lambda^{X_i}}{X_i!} e^{-\lambda} \right) = \sum_{i=1}^N (X_i \ln \lambda - \ln X_i! - \lambda) \\ &= \ln \lambda \sum_{i=1}^N X_i - \sum_{i=1}^N \ln X_i! - N\lambda. \end{aligned} \quad (3.21)$$

2 Partielle Ableitung nach λ , Nullsetzen und Auflösung nach λ liefert:


$$\frac{\partial}{\partial \lambda} L(\lambda) = \frac{1}{\lambda} \sum_{i=1}^N X_i - N \stackrel{!}{=} 0 \quad \implies \quad \hat{\lambda} = \frac{1}{N} \sum_{i=1}^N X_i. \quad (3.22)$$

☞ In diesem Beispiel stimmen die Resultate von a) und b) überein. Es gibt jedoch Fälle, bei denen unterschiedliche Schätzer erhalten werden.

Application Domain: Evolutionary Algorithms

Motivation and Basic Ideas

... a class of *probabilistic* optimization algorithms inspired by DARWIN:



- Inspired by natural evolution
- Species seem to be well adapted to their environments
- Driving evolution principle:

VARIATION-SELECTION-PRINCIPLE

“Survival of the fittest”

- ... widely accepted, but seldom suspected conclusion:

Darwinian Evolution = Optimization



Evolutionary Algorithms (EA)




The Optimization Problem:

Given an objective(s) or goal function(s) $F(\mathbf{y})$, find those $\mathbf{y} \in \mathcal{Y}$ that provide the largest, i.e. maximal (or smallest, i.e. minimal) F -value:

$$\mathbf{y}^* := \arg \max_{\mathbf{y} \in \mathcal{Y}} F(\mathbf{y}) \quad (4.1)$$

There are various algorithmic approaches to solve this problem.

How to Improve/Optimize Systems: The Black-Box EA Approach




- alternative to mathematical optimization techniques (“mathematical programming”)
- EA approach does not need a mathematical description of the function to be optimized
- the system to be optimized can be noisy, F can be a random variable
- EA provides usually an *approximation* of the optimizer $\mathbf{y}^*$



Example: Shape Optimization of a Nozzle⁵


Finding the shape of a super-sonic nozzle which maximizes the thrust.



- evolution with *variable* length genome
- segments (genes) can be duplicated and deleted
- diameters of apertures range from 6 to 36mm in 2mm steps, thickness of rings 1cm

⁵Example taken from I. Rechenberg: *Evolutionsstrategie'94*, Frommann-Holzboog Verlag, Stuttgart, 1994. 

- maximum length of nozzle 30cm
- more than $16^{30} \approx 10^{36}$ shapes
- Experimental setup:




(reference, see Footnote 5, Slide 174)

- result after < 300 experiments using an *Evolution Strategy (ES)*:
efficiency improvement from initially 55% to 80%



Evolutionary Dynamics and Result of Nozzel Optimization



(reference, see Footnote 5, Slide 174)



... another example for an evolutionary optimized object:

X-Band Antenna Design for an ST5 Spacecraft⁶





Abb. 4: The optimal antenna evolved (right) has a really unexpected shape.

See also http://www.nasa.gov/mission_pages/st-5/science/multiple_technologies.html.

⁶Reproduced from G.S. Hornby, J.D. Lohn, and D.S. Linden: *Computer-Automated Evolution of an X-Band Antenna for NASA's Space Technology 5 Mission*, in *Evolutionary Computation*, Vol. 19, No. 1, Pages 1-23, 2011.



... another example for an evolutionary evolved object:

Low-voltage balun circuit⁷




Abb. 5: Evolved balun circuit using Genetic Programming. Result after 84 generations. See also <http://www.genetic-programming.com/gecco2004tutorial.pdf>.

⁷Reproduced from J.R. Koza: *Introduction to Genetic Programming*. Tutorial, GECCO-2004, Seattle, 2004.



The “EA Schools”

- evolution strategy (ES)

RECHENBERG 1965, 1973, 1994; SCHWEFEL 1974, 1995,
primacy of mutation, deterministic selection

- genetic algorithms (GA)

HOLLAND 1962, 1975; GOLDBERG 1989,
primacy of recombination, proportional (stochastic) selection


- evolutionary programming (EP)

FOGEL, OWENS AND WALSH 1966; FOGEL 1992,
no recombination, tournament selection (stochastic)

- [*simulated annealing* (Kirkpatrick, Gelatt and Vecchi 1983)]
similar to $(1 + 1)$ -ES; however, stochastic time dependent selection

1. ... 3. are now part of CI (sometimes referred to as *Soft Computing*):





Introduction to Evolution Strategies

Notations

fitness function(s) (to be optimized):	$F(\mathbf{y})$
object parameter vector:	$\mathbf{y}^{(g)}, \mathbf{y} \in \mathcal{Y}$
state of optimum:	$\hat{\mathbf{y}}$
generation counter:	g
problem size (dimension):	N
nomenclature:	$(\mu/\rho \text{ } ^+ \text{ } \lambda)$
size of parent population:	μ
size of offspring population:	$\lambda \quad (\lambda \begin{smallmatrix} > \\ (=) \end{smallmatrix} \mu)$
size of family (parents):	$\rho \quad (1 \leq \rho \leq \mu)$



strategy type:

1. comma selection: $(\mu/\rho, \lambda)$
2. plus selection: $(\mu/\rho + \lambda)$

Remark for $\rho > 1$:

If $\rho > 1$ the “ μ/ρ ” expresses parental **recombination** (not considered in this introduction)

Selection in ESs


- similar to animal breeding, i.e., *truncation selection*
 - ▶ **(μ, λ) selection:** μ new parents are drawn from the offspring pool (i.e., out of λ) by picking out the best μ
(non-elitist strategy, global convergence cannot be guaranteed)
 - ▶ **$(\mu + \lambda)$ selection:** μ new parents are drawn from the offspring *and* the parents (i.e., out of $\mu + \lambda$) (elitist strategy, global convergence can be guaranteed under certain conditions)



Comma Selection: (μ, λ) , condition: $\lambda > \mu$

(no. of parents, no. of offspring)


Example: (4, 10)



Generation: g

Parents: ◇

Offspring: *



Generation: g+1


Parents: ●



Plus Selection: $(\mu + \lambda)$, condition: $\lambda \geq \mu$

(no. of parents + no. of offspring)


Example: (4+10)



Generation: g

Parents: ◇

Offspring: *



Generation: g+1


Parents: ●



Steady State Selection: $(\mu + 1)$

(no. of parents + no. of offspring)


Example: $(8+1)$



Generation: g

Parents: ◇

Offspring: *



Generation: g+1

Parents: ●



The Simplest EA: The $(1 + 1)$ -ES

- object parameter (or search) space: $\mathbf{y} \in \mathbb{R}^N$
- objective (or goal) function (to be optimized): $F(\mathbf{y})$

$(1 + 1)$ -ES-Minimization Line

$g := 0;$	1
$\text{initialize}(\mathbf{y}_p, \sigma);$	2
$F_p := F(\mathbf{y}_p);$	3
Repeat	4
$\tilde{\mathbf{y}} := \mathbf{y}_p + \sigma \mathcal{N}(\mathbf{0}, \mathbf{I});$	5
$\tilde{F} := F(\tilde{\mathbf{y}});$	6
If $\tilde{F} \leq F_p$ Then	7
$\mathbf{y}_p := \tilde{\mathbf{y}};$	8
$F_p := \tilde{F}$	9
End;	10
$g := g + 1;$	11
Until stop_condition	12

- L5: normal distribution $\mathcal{N}$ “mimics” that small changes are more likely (or observed in nature) than larger
- L5: other mutation types (examples):
 - ▶ non-isotropic Gaussian in $\mathbb{R}^N$
 - ▶ two-point distribution in $\mathbb{B}^\ell$
 - ▶ “move operators” for combinatorial problems (e.g. Lin- k -Opt)
- L7: $(1 + 1)$ -selection
- L12: Stopping by:
 - ▶ number of generations
 - ▶ change of F_p -values
 - ▶ change of $\mathbf{y}_p$ -values
 - ▶ change of endogenous strategy parameters (e.g. σ)



Mathematica Implementation of $(1 + 1)$ -ES *without* σ -Adaptation

```

f[y_] := Dot[y,y]                                (* function to be minimized *)

n = 10                                             (* search space dimension *)
sigma = 1                                         (* mutation strength *)
maxGen = 1000                                    (* max. number of generations *)
yu = -10; yo = 10;                               (* search space bounds *)
yParent = Table[Random[Real, {yu, yo}], {n}]      (* initial guess *)
fitnessParent = f[yParent]                       (* fitness of initial guess *)
fitnessDynamics = {fitnessParent}                (* for recording the best fitness dynamics *)

(* HERE STARTS (1+1)-ES EVOLUTION LOOP *)
Do[ yOffspring = yParent                         (* mutate parent to get offspring *)
    + sigma*Table[Random[NormalDistribution[0, 1]], {n}];
    fitnessOffspring = f[yOffspring];             (* offspring fitness *)
    If[ fitnessOffspring <= fitnessParent,        (* offspring becomes parent *)
        yParent = yOffspring;
        fitnessParent = fitnessOffspring ];
    fitnessDynamics = Append[fitnessDynamics, fitnessParent], (* record best f values *)
    {maxGen} ]                                    (* run evolution for maxGen generations *)

(* END OF (1+1)-ES *)

ListLogPlot[ fitnessDynamics, AxesLabel -> {"g", "f"},
    Joined -> True, PlotRange -> All ]          (* display best fitness dynamics *)

```



Theoretical result:

The $(1 + 1)$ -ES is for $\sigma = \text{const.} > 0$ globally convergent, i.e.:


$$\lim_{g \rightarrow \infty} \mathbb{P} \left(|F(\mathbf{y}^{(g)}) - F(\hat{\mathbf{y}})| < \varepsilon \right) = 1, \quad \varepsilon > 0 \quad (4.2)$$

However, consider the dynamical behavior of the $(1 + 1)$ -ES with $\sigma = \text{const.}$:

Using the simple goal function:

$$F(\mathbf{y}) = \sum_{i=1}^N y_i^2, \Rightarrow \min F = 0 \quad (4.3)$$

with $N = 10$ and $\sigma = 1$, $y_i^{(0)} = 10$.
Equation (4.3) is the “sphere model.”



Observation:


Although the $(1 + 1)$ -ES with $\sigma = \text{const.}$ is proveably global convergent, it gets stuck after a certain time.

What is the reason for this behavior?




The Discovery of the “Evolution Window”

There is only a small bandwidth of mutation strength in which the evolution exhibits positive progress.



Progress rate and evolution window for the sphere model



On the explanation of the evolution window (no symmetrical fitness)



Necessity of σ -Control

- ☞ Due to the existence of an evolution window, the mutation strength σ must be controlled.

Techniques:

- statistical inference methods
 - 1 1/5-rule
 - 2 cumulative step size adaptation
- evolutionary approach
 - 1 self-adaptation
 - 2 Meta-ES



ES with Self-adaptation (Basic Ideas)

- necessity of controlling the mutation strength
- basic idea of self-adaptation:
 - ▶ each individual comprises a set of object parameters **and** a set of *endogenous (i.e. evolvable) strategy parameters*
 - ▶ the endogenous strategy parameters are subject to mutation (and perhaps recombination)
 - ▶ these mutated strategy parameters control the variation of the individual's object parameter set
 - ▶ the endogenous strategy parameters are inherited **together** with the object parameters, thus they have a higher probability to survive when they provide variations that produce (on average) fitter object parameters
 - ▶ simplest version: $(1, \lambda)$ - σ SA-ES



The Simplest Self-Adaptive ES: $(1, \lambda)$ - σ SA-ES

<u>$(1, \lambda)$-σSA-ES</u>	line
$g := 0;$	1
$\text{initialize}(\mathbf{y}^{(0)}, \sigma^{(0)})$	2
Repeat	3
For $l := 1$ To λ Do	4
$\tilde{\sigma}_l^{(g)} := \xi_l \sigma^{(g)};$	5
$\tilde{\mathbf{y}}_l^{(g)} := \mathbf{y}^{(g)} + \tilde{\sigma}_l^{(g)} \mathcal{N}(\mathbf{0}, \mathbf{I});$	6
$\tilde{F}_l^{(g)} := F(\tilde{\mathbf{y}}_l^{(g)})$	7
End;	8
$\sigma^{(g+1)} := \tilde{\sigma}_{1;\lambda}^{(g)};$	9
$\mathbf{y}^{(g+1)} := \tilde{\mathbf{y}}_{1;\lambda}^{(g)};$	10
$g := g + 1;$	11
Until stop_condition	12

- L5: *multiplicative* mutation using special random variates (see next slide)
- L9f: selection is done by taking the values of the *best* offspring



How to mutate the mutation strength σ

- mutation of σ is by *multiplication* with ξ
- ξ should allow for increase as well as decrease of the σ values
- ξ_l is a random number with $\boxed{E[\xi] \approx 1}$

There are different variants for choosing the random multiplier ξ :

- ❶ Log-Normal mutation:

$$\xi := e^{\tau \mathcal{N}(0,1)}, \quad \tau = 0.2, \dots, 0.5^8 \quad (4.4)$$

- ❷ Two-point mutation:

$$\xi := \begin{cases} 1 + \beta, & \text{if } u(0,1] \leq 1/2 \\ \frac{1}{1 + \beta}, & \text{if } u(0,1] > 1/2 \end{cases}, \quad \beta = 0.2, \dots, 0.5^9 \quad (4.5)$$

⁸Alternatively one may choose $\tau \propto 1/\sqrt{N}$.

⁹Alternatively one may choose $\beta \propto 1/\sqrt{N}$.



Mathematica Implementation: $(1, \lambda)$ - σ SA-ES

```

f[y_] := Dot[y,y] (* function to be minimized *)

n = 10 (* search space dimension *)
tau = 1/Sqrt[n] (* learning parameter *)
lambda = 10 (* offspring population size *)
sigmaParent = 1 (* initial mutation strength *)
maxGen = 200 (* max. number of generations *)
yParent = Table[Random[Real, {-10, 10}], {n}] (* initial guess *)
fitnessDynamics = {f[yParent]} (* for recording the fitness dynamics *)


(* BEGIN OF (1,lambda)-ES LOOP *)
Do[ offspringPopulation = Table[
  ( offspring = {{}, {}, {}}; (* comprises: fitness, y-vector, and mutation strenght *)
    offspring[[3]] = Exp[tau*Random[NormalDistribution[0, 1]]]*sigmaParent; (* line 5 *)
    offspring[[2]] = yParent
      + offspring[[3]]*Table[Random[NormalDistribution[0, 1]], {n}]; (* line 6 *)
    offspring[[1]] = f[offspring[[2]]]; (* line 7 *)
    offspring ], {lambda} ];
{fitnessParent, yParent, sigmaParent} = Sort[offspringPopulation][[1]]; (* line 9, 10 *)
fitnessDynamics = Append[fitnessDynamics, fitnessParent], (* record best f *)
{maxGen} ] (* run evolution for maxGen generations *)

(* END OF (1,lambda)-sigmaSA-ES *)

ListLogPlot[ fitnessDynamics, AxesLabel -> {"g", "f"},
  Joined -> True, PlotRange -> All ] (* display best fitness dynamics *)

```





Observation:

Unlike the $(1 + 1)$ -ES with $\sigma = \text{const.}$ on Slide 188 the $(1, \lambda)$ - σ SA-ES permanently reduces the distance to the optimum.

The $(1, \lambda)$ - σ SA-ES exhibits *linear convergence*.



Genetic Algorithms (GA)

Characterization

- population size: μ (considered to be even here, but not stringent)
- individual m : X_m – bit string of length ℓ

$$X := x_1 x_2 \cdots x_\ell, \quad x_l \in \mathbb{B}, \quad \mathbb{B} = \{0, 1\} \quad (4.6)$$

- biological metaphor:
 - ▶ bit position $x_i \hat{=}$ “gene” (two alleles $\{0, 1\}$)
 - ▶ bit string $X_m \hat{=}$ chromosome $\hat{=}$ genotype
 - ▶ $\Pi = (X_1, \dots, X_\mu) \hat{=}$ population $\hat{=}$ gene pool
- almost always binary representation used, i.e. *not* problem specific
- ➔ • genotype-phenotype-mapping: $X_m \mapsto \mathbf{y}_m, \quad \mathbf{y}_m \in \mathbb{R}^N, \mathbb{Z}^N \dots$



- genotype-phenotype-mapping analogy:

genotype (DNA)	$\mapsto$	amino acids	$\mapsto$	phenotype
bit string X	$\mapsto$	parameter vector $\mathbf{y}$	$\mapsto$	fitness ϕ

- fitness: $\phi_m := \phi[F(\mathbf{y}_m)] = \phi(X_m) \stackrel{!}{>} 0, \quad \phi \rightarrow \max!$
($\phi > 0$ is only required for fitness proportional selection)
- selection: fitness proportional (originally in canonical GA)
 ☞ *roulette wheel selection*
 nowadays, tournament selection etc. are used
- recombination: crossover with probability $p_c = 0.6 \dots 1.0$
 usually considered as the main search operator
- mutation: random bit flips with probability p_m for a bit inversion
 in a string of length ℓ : $p_m = 1/1000$; better: $p_m = 1/\ell$;
 in “orthodox” GA usually a “background” operator



The Standard GA (sGA, aka canonical GA, or simple GA))

Genotype-Phenotype-Mapping

example: $\mathbb{R}^N \Rightarrow \ell = N \cdot L$
 i.e. L bits for each real-valued component

search domain: $\mathbf{y} \in [y_1^{\text{Lo}}, y_1^{\text{Up}}] \times [y_2^{\text{Lo}}, y_2^{\text{Up}}] \times \dots \times [y_N^{\text{Lo}}, y_N^{\text{Up}}]$

mapping: $X_m \mapsto \mathbf{y}_m, \quad \phi(X_m) := F(\mathbf{y}(X_m))$
 $\mathbf{y} = (y_1(X), y_2(X), \dots, y_N(X))^T$

usually:

bit string $x_1 \dots x_L \mapsto$ **integer** $I \mapsto$ **real** y



1. Binary code: $I_B := \sum_{i=1}^L x_i 2^{L-i}$

$$y_k := y_k^{\text{Lo}} + \frac{y_k^{\text{Up}} - y_k^{\text{Lo}}}{2^L - 1} \sum_{i=(k-1)L+1}^{kL} x_i 2^{kL-i} \quad (4.7)$$

2. Gray code: $I_G := \sum_{i=1}^L \left(\bigoplus_{j=i}^L x_j \right) 2^{i-1}$

$$y_k := y_k^{\text{Lo}} + \frac{y_k^{\text{Up}} - y_k^{\text{Lo}}}{2^L - 1} \sum_{i=(k-1)L+1}^{kL} \left(\bigoplus_{j=i}^{kL} x_j \right) 2^{i-(k-1)L-1}$$

$x_i \oplus x_j$ is XOR (exclusive OR), i.e., addition modulo 2:

$$x_i \oplus x_j = (x_i + x_j) \bmod 2$$



Comparison: Binary vs. Gray coded, $L = 4$

X $x_1 x_2 x_3 x_4$	binary $2^0 2^1 2^2 2^3$	Hamming distance D	Gray coded
0 0 0 0	0		0
0 0 0 1	1	1	15
0 0 1 0	2	1	7
0 0 1 1	3	1	8
0 1 0 0	4	3	3
0 1 0 1	5	1	12
0 1 1 0	6	2	4
0 1 1 1	7	1	11
1 0 0 0	8	4	1
1 0 0 1	9	1	14
1 0 1 0	10	2	6
1 0 1 1	11	1	9
1 1 0 0	12	3	2
1 1 0 1	13	1	13
1 1 1 0	14	2	5
1 1 1 1	15	1	10

Hamming distances D=1

Hamming distances D=1

- Note, for Gray code: $D(I, I + 1) = 1$
- Gray avoids partially “Hamming cliffs” $\Rightarrow$ better performance



Simple GA [with tournament selection]	line
initialize(μ, ℓ); $p_c := 0.8$; $p_m := 1/\ell$;	1
For $i := 1$ To μ Do initialize(X_i);	2
$g := 0$;	3
Repeat	4
For $i := 1$ To μ Step 2 Do	5
$V := \text{Select}(X_1, \dots, X_\mu)$;	6
$W := \text{Select}(X_1, \dots, X_\mu)$;	7
If $u[0, 1) < p_c$ Then $(\tilde{X}_i, \tilde{X}_{i+1}) := \text{Crossover}(V, W)$	8
Else $(\tilde{X}_i, \tilde{X}_{i+1}) := (V, W)$;	9
End ;	10
For $i := 1$ To μ Do $X_i := \text{Mutation}(\tilde{X}_i, p_m)$;	11
$g := g + 1$;	12
Until stop_condition	13



Recombination by Crossover (XO, CO)

- believed to be the main search operator producing new variants
 - ➡ mutations are only used to re-introduce lost alleles
- unproven working mechanism: XO combines good partial solutions
- central “GA dogma”:


YOU HAVE TO RECOMBINE!

- various recombination operators:
 - ▶ one-, two-, and k -point, and uniform crossover
 - ▶ crossover operators for combinatorial problems:
PMX (partially matched CO), OX (ordered CO), CX (cycle CO)
 - ▶ more general mixing operators similar to ES:
uniform scanning, diagonal scanning, occurrence-based CO



Crossover

one-point



parent V


parent W

crossover points
random positions

offspring $\tilde{X}_i$

offspring $\tilde{X}_{i+1}$

two-point



generalization: k -point crossover



```
BinaryTournamentSelection[Population_] :=  
Module[{popSize, individual1, individual2},  
    popSize = Dimensions[Population][[1]]; (* determine population size *)  
    individual1 = Population[[Random[Integer, {1,popSize}]]]; (* pick an individual randomly *)  
    individual2 = Population[[Random[Integer, {1,popSize}]]]; (* pick a 2. individual randomly *)  
    If[f[individual1] < f[individual2], individual1, individual2 ]] (* return the better one *)  
  
Mutation[individual_, pm_] := (* note, this is not a very efficient implementation *)  
Module[{stringLength, mutVector},  
    stringLength = Dimensions[individual][[1]]; (* determine length of bit string *)  
    mutVector = Table[If[Random[] < pm, 1, 0], {stringLength}]; (* determine random positions *)  
    Mod[individual + mutVector, 2]] (* flip those bits where mutVector == 1 *)  
  
OnePointCO[individual1_, individual2_] :=  
Module[{stringLength, copoint, offspring1, offspring2},  
    stringLength = Dimensions[individual1][[1]]; (* determine length of bit string *)  
    copoint = Random[Integer, {1, stringLength-1}]; (* determine crossover point (randomly) *)  
    offspring1 = Join[Take[individual1, copoint], Take[individual2, {copoint+1, stringLength}]];  
    offspring2 = Join[Take[individual2, copoint], Take[individual1, {copoint+1, stringLength}]];  
    {offspring1, offspring2}] (* crossover takes 2 strands and produces two strands *)
```

Example-specific Stuff:

```
fhvtarget = {0,0,0,0,0,1,1,1,0,0,0,0,0,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,  
            1,1,1,1,1,1,1,1,1,0,0,0,0,0,1,1,1,1,0,0,0,0,0,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,  
            1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1}  
{height,width}={11,9}  
dissimilarity[x_, target_] := Dot[x-target,x-target]  
  
f[x_]:= dissimilarity[x,fhvtarget] (* function to be minimized *)
```

Implementation continued:

Simple GA with Tournament Selection

```

(* INITIALIZATION *)

ell = Dimensions[fhvtarget][[1]]          (* bit string length *)
mu = 2*50                                (* mu should be even *)
pc = 0.8                                  (* crossover probability *)
pm = 0.2/ell                              (* bit flipping probability *)
maxGen = 100                              (* max. number of generations *)

xParentPop = Table[Table[Random[Integer, {0,1}], {ell}], {mu}];      (* initialize population *)
xOffspringPop = Table[0, {mu}, {ell}];      (* allocate space for offspring population *)
bestFitnessDynamics = {};                  (* for recording the best population fitness *)

(* BEGIN OF GA LOOP *)


Do[ For[ i=1, i < mu-1, i=i+2,              (* generate offspring by *)
  v = BinaryTournamentSelection[xParentPop];  (* taking the best of 2 randomly chosen *)
  w = BinaryTournamentSelection[xParentPop];  (* parents, do this 2 times to get two *)
  If[ Random[] < pc,
    {xOffspringPop[[i]], xOffspringPop[[i+1]]} = OnePointCO[v, w],  (* make crossover *)
    {xOffspringPop[[i]], xOffspringPop[[i+1]]} = {v, w} ] ];          (* or simple copy *)
  For[ i=1, i <= mu, i++, xParentPop[[i]] = Mutation[ xOffspringPop[[i]], pm ] ];  (* mutate *)
  evaluation = Sort[ Table[{f[xParentPop[[i]]], xParentPop[[i]]}, {i, 1, mu} ] ];  (*for output*)
  bestFitnessDynamics = Append[ bestFitnessDynamics, evaluation[[1, 1]] ];      (* for output *)
  ListDensityPlot[ Table[-evaluation[[1,2]][[width*i+j]], {i,height-1,0,-1}, {j,1,width}],
    InterpolationOrder -> 0]
, {maxGen} ]                                (* run evolution for maxGen generations *)

(* END OF GA LOOP *)

ListPlot[ bestFitnessDynamics, AxesLabel -> {"g", "f"},
  Joined -> True, PlotRange -> All ]        (* display best fitness dynamics *)



```





⇐ initial pattern

final pattern ⇒



Evolution dynamics of the pattern matching error of the **mimicry experiment**.

If You Are Interested in this Stuff, You May Consider the Master Program in Computer Science at FHV

