

Offene Untersuchung

Michael Geuze

2024-05-20

C-1

```
lorenzkurve <- function(Ressource.vec, Proz, Titel, XLabel, YLabel)
{
  # Ressource.vec ... Vektor, der die Urliste enthält, z.B. c(a1, a2, a3, a4,...)
  # Proz ... Intervall für die Prozentschritte auf der x-Achse, z.B. 0.2
  # Titel ... Diagrammüberschrift
  # XLabel ... x-Achsen-Beschriftung
  # YLabel ... y-Achsen-Beschriftung

  Ressource.vec[Ressource.vec < 0] <- 0 # setze alle negativen Einträge auf Null
  Len <- length(Ressource.vec)
  Anteil.vec <- 1:Len / Len
  Ressource.vec <- Ressource.vec[order(Ressource.vec)]
  Ressource.vec <- cumsum(Ressource.vec)
  Ressource.vec <- Ressource.vec / Ressource.vec[Len]

  Schrittw <- round(Len * Proz) #Anz. der Felder/Indizes pro Schritt
  AnzLoop <- floor(Len / Schrittw) - 1 #letzter Loop wird gesondert mit angepasster Länge au
  sgeführt
  Schritt0 <- Len - Schrittw * AnzLoop #Anz. der Felder/Indizes für letzten Schritt

  X.vec <- rep(0,AnzLoop+2)
  Y.vec <- X.vec

  for(i in 1:AnzLoop)
  {
    Idx <- i * Schrittw
    X.vec[i+1] <- Anteil.vec[Idx]
    Y.vec[i+1] <- Ressource.vec[Idx]
  }
  X.vec[AnzLoop+2] <- Anteil.vec[Len]
  Y.vec[AnzLoop+2] <- Ressource.vec[Len]

  plot(X.vec, Y.vec, main=Titel, xlab=XLabel, ylab=YLabel, type="l", col="blue")
  points(X.vec,Y.vec)
  lines(c(0,1), c(0,1), lty="dashed")
}

umsätze.df <- read.csv("Unternehmensumsaetze.csv", sep=";", dec=",", header=TRUE)
attach(umsätze.df)

cat("Verteilung der Unternehmen auf das jeweilige Land")
```


```
## Verteilung der Unternehmen auf das jeweilige Land
```

```
land.t <- table(Land); land.t
```

```
## Land
##      Brasilien      Deutschland      Frankreich      Grossbritannien
##           1           10           9           3
##      Indien      Italien      Japan      Malaysia
##           2           4           8           1
##      Mexiko      Niederlande      Norwegen      Russland
##           1           2           1           3
##      Schweiz      Spanien      Suedkorea      Taiwan
##           2           1           2           1
##      Thailand      USA      Venezuela Volksrepublik China
##           1           31           1           13
```

```
par(mar = c(9, 4, 4, 2) + 0.1)
par(las=2, cex=.8)
barplot(sort(land.t,decreasing = TRUE),
        ylab = "Anzahl der Unternehmen",
        main = "Anazhl der Unternehmen pro Land",
        ylim = c(0,35)
        )
```

Anazhl der Unternehmen pro Land



```
cat("Verteilung der Unternehmen auf die jeweilige Branche")
```


```
## Verteilung der Unternehmen auf die jeweilige Branche
```

```
branche.t <- table(Branche); branche.t
```

```
## Branche
##
##          Automobile      Automotive Telecom, IT & Tourismus
##          9              1
##          Banken          Bauhauptgewerbe
##          15              1
##          Chemie          Einzelhandel
##          1              6
##          Eisenbahnbau    Finanzdienstleister
##          2              2
##          Flugzeugbau      Grosshandel
##          1              1
##          Informationstechnik  Konsumgueter
##          1              2
## Logistik, Bankwesen, Versicherungswesen  Mischkonzern
##          1              3
##          Nahrungsmittel    Oel und Gas
##          2              22
##          Pharmahandel      Pharmazie
##          3              1
##          Rohstoffhandel    Technologie
##          2              6
##          Telekommunikation Versicherungen
##          5              5
##          Versorger
##          5
```

```
par(mar = c(8, 4, 4, 2) + 0.1)
par(las=2, cex=.7)
barplot(sort(branche.t,decreasing = TRUE),
        ylab = "Anzahl der Branchen",
        main = "Anazhl der Branchen pro Land",
        ylim = c(0,25)
        )
```

Anzahl der Branchen pro Land



```
cat("Unlesbare Branchentitel in der obigen Abbildung: \"Automotive Telecom, IT & Tourismus\" und \"Logistik, Bankwesen, Versicherungswesen\"")
```

```
## Unlesbare Branchentitel in der obigen Abbildung: "Automotive Telecom, IT & Tourismus" und "Logistik, Bankwesen, Versicherungswesen"
```

Tabelle der Länder, Summierte Umsätze, Gewinne und Mitarbeiter. Nach Gewinnen sortiert.

```
library(dplyr)
```

```
##
## Attache Paket: 'dplyr'
```

```
## Die folgenden Objekte sind maskiert von 'package:stats':
##
## filter, lag
```

```
## Die folgenden Objekte sind maskiert von 'package:base':
##
## intersect, setdiff, setequal, union
```

```

aggregated_df <- umsätze.df %>%
  group_by(Land) %>%
  summarise(
    umsatz_summe = sum(Umsatz, na.rm = TRUE),
    gewinn_summe = sum(Gewinn, na.rm = TRUE),
    mitarbeiter_summe = sum(Mitarbeiter, na.rm = TRUE)
  )

sorted_df <- aggregated_df %>%
  arrange(desc(gewinn_summe))
sorted_df

```

```

## # A tibble: 20 × 4
##   Land                umsatz_summe gewinn_summe mitarbeiter_summe
##   <chr>                <dbl>         <dbl>         <int>
## 1 USA                  4409.          457.          6906124
## 2 Volksrepublik China  2330.          165.          6677234
## 3 Russland             401.           60.7          709884
## 4 Deutschland         1271.           57.1          2225811
## 5 Grossbritannien      597.           41.2          795472
## 6 Japan               1030.           36.3          1514714
## 7 Suedkorea            311.           27.5          365287
## 8 Frankreich          1079.           24.2          1725527
## 9 Niederlande          574.           22.4          194419
## 10 Malaysia            101.           17.2           43860
## 11 Italien              527.           16.5          509503
## 12 Venezuela            121            12.9           91949
## 13 Brasilien            141.           11.1           81918
## 14 Indien               185.           10.1          696198
## 15 Norwegen             108.            6.8           31715
## 16 Spanien              98.5            5.8           193349
## 17 Taiwan               133.            3.6          1232000
## 18 Schweiz              332.            3.40          386000
## 19 Thailand              92.5            3.08           18240
## 20 Mexiko              125.           -7.36          150884

```

Die 10 Unternehmen mit den höchsten Gewinnen

```

top_10_companies <- umsätze.df %>%
  arrange(desc(Gewinn)) %>%
  head(10)
top_10_companies

```


##	Rang	Name	Hauptsitz	Land	Umsatz
## 1	37	Fannie Mae	Washington, D.C.	USA	125.700
## 2	96	Freddie Mac	Tysons Corner	USA	81.200
## 3	25	ICBC	Peking	Volksrepublik China	148.800
## 4	15	Apple	Cupertino	USA	170.910
## 5	17	Gazprom	Moskau	Russland	165.016
## 6	38	China Construction Bank	Peking	Volksrepublik China	125.400
## 7	5	ExxonMobil	Irving	USA	407.666
## 8	13	Samsung Electronics	Seoul	Suedkorea	208.838
## 9	47	Agricultural Bank of China	Peking	Volksrepublik China	115.400
## 10	6	BP	London	Grossbritannien	396.217
##	Gewinn	Mitarbeiter	Branche	Geschaeftsfuehrer	
## 1	83.900	7000	Banken	Timothy Mayopoulos	
## 2	48.700	4890	Banken	Donald Layton	
## 3	42.700	408859	Banken	Yang Kaisheng	
## 4	37.037	63300	Technologie	Tim Cook	
## 5	35.769	401000	Oel und Gas	Alexei Miller	
## 6	34.900	329438	Banken	Wang Hongzhang	
## 7	32.580	99100	Oel und Gas	Rex Tillerson	
## 8	27.245	307000	Technologie	Kwon Oh-hyun	
## 9	27.000	447401	Banken	Jiang Chaoliang	
## 10	23.451	83400	Oel und Gas	Robert Dudley	

```

par(mar = c(13, 4, 4, 2) + 0.1)
par(las = 2, cex = 0.7)
sorted_df <- umsätze.df %>%
  arrange(desc(Umsatz))
barplot(height = sorted_df$Umsatz , names.arg = sorted_df$Name, ylim= c(0,500), ylab="Umsatz
in Mrd. USD", main = "Unternehmensumsätze")

```

Unternehmensumsätze




Branchen nach Gewinn sortiert

```
aggregated_df <- umsätze.df %>%
  group_by(Branche) %>%
  summarise(
    umsatz_summe = sum(Umsatz, na.rm = TRUE),
    gewinn_summe = sum(Gewinn, na.rm = TRUE),
    mitarbeiter_summe = sum(Mitarbeiter, na.rm = TRUE)

  ) %>%
  arrange(desc(gewinn_summe))
aggregated_df
```

```
## # A tibble: 23 × 4
##   Branche                umsatz_summe gewinn_summe mitarbeiter_summe
##   <chr>                  <dbl>         <dbl>             <int>
## 1 Banken                1649.          342.             3504510
## 2 Oel und Gas           4433.          258.             4444533
## 3 Technologie           827.           81.2             2635440
## 4 Automobile           1384.           69.3             2258454
## 5 Telekommunikation     546.           45.9             1119484
## 6 Mischkonzern          430.           32.8              630145
## 7 Einzelhandel          1012.           27.3             3648531
## 8 Versicherungen        555.           26.1              536141
## 9 Pharmazie             105.           17.1               30215
## 10 Informationstechnik   99.8           16.5              431212
## # i 13 more rows
```

```
par(mar = c(8, 4, 4, 2) + 0.1)
par(las = 2, cex = 0.7)
barplot(height = aggregated_df$gewinn_summe , names.arg = aggregated_df$Branche, ylim= c(0,400), ylab="Gewinn in Mrd. USD", main = "Branchengewinne")
```



So werden die größten Gewinne in den Branchen Banken, Oel und Gas und Technologie erzielt.

Branchen nach Umsatz sortiert


```
aggregated_df <- umsätze.df %>%
  group_by(Branche) %>%
  summarise(
    umsatz_summe = sum(Umsatz, na.rm = TRUE),
    gewinn_summe = sum(Gewinn, na.rm = TRUE),
    mitarbeiter_summe = sum(Mitarbeiter, na.rm = TRUE)

  ) %>%
  arrange(desc(umsatz_summe))
aggregated_df
```

```
## # A tibble: 23 × 4
##   Branche      umsatz_summe gewinn_summe mitarbeiter_summe
##   <chr>          <dbl>         <dbl>          <int>
## 1 Oel und Gas      4433.         258.         4444533
## 2 Banken          1649.         342.         3504510
## 3 Automobile      1384.          69.3         2258454
## 4 Einzelhandel     1012.          27.3         3648531
## 5 Technologie       827.          81.2         2635440
## 6 Versorger        822.           7.49         2133720
## 7 Versicherungen    555.          26.1          536141
## 8 Telekommunikation 546.          45.9         1119484
## 9 Mischkonzern      430.          32.8          630145
## 10 Rohstoffhandel   331.          -7.16          72000
## # i 13 more rows
```

```
par(mar = c(8, 4, 4, 2) + 0.1)
par(las = 2, cex = 0.7)
barplot(height = aggregated_df$umsatz_summe , names.arg = aggregated_df$Branche, ylim= c(0,5000), ylab="Umsatz in Mrd. USD", main = "Branchenumsätze")
```

Branchenumsätze



Gewinne pro Mitarbeiter

```

aggregated_df <- umsätze.df %>%
  group_by(Branche) %>%
  summarise(
    umsatz_summe = sum(Umsatz, na.rm = TRUE),
    gewinn_summe = sum(Gewinn, na.rm = TRUE),
    mitarbeiter_summe = sum(Mitarbeiter, na.rm = TRUE)
  ) %>%
  mutate(gewinn_pro_mitarbeiter_millionen_USD = gewinn_summe / mitarbeiter_summe * 1000) %>%
  arrange(desc(gewinn_pro_mitarbeiter_millionen_USD))
aggregated_df

```

```

## # A tibble: 23 × 5
##   Branche      umsatz_summe gewinn_summe mitarbeiter_summe gewinn_pro_mitarbeit...1
##   <chr>          <dbl>         <dbl>          <int>          <dbl>
## 1 Pharmazie      105.           17.1           30215          0.566
## 2 Banken        1649.          342.          3504510        0.0977
## 3 Oel und G...  4433.          258.          4444533        0.0580
## 4 Chemie         98.2           6.4           111141         0.0576
## 5 Mischkonz...   430.           32.8           630145         0.0520
## 6 Versicher...   555.           26.1           536141         0.0486
## 7 Logistik,...   152.            4.78          110000         0.0435
## 8 Telekommu...   546.           45.9          1119484         0.0410
## 9 Informati...   99.8           16.5           431212         0.0383
## 10 Nahrungsm...  189.           12.1           358700         0.0337
## # i 13 more rows
## # i abbreviated name: 1gewinn_pro_mitarbeiter_millionen_USD


```

```

par(mar = c(8, 4, 4, 2) + 0.1)
par(las = 2, cex = 0.7)
barplot(height = aggregated_df$gewinn_pro_mitarbeiter_millionen_USD , names.arg = aggregated_
df$Branche, ylim= c(0,0.6), ylab="Gewinn pro Mitarbeiter in Millionen USD", main = "Gewinne
pro Mitarbeiter")

```

Gewinne pro Mitarbeiter



In der Sparte Gewinn pro Mitarbeiter liegt die Pharmazie an erster Stelle.

Branchenumsätze pro Mitarbeiter


```

aggregated_df <- umsätze.df %>%
  group_by(Branche) %>%
  summarise(
    umsatz_summe = sum(Umsatz, na.rm = TRUE),
    gewinn_summe = sum(Gewinn, na.rm = TRUE),
    mitarbeiter_summe = sum(Mitarbeiter, na.rm = TRUE)
  ) %>%
  mutate(umsatz_pro_mitarbeiter_mrd_USD = umsatz_summe / mitarbeiter_summe) %>%
  arrange(desc(umsatz_pro_mitarbeiter_mrd_USD))
aggregated_df

```

```
## # A tibble: 23 × 5
##   Branche      umsatz_summe gewinn_summe mitarbeiter_summe umsatz_pro_mitarbeit...1
##   <chr>      <dbl>      <dbl>      <int>      <dbl>
## 1 Rohstoffh...    331.      -7.16      72000      0.00459
## 2 Pharmahan...    328.       2.07     79450      0.00413
## 3 Pharmazie     105.      17.1      30215      0.00346
## 4 Logistik,...    152.       4.78     110000     0.00138
## 5 Versicher...    555.      26.1     536141     0.00103
## 6 Oel und G...  4433.     258.    4444533     0.000997
## 7 Chemie        98.2       6.4     111141     0.000884
## 8 Finanzdie...    265.       8.84     377879     0.000702
## 9 Mischkonz...    430.      32.8     630145     0.000683
## 10 Automobile   1384.      69.3    2258454     0.000613
## # i 13 more rows
## # i abbreviated name: 1umsatz_pro_mitarbeiter_mrd_USD
```

```
par(mar = c(8, 4, 4, 2) + 0.1)
par(las = 2, cex = 0.7)
barplot(height = aggregated_df$umsatz_pro_mitarbeiter_mrd_USD*1000 , names.arg = aggregated_d
f$Branche, ylim= c(0,5), ylab="Umsatz pro Mitarbeiter in Millionen USD", main = "Umsätze pro
Mitarbeiter")
```




Wie man hier sehen kann, liegen die Branchen Rohstoffhandel, Pharmahandel und Pharmazie an erster Stelle, wenn man denn Umsatz pro Mitarbeiter ansieht. Dies ist auch nicht verwunderlich, da ein Handelsunternehmen meist mehr Umsatz hat als andere Unternehmensarten.

Plot der Besten 5 Branchen im Sektor Gewinn

```
library(ggplot2)

top_5 <- aggregated_df %>%
  top_n(5, gewinn_summe)

ggplot(top_5, aes(x = umsatz_summe, y = gewinn_summe, label = Branche)) +
  geom_point() +
  geom_text(vjust = -0.5, hjust = 0.5) +
  labs(x = "Umsatz", y = "Gewinn") +
  theme_minimal()
```




In diesem Scatter-Plot kann man sehen, dass Banken sehr viel Gewinn/Umsatz machen und Öl und Gas generell sehr viel Umsatz.

Regressionsgerade Gewinn in Abhängigkeit der Mitarbeiteranzahl

```
regression_line <- lm(Gewinn ~ Mitarbeiter)
plot(Mitarbeiter, Gewinn, main = "Gewinn in Abhängigkeit der Mitarbeiteranzahl", xlab = "Mitarbeiter", ylab = "Gewinn in Mrd. USD", ylim = c(-10, 100))
abline(regression_line, col = "red")
```

Gewinn in Abhängigkeit der Mitarbeiteranzahl




Regressionsgerade Gewinn zu Umsatz in Abhängigkeit der Mitarbeiteranzahl

```
regression_line <- lm(Gewinn/Umsatz*100 ~ Mitarbeiter)
plot(Mitarbeiter, Gewinn/Umsatz*100, main = "Regressionsgerade Gewinn zu Umsatz in Abhängigkeit der Mitarbeiteranzahl", xlab = "Mitarbeiter", ylab = "Gewinn / Umsatz in %", ylim = c(-12, 80))

abline(regression_line, col = "red")
```

Regressionsgerade Gewinn zu Umsatz in Abhängigkeit der Mitarbeiteranz



Bewertung

In beiden Plots sind bei 2 Ausreißer zu sehen. In der vorangegangenen Auswertung ist zu sehen, dass die Unternehmen Fannie Mae und Freddie Mac sehr starke Ausreißer sind. Hier noch Daten dazu:

```
umsatz_mean <- mean(umsätze.df$Gewinn)
umsatz_sd <- sd(umsätze.df$Gewinn)
z_score <- (umsätze.df$Gewinn[Name == "Fannie Mae"] - umsatz_mean) / umsatz_sd
cat("Das Unternehmen Fannie Mae ist", z_score, "Sigma vom normalwert entfernt und daher ein s
tarker Ausreißer. In 3 Sigma sind 99.7% der Daten bei Normalverteilung. Bei diesem Wert ist e
s sehr weit davon entfernt.")
```

```
## Das Unternehmen Fannie Mae ist 5.71307 Sigma vom normalwert entfernt und daher ein starker
Ausreißer. In 3 Sigma sind 99.7% der Daten bei Normalverteilung. Bei diesem Wert ist es sehr
weit davon entfernt.
```

```
z_score <- (umsätze.df$Gewinn[Name == "Freddie Mac"] - umsatz_mean) / umsatz_sd
cat("Das Unternehmen Freddie Mac ist", z_score, "Sigma vom normalwert entfernt und daher gera
de kein wirklicher Ausreißer, wenn man annimmt, dass 3 Sigma noch im Rahmen von Normalwerten
ist.")
```

```
## Das Unternehmen Freddie Mac ist 2.990008 Sigma vom normalwert entfernt und daher gerade ke
in wirklicher Ausreißer, wenn man annimmt, dass 3 Sigma noch im Rahmen von Normalwerten ist.
```

Es sind auch diese Unternehmen, die kaum Mitarbeiter haben.

```

mitarbeiter_mean <- mean(Gewinn / Umsatz / Mitarbeiter)
mitarbeiter_sd <- sd(Gewinn / Umsatz / Mitarbeiter)
z_score <- (Gewinn[Name == "Fannie Mae"] / Umsatz[Name == "Fannie Mae"] / Mitarbeiter[Name ==
"Fannie Mae"] - mitarbeiter_mean) / mitarbeiter_sd
cat("Das Unternehmen Fannie Mae ist", z_score, "Sigma vom normalwert entfernt und daher wieder
ein starker Ausreißer.")

```

```

## Das Unternehmen Fannie Mae ist 5.893128 Sigma vom normalwert entfernt und daher wieder ein
starker Ausreißer.

```

```

z_score <- (Gewinn[Name == "Freddie Mac"] / Umsatz[Name == "Freddie Mac"] / Mitarbeiter[Name ==
"Freddie Mac"] - mitarbeiter_mean) / mitarbeiter_sd
cat("Das Unternehmen Freddie Mac ist", z_score, "Sigma vom normalwert entfernt und daher hier
ein starker Ausreißer.")

```

```

## Das Unternehmen Freddie Mac ist 7.632905 Sigma vom normalwert entfernt und daher hier ein
starker Ausreißer.

```

Lorenzkurve Umsätze

```

par(mfrow=c(1,2), cex = .8)
lorenzkurve(Umsatz, .2, "Konzernumsätze", "Anteil Unternehmen", "Anteil an Gesamtumsatz")
lorenzkurve(Mitarbeiter, .2, "Mitarbeiter", "Anteil Unternehmen", "Anteil an Mitarbeitern")

```

